

Universidad Autónoma de Baja California

FACULTAD DE INGENIERÍA

INGENIERÍA EN COMPUTACIÓN



**Desarrollo e implementación de un sistema embebido
basado en redes neuronales para la identificación automática
de variedades de vid mediante el análisis de hojas**

Asignatura

Proyecto de Carrera

Presentan:

**Jesús Ramón Ruiz Soto
Sergio Josué López García**

Profesor:

Dr. Adolfo Heriberto Ruelas Puente

Mexicali, B.C. México

Septiembre de 2026

1

Introducción

En este capítulo se presenta el estado del arte relacionado con la identificación de variedades de vid mediante características foliares, así como la problemática que motiva el desarrollo del proyecto, su justificación, objetivos, hipótesis y metodología propuesta. La revisión comprende desde los métodos ampelográficos tradicionales hasta las técnicas actuales basadas en aprendizaje profundo y su implementación en dispositivos con recursos computacionales limitados.

1.1. Estado del Arte

Esta sección presenta el estado del arte mediante una revisión sistemática de la literatura. La ejecución de la revisión sigue los lineamientos de Kitchenham y Charters [Kitchenham and Charters, 2007], mientras que la documentación del proceso de búsqueda y selección se apega al protocolo PRISMA 2020 [Page et al., 2021].

1.1.1. Metodología de la revisión sistemática

1.1.1.1. Justificación de la revisión

La identificación de variedades de vid (*Vitis vinifera* L.) mediante el análisis de hojas ha evolucionado desde la ampelografía tradicional hasta el uso de redes neuronales convolucionales, pasando por descriptores morfométricos y clasificadores de aprendizaje automático. Sin embargo, los estudios reportados emplean conjuntos de datos, arquitecturas, métricas y condiciones de evaluación heterogéneas, lo que dificulta determinar qué enfoques ofrecen un mejor equilibrio entre exactitud de clasificación y viabilidad de implementación en plataformas embebidas. Por esta razón se plantea una revisión sistemática que permita identificar, organizar y comparar la evidencia disponible sobre algoritmos, conjuntos de datos y estrategias de generalización e implementación embebida aplicadas a la identificación varietal de vid mediante hojas.

1.1.1.2. Preguntas de investigación

- **PI1.** ¿Qué algoritmos y arquitecturas se han utilizado para clasificar variedades de vid a partir de imágenes de hojas?
- **PI2.** ¿Qué conjuntos de datos (públicos o propios) se han empleado, y qué variedades y cantidad de imágenes cubren?

- **PI3.** ¿Qué métricas y niveles de desempeño se han reportado para estos clasificadores?
- **PI4.** ¿Cómo se ha evaluado la capacidad de generalización de los modelos frente a datos externos al entrenamiento?
- **PI5.** ¿Qué estrategias se han utilizado para implementar estos modelos en dispositivos con recursos computacionales limitados?

1.1.1.3. Estrategia de búsqueda

La estrategia de búsqueda se diseñó en dos fases. La **Fase 1**, cuyos resultados se reportan en esta revisión, consistió en la ejecución de las cadenas de búsqueda sobre fuentes de acceso abierto y motores académicos de cobertura amplia, complementada con el rastreo de referencias (*snowballing*) de los estudios recuperados. La **Fase 2**, que se ejecutará mediante el acceso institucional de la Universidad Autónoma de Baja California, replicará las mismas cadenas en Scopus, Web of Science e IEEE Xplore para incorporar los registros no accesibles públicamente. Esta separación se documenta de manera explícita para que el proceso sea reproducible y para distinguir con claridad el alcance de la evidencia aquí sintetizada.

1.1.1.3.1. Fuentes de información La búsqueda de la Fase 1 se realizó en las fuentes listadas en la Tabla 1.1, seleccionadas por su cobertura en agricultura de precisión, visión por computadora, aprendizaje profundo e ingeniería electrónica, así como por la disponibilidad de texto completo. Se consideraron publicaciones en inglés y español desde el año 2001 —fecha del primer antecedente morfométrico cuantitativo identificado— hasta septiembre de 2026. La última búsqueda se ejecutó el **17 de septiembre de 2026**. Los registros se consolidaron en una hoja de extracción única, en la que se eliminaron los duplicados comparando título, autores y DOI.

Tabla 1.1: Fuentes de información consultadas en la Fase 1 de la búsqueda.

Fuente	Fecha de búsqueda	Periodo	Registros recuperados
Motor académico general (Google Scholar y buscador web indexado)	17/09/2026	2001–2026	32
ScienceDirect (Elsevier)	17/09/2026	2001–2026	8
MDPI (<i>Plants</i> , <i>Agriculture</i> , <i>Sensors</i> , <i>AgriEngineering</i>)	17/09/2026	2018–2026	6
SpringerLink	17/09/2026	2015–2026	6
IEEE Xplore (acceso público)	17/09/2026	2015–2026	3

Fuente	Fecha de búsqueda	Periodo	Registros recuperados
Otras fuentes revisadas por pares (Cambridge Core, PLOS ONE, Frontiers, Nature Portfolio, Acta Horticulturae)	17/09/2026	2019–2026	7
Repositorios de datos y preimpresiones (Zenodo, Kaggle, arXiv)	17/09/2026	2021–2026	3
Total			65

1.1.1.3.2. Palabras clave Los conceptos principales derivados de las preguntas de investigación y sus sinónimos se presentan en la Tabla 1.2. Se incluyeron términos en inglés por ser el idioma predominante de la literatura especializada.

Tabla 1.2: Conceptos y palabras clave utilizadas en las cadenas de búsqueda.

Concepto	Palabras clave y sinónimos
Vid / uva	“grapevine”, “grape”, “Vitis vinifera”, “cultivar”
Hoja	“leaf”, “leaves”, “foliar”
Identificación de variedad	“variety identification”, “variety classification”, “cultivar classification”, “cultivar identification”, “ampelography”
Aprendizaje profundo	“deep learning”, “convolutional neural network”, “CNN”, “transfer learning”, “vision transformer”
Conjunto de datos	“dataset”, “image dataset”, “benchmark”
Generalización	“generalization”, “robustness”, “domain shift”, “external validation”
Sistema embebido	“embedded system”, “edge computing”, “edge device”, “lightweight model”, “mobile deployment”

1.1.1.3.3. Cadenas de búsqueda Se ejecutaron siete cadenas de búsqueda derivadas de la combinación de los conceptos anteriores. Las tres cadenas principales se muestran a continuación.

Cadena general:

("grapevine" OR "grape" OR "Vitis vinifera" OR cultivar)

AND

(leaf OR leaves OR foliar)

AND

("variety identification" OR "variety classification" OR "cultivar classification" OR ampelography)

AND

("deep learning" OR "convolutional neural network" OR CNN

OR "machine learning")

Cadena enfocada en implementación embebida:

("grapevine" OR "Vitis vinifera") AND (leaf OR foliar)

AND ("embedded system" OR "edge computing" OR
"lightweight model" OR "mobile application"
OR "edge device")

Cadena enfocada en generalización y conjuntos de datos:

("grapevine" OR "grape") AND (leaf OR leaves)

AND (dataset OR benchmark)

AND (generalization OR robustness OR "domain shift"
OR "external validation")

Durante la ejecución fue necesario adaptar las cadenas a la sintaxis de cada fuente. En los motores académicos generales se eliminaron los paréntesis anidados, que no son soportados, y cada bloque conceptual se ejecutó como una consulta independiente cuyos resultados se unieron manualmente. En MDPI y SpringerLink las comillas dobles se conservaron pero el operador AND se sustituyó por la búsqueda por campos de título y resumen. En ScienceDirect se aplicó además el filtro de tipo de documento "research article" para descartar editoriales y capítulos introductorios.

1.1.1.4. Criterios de inclusión y exclusión

Criterios de inclusión

- Estudios sobre identificación o clasificación de variedades de vid (*Vitis vinifera*) mediante hojas.
- Investigaciones que describan un método ampelográfico, morfométrico, de aprendizaje automático o aprendizaje profundo.
- Estudios que utilicen conjuntos de datos de imágenes foliares, públicos o propios.
- Conjuntos de datos públicos de imágenes de hoja de vid etiquetados por variedad, incorporados como recursos de datos.
- Artículos publicados en revistas o congresos con revisión por pares.
- Publicaciones en inglés o español dentro del periodo establecido.
- Documentos con texto completo disponible.

Criterios de exclusión

- Registros duplicados.
- Estudios sobre otras especies vegetales sin relación directa con vid, o sobre órganos distintos de la hoja (semilla, baya, sarmiento).
- Estudios enfocados exclusivamente en detección de enfermedades sin relación con identificación varietal. Estos se documentan como antecedente narrativo cuando aportan evidencia sobre arquitecturas ligeras o implementación embebida, pero no se integran a la extracción formal.
- Revisiones, editoriales, resúmenes y presentaciones sin datos originales.
- Propuestas teóricas sin implementación ni evaluación experimental.
- Documentación técnica, tutoriales y repositorios de código sin revisión por pares.
- Documentos no recuperados a texto completo o publicados fuera del periodo establecido.

1.1.1.5. Proceso de selección

Los registros recuperados de las siete cadenas se integraron en una hoja de extracción única. Primero se eliminaron los duplicados comparando título, autores y DOI; posteriormente se cribaron títulos y resúmenes aplicando los criterios de elegibilidad, y finalmente los documentos potencialmente relevantes se recuperaron y evaluaron a texto completo. Las cifras del proceso se presentan en la Tabla 1.3 y el flujo completo en la Figura 1.1.

Tabla 1.3: Resultados del proceso de selección de estudios (Fase 1).

Etapas	Cantidad
Registros identificados	65
Duplicados eliminados	18
Registros cribados (título/resumen)	47
Registros excluidos en el cribado	27
Informes buscados a texto completo	20
Informes no recuperados (acceso restringido)	2
Informes evaluados a texto completo	18
Informes excluidos a texto completo	6
Registros retenidos en la Fase 1	12
Coincidentes con la revisión narrativa previa	5
Nuevos registros incorporados	7
Total de registros incluidos en la revisión	26

El corpus final está formado por los 19 registros documentados en la revisión narrativa previa del proyecto más los 7 registros nuevos aportados por la Fase 1, para un total de 26 registros incluidos (22 estudios y 4 recursos de datos).




Figura 1.1: Diagrama de flujo del proceso de selección de estudios según PRISMA 2020, correspondiente a la Fase 1 de la búsqueda (17 de septiembre de 2026).

1.1.1.6. Evaluación de calidad

La calidad metodológica de los estudios se evaluó mediante la rúbrica de siete criterios presentada en la Tabla 1.4. Se establece de antemano que **la puntuación de calidad no se utiliza como criterio de exclusión**, sino únicamente para ponderar la interpretación de la evidencia: los hallazgos procedentes de estudios de calidad baja se reportan señalando explícitamente esa condición.

Tabla 1.4: Rúbrica de evaluación de calidad metodológica.

Código	Criterio de calidad
C1	¿Se define claramente el objetivo de clasificación varietal?
C2	¿Se describe el conjunto de datos (variedades, tamaño, procedencia)?
C3	¿Se explica suficientemente la arquitectura o método utilizado?
C4	¿Se reportan métricas de desempeño (exactitud, F1, matriz de confusión)?
C5	¿Se evalúa la generalización mediante datos externos o independientes?
C6	¿Se abordan requerimientos computacionales o viabilidad embebida?
C7	¿Se discuten limitaciones o amenazas a la validez?

Cada criterio se califica con 1 punto (sí), 0.5 (parcialmente) o 0 (no), para un máximo de 7 puntos. Los niveles resultantes son: calidad alta, de 6 a 7 puntos; calidad media, de 4 a 5.5 puntos; y calidad baja, menos de 4 puntos. Los cuatro recursos de datos (E14, E15, E16 y E26) no se puntúan, ya que la rúbrica está diseñada para estudios experimentales.

1.1.1.7. Extracción de datos

La Tabla 1.5 contiene la hoja de extracción completa de los 26 registros incluidos. La columna de calidad reporta la puntuación obtenida con la rúbrica C1–C7; se indica “RD” para los recursos de datos y “NI” (no informado) cuando el estudio no proporciona el dato correspondiente.

Tabla 1.5: Hoja de extracción de datos de los registros incluidos.

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E01	Ates et al. [2011]	Descriptores ampelográficos + análisis de conglomerados	10 cultivares (Turquía)	Diferenciación morfológica por conglo- merados	4.0

continúa en la página siguiente

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E02	Mancuso [2001]	Dimensión fractal (<i>box-counting</i>)	Ecotipos de Sangiovese	Menor error que descriptores tradicionales	3.0
E03	Chitwood et al. [2014]	Morfometría geométrica (Fourier elíptico, Procrustes)	>1200 accesiones	Componentes genéticos de forma y venación	4.5
E04	Chitwood [2021]	Integración de ampelografía clásica y morfometría	NI	Marco conceptual, sin clasificador automático	2.0
E05	Fuentes et al. [2018]	Morfo-colorimetría + fractal + NIR + ANN	16 cultivares	Exactitud 94.2 %	5.5
E06	Koklu et al. [2022a]	MobileNetV2 (extracción de características) + SVM	5 variedades, 500 imágenes	Exactitud >97 %	5.0
E07	Reyes et al. [2015]	Ajuste fino de CNN preentrenadas	Reconocimiento de plantas (general)	Antecedente metodológico de transferencia	3.5
E08	Hall et al. [2015]	Evaluación de características para clasificación de hojas	Condiciones visuales complejas (general)	Antecedente metodológico, no específico de vid	4.5
E09	Pereira et al. [2019]	Transferencia de aprendizaje (AlexNet)	6 variedades de uva tinta	Exactitud 77.3 %	5.5
E10	Liu et al. [2021]	Comparación de CNN + aplicación Android	21 cultivares	Hasta 99.91 % (GoogLeNet); app funcional	6.5
E11	Magalhães et al. [2023b]	MobileNetV2 / ResNet-34 / VGG-11-BN	26 variedades	F1-score 94.75 % (MobileNetV2)	6.0

continúa en la página siguiente

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E12	Terzi et al. [2024]	CNN con nuevas características ampelográficas	NI	Exactitud ≈94.1 %	4.0
E13	Adão et al. [2025]	Xception + Mask R-CNN (segmentación previa)	6 var. (GIG6wb, 480 img.) y 12 var. (GIG12nb, 888 img.), Portugal	98.33 % (6 var.) / 95 % (12 var.)	6.0
E14	Vlah [2021]	Conjunto de datos público <i>Grapevine Leaves</i> (Kaggle)	11 variedades, ≈1000 imágenes	Recurso de datos; usado como conjunto externo por E17	RD
E15	Carneiro [2024]	Conjunto de datos público UTAD Grapevine Varieties 2023	Varios dispositivos y condiciones	Recurso de datos con mayor variabilidad	RD
E16	Shah et al. [2026]	Conjunto de datos estandarizado GLVD (multi-fuente)	1469 imágenes, 16 cultivares	Particiones definidas de entrenamien- to/validación/ prueba	RD
E17	De Nart et al. [2024]	Comparación de 5 modelos de visión + validación externa	26 382 imágenes, 27 variedades, 3 sitios (Italia)	Alta exactitud interna; caída marcada en conjunto externo	6.5
E18	Lazcano- García et al. [2025]	CNN para enfermedades virales + <i>edge computing</i> (Jetson Nano)	Contexto vitivinícola de Baja California	Viabilidad de <i>edge computing</i> demostrada (no varietal)	6.0
E19	López García [2025]	Mediciones ampelográficas manuales (ImageJ)	Misión, Syrah y Tempranillo (Baja California)	Conjunto local de referencia para evaluación externa	2.5

continúa en la página siguiente

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E20	Vélez et al. [2024]	CNN con Keras/-TensorFlow (ampelografía digital)	2 cultivares (Verdejo, Tempranillo), 1011 imágenes	95.8 % (Verdejo) y 100 % (Tempranillo)	4.0
E21	Kunduracioglu and Pacal [2024]	Comparación de 14 CNN y 17 transformadores de visión	5 variedades, 500 imágenes	100 % con Swinv2-Base sobre un conjunto reducido	5.0
E22	Carneiro et al. [2024]	Transformadores de visión (ViT) + autocodificadores enmascarados	43 variedades; 13 479 y 6 776 img. etiquetadas; 54 571 sin etiquetar	F1-score 0.796 (ViT-B preentrenado)	6.5
E23	Huang [2025]	DenseNet201 optimizado (normalización, agrupamiento global y regularización)	5 variedades, 500 img. aumentadas a 2500	F1-score 0.756 en prueba, pese a 99.5 % en entrenamiento	4.5
E24	Deng et al. [2025]	ICS-MobileNetV3-Small (atención de coordenadas + pérdida conjunta)	11 cultivares (incl. Syrah y Tempranillo), 6051 img. en viñedo real	96.53 % con 1.17 M de parámetros (−23.5 %)	6.5
E25	Colibaba et al. [2026]	Xception con ajuste fino en dos fases	10 cultivares autóctonos rumanos	Herramienta de reconocimiento; exactitud NI	2.0
E26	Koklu et al. [2022b]	Conjunto de datos público Grapevine Leaves Image Dataset	500 imágenes, 5 variedades	Recurso de datos base de E06, E21 y E23	RD

1.1.1.8. Método de síntesis

Los estudios se agruparon en las categorías: ampelografía tradicional, morfometría cuantitativa sin aprendizaje automático, aprendizaje automático clásico con características diseñadas manualmente, aprendizaje profundo y transferencia de aprendizaje, arquitecturas basadas en transformadores, implementación embebida y recursos de datos públicos. Para cada categoría se compararon resultados, arquitecturas y limitaciones mediante tablas, gráficas generadas a partir de la hoja de

extracción y una síntesis narrativa. No se realizó un metaanálisis estadístico debido a la heterogeneidad de conjuntos de datos, número de variedades consideradas, particiones de evaluación y métricas reportadas entre los estudios.

1.1.2. Resultados de la revisión

1.1.2.1. Resultados de la búsqueda y selección

La Fase 1 de la búsqueda produjo 65 registros. Tras eliminar 18 duplicados se cribaron 47 títulos y resúmenes, de los cuales 27 fueron excluidos principalmente por tratarse de documentación técnica sin revisión por pares, de estudios sobre enfermedades sin relación varietal o de trabajos sobre otras especies vegetales. Se buscaron 20 informes a texto completo; 2 no pudieron recuperarse por acceso restringido —ambos artículos de congreso alojados en IEEE Xplore, uno sobre modelos de conjunto y otro sobre una aproximación basada en MobileNetV3Large—, por lo que se evaluaron 18 informes completos. De estos, 6 fueron excluidos y 12 retenidos; 5 de los 12 coincidían con estudios ya documentados en la revisión narrativa previa del proyecto y 7 constituyen aportaciones nuevas. Sumados a los 19 registros previos, el corpus final de la revisión asciende a 26 registros: 22 estudios y 4 recursos de datos públicos. La Figura 1.1 presenta el flujo completo.

Es pertinente señalar que la coincidencia de 5 de los 12 registros retenidos con el conjunto documentado previamente funciona como una prueba piloto implícita: indica que las cadenas de búsqueda recuperan de manera efectiva los estudios relevantes ya conocidos, lo cual respalda su validez antes de ejecutar la Fase 2 en las bases de datos de suscripción.

1.1.2.2. Características de los estudios incluidos

La Tabla 1.6 resume la distribución de los 26 registros incluidos por enfoque metodológico principal. La categoría más numerosa es la del aprendizaje profundo basado en redes convolucionales, con 10 estudios, y las dos categorías más recientes —transformadores de visión e implementación embebida— concentran los trabajos publicados a partir de 2024.

Tabla 1.6: Distribución de los registros incluidos por enfoque metodológico.

Categoría	n	Identificadores
Ampelografía tradicional	1	E01
Morfometría cuantitativa sin aprendizaje automático	4	E02, E03, E04, E19
Aprendizaje automático clásico con características diseñadas manualmente	3	E05, E06, E08
Aprendizaje profundo con redes convolucionales	10	E07, E09, E10, E11, E12, E13, E17, E20, E23, E25

Categoría	n	Identificadores
Transformadores de visión y aprendizaje autosupervisado	2	E21, E22
Implementación embebida o <i>edge computing</i>	2	E18, E24
Recursos de datos públicos	4	E14, E15, E16, E26
Total	26	

En cuanto a la distribución temporal, 19 de los 26 registros (73 %) se publicaron a partir de 2021 y 13 (50 %) a partir de 2024, lo que confirma que se trata de una línea de investigación en expansión activa. Geográficamente predominan los trabajos europeos —Portugal (E11, E13, E22), Italia (E02, E17), España (E20) y Rumania (E25)—, seguidos de Turquía (E01, E06, E12, E21, E26) y China (E10, E23, E24). Los únicos antecedentes mexicanos identificados corresponden al propio contexto de Baja California (E18 y E19).

1.1.2.3. Resultados de la extracción de datos

Las exactitudes reportadas por los estudios de clasificación varietal mediante aprendizaje automático y profundo oscilan entre 75.6 % de F1-score (E23, DenseNet201 sobre 5 variedades) y 100 % (E21, Swinv2-Base sobre las mismas 5 variedades y el mismo conjunto de 500 imágenes). Este contraste es el hallazgo más informativo de la extracción: dos estudios que emplean el mismo recurso de datos (E26) reportan desempeños separados por casi 25 puntos porcentuales, lo que evidencia que el protocolo de evaluación —particiones, aumento de datos y selección del conjunto de prueba— influye tanto o más que la arquitectura elegida.

Las arquitecturas ligeras de la familia MobileNet aparecen de forma recurrente (E06, E11, E17, E21, E24), y el estudio más reciente de la serie (E24) es también el que reporta de manera más completa el costo computacional: 1.17 millones de parámetros, una reducción del 23.5 % respecto a la línea base, con 96.53 % de exactitud sobre 11 cultivos fotografiados en un viñedo real. Los tamaños de los conjuntos de datos varían en tres órdenes de magnitud, desde 500 imágenes (E06, E21, E23, E26) hasta 26 382 imágenes (E17) y 54 571 imágenes sin etiquetar empleadas para preentrenamiento autosupervisado (E22).

El número de variedades consideradas oscila entre 2 (E20) y 43 (E22). Las métricas reportadas con mayor frecuencia son la exactitud (*accuracy*), el F1-score y el F1-score macro; solo E11, E22, E23 y E24 reportan además matrices de confusión o métricas por clase, y únicamente E17 y E22 reportan resultados sobre conjuntos externos al entrenamiento.

1.1.2.4. Resultados de la evaluación de calidad

La rúbrica C1–C7 se aplicó a los 22 estudios experimentales; los 4 recursos de datos quedaron fuera de la evaluación. Las puntuaciones individuales se presentan en la Tabla 1.7. La evaluación se basó en la información disponible en los textos completos recuperados y en los resúmenes estructurados de los estudios no accesibles en su totalidad, condición que se reconoce en la sección de amenazas a la validez.

Tabla 1.7: Puntuaciones de calidad metodológica por estudio.

ID	C1	C2	C3	C4	C5	C6	C7	Total	Nivel
E01	1	1	1	0.5	0	0	0.5	4.0	Media
E02	0.5	0.5	1	0.5	0	0	0.5	3.0	Baja
E03	0.5	1	1	1	0	0	1	4.5	Media
E04	0.5	0.5	0.5	0	0	0	0.5	2.0	Baja
E05	1	1	1	1	0	0.5	1	5.5	Media
E06	1	1	1	1	0	0.5	0.5	5.0	Media
E07	0	1	1	1	0	0	0.5	3.5	Baja
E08	0	1	1	1	0.5	0.5	0.5	4.5	Media
E09	1	1	1	1	0	0.5	1	5.5	Media
E10	1	1	1	1	0.5	1	1	6.5	Alta
E11	1	1	1	1	0	1	1	6.0	Alta
E12	1	0.5	1	1	0	0	0.5	4.0	Media
E13	1	1	1	1	0.5	0.5	1	6.0	Alta
E17	1	1	1	1	1	0.5	1	6.5	Alta
E18	0.5	1	1	1	0.5	1	1	6.0	Alta
E19	1	0.5	0.5	0	0	0	0.5	2.5	Baja
E20	1	1	0.5	1	0	0	0.5	4.0	Media
E21	1	1	1	1	0	0.5	0.5	5.0	Media
E22	1	1	1	1	1	0.5	1	6.5	Alta
E23	1	1	1	1	0	0	0.5	4.5	Media
E24	1	1	1	1	0.5	1	1	6.5	Alta
E25	1	0.5	0.5	0	0	0	0	2.0	Baja

De los 22 estudios evaluados, 7 alcanzaron calidad alta (E10, E11, E13, E17, E18, E22 y E24), 10 calidad media y 5 calidad baja. La distribución se muestra en la Figura 1.5.

El análisis por criterio revela un patrón muy marcado. Los criterios C3 (descripción del método) y C4 (reporte de métricas) se satisfacen de forma prácticamente generalizada: 18 y 17 de los 22 estudios los cumplen por completo. En cambio, el criterio **C5 (generalización con datos externos)** es el más débil de todo el corpus: solo 2 estudios de 22 (E17 y E22) lo satisfacen plenamente y 5 más lo hacen de manera parcial, lo que significa que 15 de 22 estudios no evalúan en absoluto el comportamiento de su modelo fuera del conjunto con el que fue entrenado. El criterio C6 (requerimientos computacionales o viabilidad embebida) es el segundo más débil, con solo 4 estudios que lo satisfacen por completo (E10, E11, E18 y E24).

Estas dos debilidades coinciden exactamente con los dos ejes que el presente proyecto se propone abordar.

1.1.2.5. Resultados por pregunta de investigación

PI1 (Algoritmos y arquitecturas). Se identificó una progresión clara en cuatro etapas. Primero, descriptores ampelográficos y morfométricos (E01–E04, E19). Segundo, clasificadores de aprendizaje automático sobre características diseñadas manualmente, como redes neuronales artificiales alimentadas con parámetros morfocolorimétricos, fractales y de espectroscopía NIR (E05), o máquinas de soporte vectorial sobre características extraídas por una red convolucional (E06). Tercero, redes neuronales convolucionales mediante transferencia de aprendizaje, incluyendo AlexNet (E09), GoogLeNet (E10), MobileNetV2, ResNet-34 y VGG-11-BN (E11), Xception con segmentación previa por Mask R-CNN (E13), Xception con ajuste fino en dos fases (E25), EfficientNet e Inception-ResNet (E17) y DenseNet201 optimizado (E23). Cuarto, y como desarrollo más reciente, arquitecturas basadas en transformadores de visión: comparaciones exhaustivas de 14 CNN frente a 17 transformadores (E21) y preentrenamiento autosupervisado con autocodificadores enmascarados sobre ViT (E22). En paralelo a esta progresión, una línea específica optimiza arquitecturas ligeras para su despliegue en campo, cuyo exponente más avanzado es ICS-MobileNetV3-Small (E24). La Figura 1.3 presenta la frecuencia de cada categoría.

PI2 (Conjuntos de datos). Existen cuatro recursos públicos identificados: *Grapevine Leaves* en Kaggle, con 11 variedades y alrededor de 1000 imágenes (E14); el Grapevine Leaves Image Dataset, con 500 imágenes de 5 variedades, que es el más utilizado por su facilidad de acceso (E26, empleado por E06, E21 y E23); UTAD Grapevine Varieties 2023, adquirido con múltiples dispositivos y condiciones (E15); y GLVD, con 1469 imágenes de 16 cultivares y particiones predefinidas de entrenamiento, validación y prueba (E16). Los conjuntos propios de mayor escala pertenecen a E17 (26 382 imágenes, 27 variedades, 3 sitios en Italia) y E22 (13 479 y 6 776 imágenes etiquetadas de 43 variedades, más 54 571 imágenes sin etiquetar para preentrenamiento). En el extremo opuesto, E20 trabaja con solo 2 cultivares y E06, E21, E23 y E26 con 5.

PI3 (Métricas y desempeño). Las métricas predominantes son la exactitud, el F1-score y el F1-score macro. Los valores reportados abarcan un rango muy amplio, de 75.6 % (E23) a 100 % (E21), sin una relación monótona con el número de variedades, como se aprecia en la Figura 1.4. El caso de E10 (99.91 % sobre 21 cultivares) y el de E22 (F1 de 0.796 sobre 43 variedades) ilustran que la dificultad real depende más de las condiciones de adquisición —fondo controlado frente a viñedo real— que del número de clases. Solo cuatro estudios (E11, E22, E23 y E24) reportan métricas desagregadas por clase o matrices de confusión, lo que limita la posibilidad de identificar qué variedades resultan sistemáticamente más difíciles de distinguir.

PI4 (Generalización). Esta es la dimensión con mayor déficit de evidencia. E17 constituye el caso más directo y mejor documentado: cinco modelos entrenados sobre 26 382 imágenes de 27 variedades alcanzaron exactitudes internas muy altas, pero al evaluarse contra un conjunto externo —precisamente el recurso público E14,

restringido a las 8 variedades compartidas— la exactitud en la primera predicción cayó de manera drástica, recuperándose de forma solo parcial (aproximadamente 0.75 a 0.83) al admitir las tres o cinco predicciones más probables. E22 confirma el mismo fenómeno desde otro ángulo: al construir un banco de pruebas con temporadas de adquisición distintas para entrenamiento y evaluación, el mejor F1-score obtenido fue de 0.796, muy por debajo de las cifras superiores al 95 % que se reportan en escenarios de partición aleatoria. E24 aporta evidencia complementaria al trabajar directamente con fondos complejos de viñedo real y cuantificar el nivel de oclusión de las hojas (65 % sin obstrucción, 25 % ligeramente ocluidas, 10 % moderadamente ocluidas). En conjunto, estos tres estudios establecen que la exactitud obtenida sobre particiones aleatorias de un conjunto homogéneo sobrestima de manera sistemática el desempeño esperable en campo.

PI5 (Implementación embebida). Se identificaron dos estrategias diferenciadas. La primera es el despliegue en dispositivos móviles: E10 desarrolló y validó una aplicación Android funcional para 21 cultivos, y E11 seleccionó MobileNetV2 explícitamente por su relación entre desempeño y costo computacional. La segunda es el diseño de arquitecturas ligeras específicas: E24 reduce MobileNetV3-Small a 1.17 millones de parámetros mediante atención de coordenadas y una función de pérdida conjunta, conservando 96.53 % de exactitud. Como antecedentes narrativos —excluidos de la extracción formal por tratarse de detección de enfermedades y no de identificación varietal— destacan tres trabajos que documentan con precisión el costo de inferencia en hardware real: E18, que ejecuta modelos de visión sobre NVIDIA Jetson Nano en el contexto vitivinícola de Baja California; Karim et al. [2024], que reporta 90 ms por imagen y un consumo aproximado de 3.4 W sobre Jetson Nano B01; y Chen et al. [2025], que alcanza 1.75 millones de parámetros y 0.18 GFLOPs con una variante de MobileNetV4-small. Ninguno de los estudios de identificación varietal recuperados reporta simultáneamente latencia, consumo energético y exactitud medidos sobre la plataforma embebida de destino.

1.1.2.6. Representación gráfica

Las figuras de esta subsección se generaron a partir de la hoja de extracción de datos (Tabla 1.5) y de las puntuaciones de calidad (Tabla 1.7).

La Figura 1.2 muestra una concentración pronunciada en el periodo 2024–2026, que reúne 13 de los 26 registros. Los antecedentes previos a 2015 corresponden en su totalidad a métodos ampelográficos y morfométricos, sin componentes de aprendizaje automático.

La Figura 1.4 confirma la ausencia de una relación simple entre el número de variedades y el desempeño alcanzado. Los dos valores más bajos del corpus corresponden, por un lado, al estudio con mayor número de clases y condiciones de adquisición más exigentes (E22, 43 variedades) y, por otro, a un estudio con solo 5 variedades sobre un conjunto reducido (E23), mientras que otro estudio sobre ese mismo conjunto alcanza el 100 % (E21). Esta dispersión vertical dentro de una misma abscisa es la evidencia más directa de que las métricas publicadas no son comparables entre sí sin considerar el protocolo de evaluación.




Figura 1.2: Distribución de los 26 registros incluidos por año de publicación.




Figura 1.3: Frecuencia de los enfoques metodológicos identificados en la revisión.




Figura 1.4: Desempeño reportado frente al número de variedades clasificadas. Para E20 se grafica el promedio de los dos cultivares evaluados; para E22 y E23 se grafica el F1-score, por ser la métrica principal reportada.




Figura 1.5: Distribución de los 22 estudios experimentales por nivel de calidad metodológica según la rúbrica C1–C7.

1.1.3. Discusión de los hallazgos

1.1.3.1. Interpretación de los resultados

Los hallazgos revelan una tensión de tres vértices —exactitud, costo computacional y generalización— que la literatura ha resuelto hasta ahora sacrificando alguno de ellos. Los métodos ampelográficos y morfométricos clásicos (E01–E04, E19) exigen recursos computacionales mínimos y ofrecen interpretabilidad botánica directa, pero dependen de mediciones manuales que impiden la automatización. Las redes convolucionales profundas alcanzan exactitudes superiores al 99 % (E10) a costa de modelos de decenas de millones de parámetros. Las arquitecturas ligeras constituyen el punto intermedio más prometedor, y su evolución dentro del corpus es medible: de MobileNetV2 usada como extractor de características (E06) y como clasificador completo (E11, F1 de 94.75 % sobre 26 variedades), a una variante de MobileNetV3-Small rediseñada específicamente para el problema, con 1.17 millones de parámetros y 96.53 % de exactitud sobre imágenes de viñedo real (E24).

La interpretación más relevante para el presente proyecto, sin embargo, no proviene de los valores máximos de exactitud sino de su varianza. Que E21 y E23 reporten 100 % y 75.6 % respectivamente sobre el mismo recurso de 500 imágenes y las mismas 5 variedades indica que una parte sustancial de las cifras publicadas mide la facilidad del conjunto de datos y no la capacidad del modelo. Los conjuntos pequeños de fondo controlado, con particiones aleatorias y aumento de datos aplicado antes de la partición, favorecen la memorización de artefactos de adquisición. Esta lectura es coherente con la caída documentada por E17 al cambiar de fuente de datos y con el F1-score de 0.796 que E22 obtiene al separar las temporadas de adquisición entre entrenamiento y evaluación.

En cuanto a la viabilidad embebida, los estudios de identificación varietal tratan el costo computacional como una justificación cualitativa para elegir una arquitectura, no como una variable medida. Solo E10 valida una implementación funcional —una aplicación Android— y solo E24 reporta el conteo de parámetros del modelo final. Ninguno reporta latencia de inferencia, consumo energético ni uso de memoria sobre la plataforma de destino. Los datos más precisos sobre este eje provienen de trabajos

de detección de enfermedades: 90 ms por imagen y 3.4 W en Jetson Nano [Karim et al., 2024] y 0.18 GFLOPs con 1.75 millones de parámetros [Chen et al., 2025]. Esto significa que el proyecto debe importar la metodología de medición de la literatura de enfermedades y aplicarla al problema varietal.

1.1.3.2. Comparación con otras investigaciones

Los resultados de esta revisión coinciden con la conclusión central de las revisiones previas sobre ampelografía digital, que identifican la transferencia de aprendizaje sobre redes convolucionales preentrenadas como el enfoque dominante. La aportación diferencial de la presente revisión es la incorporación de los trabajos de 2024–2026, que modifican ese panorama en dos sentidos: introducen los transformadores de visión y el preentrenamiento autosupervisado como alternativa competitiva (E21, E22) y, sobre todo, desplazan el criterio de evaluación desde la exactitud sobre conjuntos controlados hacia la robustez en condiciones de campo (E17, E22, E24). El antecedente local del PVVC-UABC (E19) resulta directamente consistente con la necesidad señalada por E17 y E22 de evaluar los modelos con muestras independientes del entrenamiento: las hojas de Misión, Syrah y Tempranillo cultivadas en Baja California constituyen precisamente un dominio distinto al de los conjuntos públicos europeos y turcos. Este punto adquiere mayor peso al observar que E24 clasifica 11 cultivares que incluyen Syrah y Tempranillo, lo que abre la posibilidad de una comparación directa entre el desempeño publicado sobre ese conjunto chino y el desempeño obtenido sobre material vegetal de Baja California. Se trata, en los términos de E17, de un escenario de validación externa con variedades compartidas.

De manera complementaria, Lazcano-García et al. [2025] (E18) —aunque enfocado en enfermedades virales y no en identificación varietal— constituye el antecedente regional más directo de que es viable procesar imágenes de hojas de vid sobre plataformas de *edge computing* dentro del contexto vitivinícola de Baja California, y por tanto valida la factibilidad técnica de la plataforma sobre la que se desplegará el sistema propuesto.

1.1.3.3. Limitaciones y amenazas a la validez

Se reconocen cinco amenazas a la validez de esta revisión.

Cobertura incompleta de las fuentes. La Fase 1 se ejecutó sobre fuentes de acceso abierto y motores académicos de cobertura amplia; los conteos exportables de Scopus, Web of Science e IEEE Xplore quedan pendientes de la Fase 2. Es posible que existan estudios indexados exclusivamente en esas bases que no hayan sido recuperados. La coincidencia de 5 de los 12 registros retenidos con el conjunto documentado previamente mitiga parcialmente esta amenaza, pero no la elimina.

Sesgo de recuperación por acceso. Dos informes de congreso no pudieron evaluarse a texto completo por acceso restringido, y ambos tratan precisamente temas centrales para las preguntas PI1 y PI5 (modelos de conjunto y una aproximación basada en MobileNetV3Large). Su exclusión podría subestimar la evidencia disponible sobre arquitecturas ligeras.

Evaluación de calidad basada en información parcial. La rúbrica C1–C7 se aplicó a partir de los textos completos recuperados y, en los casos en que el texto completo no estaba disponible, de resúmenes estructurados. Las puntuaciones de E12 y E25 son las más susceptibles a esta limitación, al haberse asignado con información reducida.

Heterogeneidad que impide la comparación cuantitativa. Las diferencias en número de variedades, tamaño y procedencia de los conjuntos de datos, estrategias de aumento, particiones y métricas hacen que las cifras de desempeño no sean directamente comparables, motivo por el cual se descartó el metaanálisis. Las comparaciones presentadas en la Figura 1.4 deben leerse como una caracterización de la dispersión existente, no como un ordenamiento de arquitecturas.

Extracción realizada por un número reducido de revisores. La selección y extracción no se realizaron por duplicado de forma independiente, por lo que no fue posible calcular un índice de concordancia entre revisores. Esta condición introduce un riesgo de sesgo de selección que se mitigó mediante la aplicación explícita y documentada de los criterios de elegibilidad, pero que no queda descartado.

1.1.4. Conclusiones del estado del arte

La revisión de 26 registros confirma que la identificación automática de variedades de vid mediante imágenes de hojas es técnicamente viable, con exactitudes reportadas de hasta 99.91 % sobre 21 cultivares (E10), y que existen antecedentes de implementación tanto en dispositivos móviles (E10) como en plataformas de *edge computing* en el propio contexto vitivinícola de Baja California (E18). La evolución metodológica documentada —de la ampelografía manual a las arquitecturas ligeras optimizadas para campo— indica además que el problema se considera resuelto en el plano algorítmico y que el interés de la comunidad se ha desplazado hacia las condiciones de despliegue.

Ese desplazamiento es precisamente donde la evidencia resulta más escasa. La evaluación de calidad muestra que 15 de los 22 estudios experimentales no evalúan en absoluto la generalización hacia datos externos, y que solo 4 documentan los requerimientos computacionales de su modelo final. Los tres estudios que sí abordan la generalización (E17, E22 y E24) coinciden en que la exactitud obtenida sobre particiones aleatorias de un conjunto homogéneo sobrestima de manera sistemática el desempeño en campo, con caídas que en el caso de E17 resultan drásticas al cambiar de fuente de datos. A esto se suma que ningún estudio de identificación varietal reporta latencia de inferencia, consumo energético y exactitud medidos de forma conjunta sobre la plataforma embebida de destino; los únicos datos precisos en ese sentido provienen de la literatura de detección de enfermedades.

En consecuencia, ningún trabajo identificado combina simultáneamente los tres elementos que define el presente proyecto: clasificación varietal de vid a partir de hojas, evaluación de generalización con un conjunto local independiente del entrenamiento, e implementación completa y caracterizada en una plataforma embebida. Esta combinación constituye la brecha que aborda el proyecto, y el conjunto local de Misión, Syrah y Tempranillo documentado por el PVVC-UABC (E19) —con dos de esas tres variedades presentes también en el conjunto de E24—

ofrece la base para llevar a cabo esa evaluación externa.

1.2. Problemática

Baja California concentra la mayor parte de la producción vitivinícola del país: de acuerdo con cifras difundidas en 2024, alrededor del 85 % del vino que se produce en México proviene de este estado, que reúne más de 150 vinícolas y cerca de 4600 hectáreas de viñedo [Torres, 2024]. En una industria de este peso regional, conocer con certeza qué variedad se tiene plantada no es un detalle técnico: determina el manejo agronómico del viñedo, la etiqueta del vino, el valor comercial de la uva y el cumplimiento de los contratos entre productores y vinícolas.

A pesar de ello, la identificación varietal sigue dependiendo de dos caminos, ambos con limitaciones importantes. El primero es la ampelografía: la descripción morfológica de hojas, brotes y racimos por parte de un especialista. Este método requiere personal altamente capacitado y escaso, solo puede aplicarse en ventanas específicas del ciclo vegetativo, y su resultado se ve afectado por la variación ambiental, las infecciones virales que deforman la hoja, la variabilidad clonal de las variedades antiguas y la interpretación del propio observador [Wine Australia, 2010]. El segundo camino es el análisis molecular mediante marcadores de ADN, que ofrece una identificación objetiva pero exige enviar muestras a un laboratorio especializado, con el costo y el tiempo de espera que ello implica, lo que lo hace poco práctico como herramienta de consulta cotidiana en campo.

Las consecuencias de una identificación errónea están documentadas. En la industria australiana se han reportado plantaciones registradas con un nombre que en realidad contenían otra variedad, mezclas de varias variedades bajo una sola denominación y, en el caso más conocido, un material importado como Albariño que años después resultó ser Savagnin Blanc, lo que obligó a reetiquetar vinos, modificar planes de comercialización y suspender contratos con productores [Wine Australia, 2010].

En el plano tecnológico, la revisión sistemática presentada en la sección anterior muestra que la identificación automática de variedades a partir de imágenes de hojas es técnicamente viable, con exactitudes reportadas superiores al 95 % en múltiples estudios. Sin embargo, la misma revisión evidencia dos carencias que impiden trasladar esos resultados al campo. La primera es la falta de evaluación de la generalización: 15 de los 22 estudios experimentales no evalúan su modelo con datos externos al conjunto de entrenamiento, y los pocos que lo hacen documentan caídas drásticas de desempeño al cambiar la fuente de las imágenes [De Nart et al., 2024, Carneiro et al., 2024]. La segunda es la falta de caracterización embebida: ningún estudio de identificación varietal reporta de manera conjunta la exactitud, la latencia y el consumo energético del modelo sobre la plataforma de hardware en la que operaría.

A estas dos carencias se suma una tercera, propia del contexto regional. Los conjuntos de datos públicos disponibles fueron adquiridos en viñedos de Europa, Turquía y China, bajo condiciones de clima, suelo, iluminación y equipo de captura distintas a las de Baja California. Además, la variedad Misión —la vid histórica introducida en las misiones de la península y genéticamente identificada con la española Listán Prieto [Tapia et al., 2007]— no aparece en ninguno de los conjuntos

públicos identificados. En consecuencia, un clasificador entrenado exclusivamente con datos públicos no solo podría perder exactitud al enfrentarse a hojas locales de variedades conocidas, sino que tendería a asignar con falsa seguridad una etiqueta equivocada a cualquier variedad que nunca vio durante el entrenamiento.

Con base en lo anterior, el problema que aborda este proyecto se formula de la siguiente manera: **no se dispone de un sistema de identificación varietal de vid a partir de hojas que opere de forma autónoma sobre hardware de bajo costo y cuyo desempeño haya sido verificado con hojas cultivadas en Baja California, independientes de los datos con los que fue entrenado.**

1.3. Justificación

El desarrollo del sistema propuesto se justifica desde cuatro perspectivas.

Relevancia regional y económica. Dado que Baja California concentra la mayor parte de la producción nacional de vino [Torres, 2024], una herramienta que facilite la verificación varietal atiende una necesidad concreta de la industria local: la validación del material vegetal adquirido en viveros, la auditoría de plantaciones existentes y la documentación de variedades en viñedos antiguos. Un sistema embebido de bajo costo permitiría realizar una primera verificación directamente en el viñedo, reservando el análisis molecular —más costoso y lento— para los casos en que el sistema reporte baja confianza o una posible discrepancia.

Aportación técnica. El proyecto se dirige exactamente a las dos debilidades más marcadas que identificó la evaluación de calidad del estado del arte: la evaluación de la generalización con datos externos (criterio C5) y la caracterización de la viabilidad embebida (criterio C6). A diferencia de los trabajos revisados, el sistema no se evaluará únicamente sobre una partición del mismo conjunto con el que se entrenó, sino sobre un conjunto local adquirido de forma independiente, y su desempeño se medirá directamente sobre la plataforma de destino. Incorpora además un mecanismo de rechazo por confianza, de modo que el sistema pueda reportar “variedad no reconocida” en lugar de forzar una etiqueta incorrecta, una capacidad que ninguno de los estudios revisados evalúa de forma explícita.

Vinculación académica. El proyecto da continuidad al trabajo del Programa de Vinculación con Valor en Créditos de la UABC realizado en colaboración con Viñas Pasini [López García, 2025], que documentó hojas de Misión, Syrah y Tempranillo cultivadas en Baja California. Ese material, que por sí solo es insuficiente para entrenar una red neuronal profunda, adquiere un valor científico particular al emplearse como conjunto de prueba independiente, ya que permite medir de forma directa el efecto del cambio de dominio entre los datos públicos y las condiciones locales.

Viabilidad. El proyecto es realizable con los recursos disponibles: existen conjuntos de datos públicos con licencia abierta que incluyen dos de las tres variedades locales, las arquitecturas ligeras de redes convolucionales cuentan con modelos preentrenados de libre acceso, y las plataformas embebidas candidatas son de bajo costo y cuentan con soporte maduro para la ejecución de modelos cuantizados.

Los beneficiarios directos del proyecto son los productores y viveristas de la región, que contarían con una herramienta de verificación de primer nivel; los técnicos y

enólogos, como apoyo a la labor ampelográfica; y la comunidad académica, que dispondría de una evaluación documentada del comportamiento de estos modelos fuera de su dominio de entrenamiento.

1.4. Objetivos

1.4.1. Objetivo general

Desarrollar e implementar un sistema embebido basado en redes neuronales convolucionales que identifique automáticamente variedades de vid a partir de imágenes de hojas, entrenado con conjuntos de datos públicos y validado con un conjunto independiente de hojas cultivadas en Baja California.

1.4.2. Objetivos específicos

- OE1.** Integrar un conjunto de datos de entrenamiento a partir de conjuntos públicos de imágenes de hojas de vid, homologando los sinónimos varietales y eliminando imágenes duplicadas entre fuentes.
- OE2.** Entrenar y comparar al menos cuatro arquitecturas de redes neuronales convolucionales mediante transferencia de aprendizaje, priorizando arquitecturas ligeras, y seleccionar la de mejor equilibrio entre desempeño y costo computacional.
- OE3.** Optimizar el modelo seleccionado para su ejecución en dispositivos con recursos limitados mediante cuantización a enteros de 8 bits, cuantificando la pérdida de desempeño asociada.
- OE4.** Seleccionar la plataforma embebida de implementación mediante una comparación de alternativas con criterios ponderados de latencia, consumo energético, memoria disponible y costo.
- OE5.** Implementar el sistema completo de captura, preprocesamiento, inferencia y presentación de resultados en la plataforma seleccionada, incluyendo un mecanismo de rechazo para variedades no reconocidas.
- OE6.** Evaluar la capacidad de generalización del sistema con el conjunto local de hojas de Misión, Syrah y Tempranillo de la UABC, sin emplearlo en ninguna etapa de entrenamiento o ajuste.
- OE7.** Caracterizar el desempeño del sistema sobre la plataforma embebida en términos de latencia de inferencia, consumo energético y uso de memoria.

1.5. Hipótesis

Hipótesis de investigación (H1). Un modelo de red neuronal convolucional ligera, entrenado exclusivamente con conjuntos de datos públicos y cuantizado a enteros de 8 bits, puede implementarse en una plataforma embebida de bajo costo e identificar variedades de vid a partir de imágenes de hojas con un desempeño adecuado para su uso como herramienta de verificación en campo, aun cuando

se evalúa con hojas cultivadas en Baja California que no formaron parte del entrenamiento.

Para que la hipótesis pueda aceptarse o rechazarse de forma objetiva, se descompone en cuatro hipótesis específicas con umbrales verificables, resumidas en la Tabla 1.8. Los umbrales se fijaron a partir de la evidencia del estado del arte: los modelos ligeros reportan entre 94.75 % y 96.53 % de exactitud en validación interna [Magalhães et al., 2023b, Deng et al., 2025], por lo que un umbral de 90 % resulta conservador considerando un conjunto de entrenamiento más reducido; en cambio, los estudios que evaluaron datos externos documentan caídas drásticas [De Nart et al., 2024] y un F1-score de 0.796 incluso con preentrenamiento a gran escala [Carneiro et al., 2024], por lo que el umbral externo se estableció en 70 %.

Tabla 1.8: Hipótesis específicas y criterios de aceptación.

Código	Hipótesis específica	Criterio de aceptación
H1a	El modelo alcanza un desempeño alto dentro del dominio de los conjuntos públicos.	Exactitud top-1 ≥ 90 % y F1-score macro ≥ 0.88 en la partición de prueba interna.
H1b	El modelo generaliza a hojas locales de las variedades que conoce.	Exactitud top-1 ≥ 70 % sobre las imágenes locales de Syrah y Tempranillo.
H1c	El mecanismo de rechazo evita asignar etiquetas falsas a una variedad no incluida en el entrenamiento.	Tasa de rechazo ≥ 70 % sobre las imágenes locales de Misión.
H1d	El modelo optimizado es viable en la plataforma embebida sin pérdida significativa de desempeño.	Latencia de inferencia ≤ 500 ms por imagen y pérdida por cuantización ≤ 2 puntos porcentuales de exactitud.

Hipótesis nula (H0). Al menos uno de los criterios de la Tabla 1.8 no se cumple; es decir, el modelo no alcanza el desempeño interno requerido, no generaliza a las hojas locales, no es capaz de rechazar una variedad desconocida o no es viable sobre la plataforma embebida seleccionada. Cada hipótesis específica se evaluará y reportará de manera independiente, de modo que el rechazo de una de ellas documente con precisión en qué dimensión falla el enfoque.

Las variables del estudio son las siguientes. Las **variables independientes** son la arquitectura de la red, el esquema de optimización (precisión completa frente a cuantización int8) y la plataforma de ejecución. Las **variables dependientes** son la exactitud top-1, el F1-score macro, la tasa de rechazo, la latencia de inferencia, el consumo energético y el uso de memoria. Como **variables controladas** se mantienen fijas la resolución de entrada, las particiones de datos y las semillas aleatorias de entrenamiento.

1.6. Metodología

La metodología se organiza en siete etapas secuenciales, cada una con actividades, entregables y un criterio de salida que debe cumplirse antes de avanzar a la siguiente. La Figura 1.6 presenta el flujo general y la Tabla 1.9 resume la correspondencia entre etapas, objetivos específicos e hipótesis.




Figura 1.6: Flujo general de la metodología. El conjunto local de la UABC ingresa únicamente en la etapa de validación.

Tabla 1.9: Correspondencia entre etapas, objetivos específicos, entregables e hipótesis.

Etapa	Objetivo específico	Entregable	Hipótesis
1. Integración y curaduría de datos	OE1	Conjunto integrado con particiones fijas	–
2. Entrenamiento y selección	OE2	Modelo seleccionado y tabla comparativa	H1a
3. Optimización	OE3	Modelo cuantizado int8	H1d
4. Selección de plataforma	OE4	Matriz de decisión	H1d
5. Implementación embebida	OE5	Prototipo funcional	–
6. Validación y caracterización	OE6, OE7	Métricas internas, externas y de hardware	H1a–H1d

Etap	Objetivo específico	Entregable	Hipótesis
7. Análisis de resultados	–	Contraste de hipótesis	H1, H0

1.6.1. Etapa 1: Integración y curaduría de datos públicos

El conjunto de entrenamiento se construirá a partir de conjuntos públicos con licencia abierta. La base principal será GLVD [Shah et al., 2026], que compila 1 469 imágenes de 16 cultivos con particiones predefinidas e integra los recursos de Koklu et al. [2022b] y Vlah [2021]; se complementará con el UTAD Grapevine Varieties Dataset 2023 [Carneiro, 2024], que aporta imágenes adquiridas con nueve dispositivos distintos y mayor variabilidad de condiciones. El conjunto INCAFO [Magalhães et al., 2023a], con 37 variedades, se solicitará a sus autores dado que su acceso es restringido; su incorporación se considerará opcional.

La Tabla 1.10 muestra la cobertura de las tres variedades locales en los conjuntos públicos identificados. Syrah y Tempranillo están disponibles en al menos un conjunto abierto; Misión no aparece en ninguno. Esta condición define el diseño experimental de la validación: Syrah y Tempranillo funcionarán como clases conocidas para medir la generalización (H1b), mientras que Misión funcionará como variedad desconocida para medir la capacidad de rechazo del sistema (H1c).

Tabla 1.10: Cobertura de las variedades locales en los conjuntos públicos.

Variedad local	Sinónimos	GLVD / Kaggle	UTAD 2023	INCAFO
Syrah	Shiraz	Sí	No	Sí
Tempranillo	Tinta Roriz, Aragonez	Sí	Sí (Tinta Roriz)	Sí (Aragonez)
Misión	Listán Prieto, País, Criolla Chica	No	No	No
Licencia		CC BY 4.0	CC BY 4.0	Restringida

Las actividades de esta etapa son: (a) homologar las etiquetas de las distintas fuentes, unificando sinónimos varietales bajo un solo nombre; (b) eliminar imágenes duplicadas o casi duplicadas mediante comparación por *hash* perceptual, paso indispensable porque GLVD integra imágenes de otros conjuntos públicos y un duplicado presente en entrenamiento y en prueba inflaría artificialmente las métricas; (c) excluir las clases con un número insuficiente de imágenes; y (d) generar particiones estratificadas de entrenamiento, validación y prueba, que quedarán fijas para todo el proyecto. El criterio de salida es disponer del conjunto integrado, con sus particiones congeladas y un reporte del número de imágenes por clase.

1.6.2. Etapa 2: Entrenamiento y selección de arquitectura

Se entrenarán al menos cuatro arquitecturas mediante transferencia de aprendizaje a partir de pesos preentrenados en ImageNet: MobileNetV2, MobileNetV3-Small y EfficientNet-B0 como candidatas ligeras, y ResNet-50 como referencia de mayor capacidad. El entrenamiento se realizará en dos fases: primero con la base convolucional congelada para ajustar el clasificador, y después con descongelamiento parcial de las capas superiores y una tasa de aprendizaje reducida.

Las imágenes se redimensionarán a 224×224 píxeles y se normalizarán según los parámetros de ImageNet. El aumento de datos —rotaciones, reflejos, variaciones de brillo, contraste y tono, y recortes aleatorios— se aplicará exclusivamente sobre la partición de entrenamiento y después de generar las particiones. Esta precaución responde directamente a la evidencia del estado del arte, donde dos estudios sobre el mismo conjunto reportan desempeños separados por casi 25 puntos porcentuales [Kunduracioglu and Pacal, 2024, Huang, 2025].

Cada arquitectura se entrenará con tres semillas aleatorias distintas y se reportará la media y la desviación estándar de la exactitud top-1 y del F1-score macro sobre la partición de prueba interna, junto con la matriz de confusión. La arquitectura se seleccionará con un criterio de equilibrio: entre los modelos que cumplan el umbral de H1a, se elegirá el de menor número de parámetros y operaciones de punto flotante.

1.6.3. Etapa 3: Optimización para recursos limitados

El modelo seleccionado se convertirá a un formato de inferencia embebida (TensorFlow Lite u ONNX, según la plataforma) y se aplicará cuantización posterior al entrenamiento a enteros de 8 bits, utilizando un subconjunto representativo de la partición de entrenamiento para la calibración. Se medirá el tamaño del modelo y la exactitud antes y después de la cuantización sobre la misma partición de prueba. Si la pérdida supera el umbral de H1d, se aplicará entrenamiento consciente de la cuantización como alternativa.

En esta etapa se fijará también el umbral del mecanismo de rechazo. Se utilizará la probabilidad máxima de la salida *softmax* como medida de confianza, y el umbral se calibrará sobre la partición de validación de los conjuntos públicos, de manera que acepte al menos el 95 % de las predicciones correctas. El umbral quedará fijo antes de cualquier contacto con el conjunto local, para que la evaluación de H1c no esté sesgada.

1.6.4. Etapa 4: Selección de la plataforma embebida

La plataforma de implementación se seleccionará mediante una matriz de decisión ponderada entre tres alternativas representativas de distintos niveles de capacidad y costo: una computadora de placa única basada en CPU (Raspberry Pi 5), un módulo con aceleración por GPU (NVIDIA Jetson Orin Nano) y un microcontrolador con cámara integrada (ESP32-S3). Los criterios de evaluación serán la latencia de inferencia del modelo cuantizado, el consumo energético, la memoria disponible frente a la requerida por el modelo, el costo de adquisición y la madurez del soporte de software y de cámara. Como filtro previo se descartará cualquier plataforma en

la que el modelo no quepa en memoria o no alcance el umbral de latencia de H1d. El entregable de la etapa es la matriz de decisión con la justificación de la plataforma elegida.

1.6.5. Etapa 5: Implementación del sistema embebido

Sobre la plataforma seleccionada se implementará el flujo completo del sistema: captura de la imagen de la hoja mediante la cámara, preprocesamiento con los mismos parámetros empleados en el entrenamiento, inferencia con el modelo cuantizado, aplicación del umbral de rechazo y presentación del resultado al usuario, incluyendo la variedad identificada —o la indicación de “variedad no reconocida”— y el nivel de confianza asociado. El criterio de salida es un prototipo que ejecute el flujo completo de forma autónoma, sin depender de una computadora externa ni de conexión a internet.

1.6.6. Etapa 6: Validación y caracterización

La validación se realizará en tres niveles. El **nivel interno** evaluará el modelo sobre la partición de prueba de los conjuntos públicos para contrastar H1a. El **nivel externo** evaluará el sistema sobre el conjunto local de la UABC: las imágenes de Syrah y Tempranillo se usarán para medir la exactitud top-1 (H1b) y las de Misión para medir la tasa de rechazo (H1c). El conjunto local no se utilizará en ninguna etapa de entrenamiento, selección de arquitectura, calibración del umbral ni ajuste de hiperparámetros. Dado que el conjunto local es de tamaño reducido, las métricas externas se reportarán acompañadas de intervalos de confianza al 95 % calculados con el método de Wilson, para que la aceptación o rechazo de la hipótesis considere la incertidumbre asociada al tamaño de muestra.

El **nivel de hardware** caracterizará el sistema sobre la plataforma embebida: latencia de inferencia (media y percentil 95 sobre al menos 100 ejecuciones, excluyendo las ejecuciones iniciales de calentamiento), consumo energético durante la inferencia medido con un medidor de potencia en la alimentación, y uso máximo de memoria. Estas mediciones permitirán contrastar H1d.

1.6.7. Etapa 7: Análisis de resultados y contraste de hipótesis

Cada hipótesis específica se contrastará contra su criterio de aceptación y se reportará de manera independiente. Se analizarán además las matrices de confusión internas y externas para identificar qué variedades se confunden con mayor frecuencia, y se compararán los resultados con los reportados en el estado del arte, con especial atención a la magnitud de la caída entre la evaluación interna y la externa. En caso de que alguna hipótesis se rechace, el análisis documentará la causa probable —insuficiencia de datos, cambio de dominio o limitación del hardware— como base para trabajos futuros.

1.6.8. Alcance y limitaciones

El sistema se limita a la identificación de variedades a partir de hojas maduras fotografiadas individualmente; no contempla racimos, sarmientos ni la detección de enfermedades. El número de variedades que el sistema podrá reconocer está determinado por la cobertura de los conjuntos públicos, por lo que Misión no podrá identificarse positivamente sino únicamente rechazarse como variedad desconocida. Los resultados de la validación externa corresponden a las condiciones de captura del conjunto local de la UABC y no deben extrapolarse sin evaluación adicional a otros viñedos, temporadas o dispositivos de captura. Finalmente, el sistema se plantea como una herramienta de verificación de primer nivel y no sustituye al análisis molecular en los casos que requieran certeza legal o comercial.

2

Marco teórico

Este capítulo reúne los fundamentos necesarios para comprender y sustentar el sistema propuesto. Se parte de la base botánica del problema —qué es una variedad de vid y qué rasgos de la hoja permiten distinguirla— y se avanza hacia las herramientas computacionales que hacen posible automatizar esa distinción: el procesamiento digital de imágenes, las redes neuronales artificiales y, en particular, las redes convolucionales y sus variantes ligeras. Posteriormente se establecen los criterios con los que se mide el desempeño de un clasificador, incluyendo el problema de la generalización fuera del dominio de entrenamiento, y finalmente se describen las plataformas y técnicas que permiten ejecutar estos modelos en dispositivos con recursos limitados.

2.1. Viticultura y ampelografía

2.1.1. La vid y el concepto de variedad

La vid europea, *Vitis vinifera* L., es la especie del género *Vitis* de mayor importancia económica y la base de prácticamente toda la producción mundial de vino. Dentro de la especie se reconocen miles de **variedades** o **cultivares**: poblaciones de plantas genéticamente distintas que se propagan de forma vegetativa —mediante estacas o injertos— y no por semilla. Esta propagación clonal es la razón por la que todos los individuos de una variedad comparten esencialmente el mismo genotipo, y por la que las diferencias morfológicas entre variedades se mantienen estables a lo largo del tiempo.

Es importante distinguir tres niveles. La **variedad** es la unidad de identificación: Syrah, Tempranillo o Misión. El **clon** es una selección dentro de una variedad, originada por mutaciones somáticas acumuladas, que conserva la identidad varietal pero puede diferir en aspectos agronómicos. El **sinónimo** es un nombre distinto para la misma variedad, generalmente de origen regional. La sinonimia es particularmente relevante para este proyecto: Tempranillo se denomina Tinta Roriz o Aragonez en Portugal, Syrah se conoce como Shiraz en Australia, y la variedad Misión, introducida en América por las misiones españolas, corresponde genéticamente a la variedad española Listán Prieto, conocida como País en Chile y Criolla Chica en Argentina [Tapia et al., 2007]. Un sistema de clasificación que integre conjuntos de datos de distintos países debe homologar estos nombres antes del entrenamiento, pues de lo contrario la misma variedad aparecería como dos clases distintas.

2.1.2. Ampelografía y descriptores morfológicos

La **ampelografía** es la disciplina que identifica y describe las variedades de vid a partir de sus caracteres morfológicos. Tradicionalmente se apoya en la observación de cuatro órganos: el pámpano joven, la hoja adulta, el racimo y la baya. De estos, la hoja adulta es el más utilizado, por tres razones: está disponible durante buena parte del ciclo vegetativo, es plana y por tanto fácil de fotografiar sin deformación, y concentra un número elevado de caracteres discriminantes.

Para que las descripciones sean comparables entre instituciones y países, la Organización Internacional de la Viña y el Vino publica una lista normalizada de descriptores [Organisation Internationale de la Vigne et du Vin, 2009, 2023]. Cada descriptor recibe un código numérico y una escala de valores. Los descriptores se dividen en dos familias. Los **descriptores cualitativos u ordinales** —por ejemplo, la forma del limbo, el número de lóbulos, el grado de apertura del seno peciolar o la densidad de pelos en el envés— se evalúan por comparación visual contra ilustraciones de referencia y se expresan en escalas discretas, típicamente de 1 a 9. Los **descriptores ampelométricos**, agrupados en la serie 600 de la lista, son mediciones cuantitativas realizadas sobre la hoja; la Tabla 2.1 resume los principales.

Tabla 2.1: Descriptores ampelométricos de la hoja adulta según la lista de la OIV [Organisation Internationale de la Vigne et du Vin, 2023].

Código	Descriptor
OIV 601–604	Longitud de las nervaduras N1 a N4
OIV 605	Longitud del seno peciolar al seno lateral superior
OIV 606	Longitud del seno peciolar al seno lateral inferior
OIV 607–609	Ángulos entre nervaduras consecutivas (N1–N2, N2–N3, N3–N4), medidos en la primera ramificación
OIV 610	Ángulo entre N3 y la tangente entre el punto peciolar y la punta del diente de N5
OIV 611	Longitud de la nervadura N5
OIV 612–615	Longitud y anchura de los dientes de N2 y N4
OIV 616	Número de dientes entre la punta del diente de N2 y la de la primera nervadura secundaria de N2
OIV 617	Longitud entre esas dos puntas de diente
OIV 618	Apertura o superposición del seno peciolar

La Figura 2.1 muestra la anatomía de una hoja adulta de vid con los elementos que sirven de base a estos descriptores. La hoja es palmada y típicamente pentalobulada: presenta un lóbulo central terminado en la nervadura principal N1, dos lóbulos laterales superiores asociados a las nervaduras N2 y dos lóbulos laterales inferiores asociados a las nervaduras N3. Entre los lóbulos se abren los **senos laterales**, y en la base, donde se inserta el pecíolo, se encuentra el **seno peciolar**, cuya forma y grado de apertura constituyen uno de los caracteres más discriminantes entre variedades.




Figura 2.1: Esquema de la hoja adulta de vid y elementos morfológicos que sustentan los descriptores ampelográficos. El borde dentado se omite por claridad.

La ampelografía presenta tres limitaciones que motivan su automatización. Primero, requiere un especialista con formación específica, un recurso escaso. Segundo, los caracteres deben observarse en momentos concretos del ciclo vegetativo, cuando la hoja ha alcanzado su desarrollo completo. Tercero, la expresión morfológica está influida por el ambiente, el estado sanitario de la planta y la variabilidad clonal, de modo que dos hojas de la misma variedad cultivadas en sitios distintos pueden diferir de forma apreciable. Esta última limitación es especialmente relevante para el presente proyecto, porque es el fundamento botánico del fenómeno que en aprendizaje automático se denomina cambio de dominio y que se aborda en la sección 2.5.5.

2.1.3. Identificación molecular

El análisis del ADN mediante marcadores microsatélite —repeticiones simples de secuencia o SSR— permite identificar una variedad comparando su perfil genético contra bases de datos de referencia, con independencia del estado fenológico de la planta. La OIV incluye estos marcadores en su lista de descriptores dentro de la serie 800 [Organisation Internationale de la Vigne et du Vin, 2023], y fue esta técnica la que permitió establecer la correspondencia entre la variedad Misión y la española Listán Prieto [Tapia et al., 2007]. Su principal limitación práctica es operativa: exige enviar muestras a un laboratorio especializado, con el costo y el tiempo de espera asociados, lo que impide usarla como herramienta de consulta rutinaria en campo. El sistema propuesto en este trabajo no pretende sustituir esta técnica, sino ofrecer una verificación preliminar que permita reservarla para los casos que realmente la requieran.

2.1.4. Las variedades de interés del proyecto

Las tres variedades que integran el conjunto local de validación externa tienen orígenes y trayectorias distintas, lo que condiciona su disponibilidad en los conjuntos

de datos públicos.

Syrah es originaria del norte del valle del Ródano, en el sureste de Francia. Los análisis de marcadores microsatélite establecieron que procede del cruce entre Dureza, de Ardèche, y Mondeuse Blanca, de Saboya [Vouillamoz and Grando, 2006], lo que descartó las hipótesis previas que le atribuían un origen persa o siciliano derivadas de la semejanza fonética de su nombre. Se conoce como Shiraz en Australia y Sudáfrica, sinónimo bajo el cual también aparece en algunos conjuntos de datos.

Tempranillo es la variedad tinta de mayor superficie cultivada en España. Su origen genético se determinó mediante marcadores SNP y microsatélites, que identificaron a Albillo Mayor y Benedicto como sus progenitores [Ibáñez et al., 2012]. Su sinonimia es particularmente extensa: en Portugal se denomina Tinta Roriz en la región del Duero y Aragonez en el Alentejo, y bajo esos nombres aparece en los conjuntos de datos de origen portugués. Una integración que no homologue estos tres nombres trataría a la misma variedad como tres clases distintas, con el consiguiente deterioro del clasificador.

Misión es la variedad de mayor relevancia histórica en la península de Baja California, pues fue la introducida por las misiones españolas y constituye la base de la viticultura más antigua de América. El análisis de ADN estableció su correspondencia genética con la variedad española Listán Prieto, originaria de Castilla-La Mancha y difundida hacia América a través de las Islas Canarias [Tapia et al., 2007]. Recibe el nombre de País en Chile y Criolla Chica en Argentina. A diferencia de las dos anteriores, Misión no figura en ninguno de los conjuntos públicos de imágenes de hoja identificados en la revisión del capítulo anterior, lo que la convierte en el caso de prueba idóneo para evaluar el comportamiento del sistema ante una variedad desconocida.

La Tabla 2.2 resume esta información.

Tabla 2.2: Variedades que integran el conjunto local de validación externa.

Variedad	Origen	Progenitores o correspondencia	Sinónimos principales
Syrah	Norte del valle del Ródano, Francia	Dureza × Mondeuse Blanca [Vouillamoz and Grando, 2006]	Shiraz
Tempranillo	España	Albillo Mayor × Benedicto [Ibáñez et al., 2012]	Tinta Roriz, Aragonez
Misión	Castilla-La Mancha, vía Islas Canarias	Corresponde genéticamente a Listán Prieto [Tapia et al., 2007]	Listán Prieto, País, Criolla Chica

Para la consulta sistemática de sinonimias y pedigríes existe el *Vitis International Variety Catalogue* [Institut für Rebenzüchtung Geilweilerhof, 2026], base de datos de referencia que registra los nombres aceptados, los sinónimos documentados y

las relaciones de parentesco de las variedades de vid, y que constituye la fuente recomendada para la homologación de etiquetas entre conjuntos de datos de distinta procedencia.

2.2. Procesamiento digital de imágenes

2.2.1. Representación digital de una imagen

Una imagen digital en color puede modelarse como una función discreta $I(x, y, c)$ que asigna un valor de intensidad a cada posición espacial (x, y) y a cada canal de color c [Gonzalez and Woods, 2018]. En el modelo RGB, el más común en cámaras y sensores, la imagen se compone de tres canales —rojo, verde y azul— y se representa como un tensor de dimensiones $H \times W \times 3$, donde H y W son el alto y el ancho en píxeles. Con una profundidad de 8 bits por canal, cada elemento toma valores enteros en el intervalo $[0, 255]$.

Además del RGB existen otros espacios de color útiles en tareas agrícolas. El espacio HSV descompone la información en matiz, saturación y valor, y separa así el contenido cromático de la intensidad luminosa, lo que lo hace más robusto frente a variaciones de iluminación; esta propiedad resulta conveniente cuando se requiere segmentar la hoja del fondo en condiciones de campo.

2.2.2. Preprocesamiento

Antes de alimentar una imagen a una red neuronal es necesario llevarla a un formato uniforme. El **redimensionamiento** ajusta todas las imágenes a la resolución de entrada que espera la arquitectura, comúnmente 224×224 píxeles. La **normalización** transforma el rango de intensidades para estabilizar el entrenamiento; la forma más habitual estandariza cada canal restando su media y dividiendo entre su desviación estándar:

$$\hat{I}_c(x, y) = \frac{I_c(x, y) - \mu_c}{\sigma_c}, \quad (2.1)$$

donde μ_c y σ_c son la media y la desviación estándar del canal c , calculadas sobre el conjunto de entrenamiento o heredadas del conjunto con el que se preentrenó el modelo. Un aspecto crítico es que los mismos valores de μ_c y σ_c deben aplicarse durante la inferencia; una discrepancia entre el preprocesamiento de entrenamiento y el de despliegue degrada el desempeño sin producir ningún error visible.

2.2.3. Interpolación, contraste y constancia de color

El redimensionamiento no es una operación neutra: al reducir la resolución es necesario interpolar, y el método elegido afecta al detalle que se conserva. La interpolación por vecino más cercano es la más rápida pero produce bordes escalonados; la bilineal promedia los cuatro píxeles vecinos; y la bicúbica, que considera dieciséis vecinos, preserva mejor los bordes finos [Gonzalez and Woods, 2018]. En una hoja de vid, el borde dentado y las nervaduras de menor calibre

son precisamente las estructuras que una interpolación pobre elimina, por lo que conviene capturar a una resolución holgadamente superior a la de entrada del modelo y reducir en un solo paso.

El **ajuste de contraste** redistribuye los valores de intensidad para aprovechar todo el rango disponible. La ecualización de histograma es la técnica clásica; su variante adaptativa con limitación de contraste opera por regiones y evita la amplificación excesiva del ruido en zonas homogéneas. Estas operaciones pueden mejorar la visibilidad de las nervaduras en imágenes subexpuestas, aunque alteran la información cromática y deben aplicarse de forma consistente entre entrenamiento e inferencia.

La **constancia de color** busca que un mismo objeto produzca los mismos valores cromáticos bajo iluminaciones distintas. Los algoritmos de balance de blancos estiman el color de la fuente de luz y compensan sus efectos. Su importancia en este problema es directa: el color del limbo y la presencia de pigmentación antociánica en las nervaduras son caracteres descriptivos, y una dominante de color introducida por la iluminación o por el procesamiento automático de la cámara puede alterarlos lo suficiente para confundir al clasificador.

Finalmente, conviene considerar los **artefactos de compresión**. El formato JPEG, habitual en cámaras y conjuntos públicos, descarta información de alta frecuencia y puede introducir distorsiones en los bordes finos. Cuando el conjunto de entrenamiento y las imágenes de producción provienen de cadenas de compresión distintas, esa diferencia constituye otra fuente de cambio de dominio.

2.2.4. Segmentación

La **segmentación** separa el objeto de interés del fondo. En imágenes de hojas adquiridas sobre fondo blanco controlado, basta con técnicas clásicas como la umbralización sobre un canal de color. En imágenes de campo, donde el fondo contiene suelo, hierba, troncos y otras hojas, se requieren métodos de aprendizaje profundo: el trabajo de Adão et al. [2025] emplea Mask R-CNN para extraer la hoja antes de clasificarla. Una alternativa es prescindir de la segmentación explícita y entrenar el clasificador directamente sobre imágenes con fondo complejo, incorporando mecanismos de atención que aprendan a suprimir el fondo, como hace Deng et al. [2025].

2.2.5. Descriptores clásicos de forma

Antes de la adopción generalizada del aprendizaje profundo, la clasificación automática de hojas se abordaba extrayendo descriptores numéricos diseñados manualmente y alimentando con ellos un clasificador convencional. Conocer estos descriptores es pertinente por dos motivos: constituyen el puente entre la ampelometría de la sección 2.1.4 y el aprendizaje automático, y siguen siendo la base de varios de los estudios revisados en el capítulo anterior.

Los **descriptores geométricos básicos** se calculan directamente sobre la silueta segmentada de la hoja: área, perímetro, longitud de los ejes principales, y razones adimensionales derivadas de ellos. Entre estas últimas destaca la **circularidad**

$$C = \frac{4\pi A}{P^2}, \quad (2.2)$$

donde A es el área y P el perímetro. Su valor es 1 para un círculo perfecto y disminuye conforme el contorno se vuelve más irregular, por lo que resume en un solo número el grado de lobulación y de dentado del borde.

Los **momentos invariantes** describen la distribución espacial de la masa de la figura. A partir de los momentos centrales normalizados se construyen combinaciones que permanecen constantes ante traslación, escala y rotación, propiedad esencial cuando las hojas se fotografían con orientaciones y distancias variables.

Los **descriptores elípticos de Fourier** representan el contorno cerrado como una serie de armónicos, de modo que los primeros coeficientes capturan la forma global y los superiores el detalle fino del borde. Truncar la serie en un número reducido de armónicos produce una representación compacta y ordenada por escala, sobre la que puede aplicarse un análisis de componentes principales. Chitwood et al. [2014] emplean esta técnica, combinada con superposición de Procrustes, para cuantificar la variación de forma y venación entre más de mil accesiones de vid.

La **dimensión fractal** caracteriza la complejidad del contorno. El método de conteo de cajas recubre la imagen con una malla de celdas de lado ε , cuenta cuántas celdas $N(\varepsilon)$ contienen parte del contorno y estima

$$D = \lim_{\varepsilon \rightarrow 0} \frac{\log N(\varepsilon)}{\log(1/\varepsilon)}, \quad (2.3)$$

valor que en la práctica se obtiene como la pendiente de la regresión lineal de $\log N(\varepsilon)$ frente a $\log(1/\varepsilon)$. Mancuso [2001] aplicó esta medida a hojas de vid y reportó un error experimental menor que el de los descriptores ampelográficos tradicionales, y Fuentes et al. [2018] la combinó con parámetros morfo-colorimétricos y espectroscópicos para alimentar una red neuronal artificial.

La limitación común de todos estos descriptores es que exigen una segmentación precisa del contorno y que capturan únicamente aquello que el diseñador decidió medir. Las redes convolucionales invierten esa lógica: aprenden de los datos qué medir, a costa de requerir muchos más ejemplos y de perder la interpretabilidad directa de cada valor.

2.2.6. Aumento de datos

El **aumento de datos** genera ejemplos sintéticos aplicando transformaciones que preservan la etiqueta de la imagen: rotaciones, reflejos, recortes aleatorios, variaciones de brillo, contraste, saturación y tono, y adición de ruido [Shorten and Khoshgoftaar, 2019]. Su propósito es doble: ampliar artificialmente el tamaño del conjunto de entrenamiento y enseñar al modelo a ser invariante frente a esas transformaciones, lo que reduce el sobreajuste.

El aumento de datos debe aplicarse **únicamente sobre la partición de entrenamiento y después de haber definido las particiones**. Si se aumenta el conjunto completo y se parte después, versiones transformadas de la misma imagen original pueden quedar repartidas entre entrenamiento y prueba; el modelo entonces

evalúa imágenes que en esencia ya vio, y las métricas resultantes sobrestiman su desempeño real. Este fenómeno, conocido como **fuga de datos**, es una explicación plausible de las discrepancias observadas en el estado del arte entre estudios que emplean el mismo conjunto de imágenes.

2.3. Redes neuronales artificiales

2.3.1. Aprendizaje supervisado y clasificación

El **aprendizaje supervisado** consiste en inferir una función $f_\theta : \mathcal{X} \rightarrow \mathcal{Y}$ a partir de un conjunto de pares etiquetados $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$, ajustando los parámetros θ para minimizar el error entre la salida del modelo y la etiqueta real [Goodfellow et al., 2016]. Cuando $\mathcal{Y}$ es un conjunto discreto y finito, el problema es de **clasificación**. La identificación varietal de vid se formula como una clasificación multiclase: la entrada $\mathbf{x}$ es la imagen de una hoja y la salida y es una de las K variedades consideradas.

2.3.2. La neurona artificial y el perceptrón multicapa

La unidad básica de una red neuronal calcula una combinación lineal de sus entradas seguida de una transformación no lineal:

$$a = f\left(\sum_{j=1}^n w_j x_j + b\right) = f(\mathbf{w}^\top \mathbf{x} + b), \quad (2.4)$$

donde $\mathbf{x}$ es el vector de entradas, $\mathbf{w}$ el vector de pesos, b el sesgo y f la **función de activación**. Sin la no linealidad de f , la composición de varias capas seguiría siendo una transformación lineal y la red no podría representar fronteras de decisión complejas.

El **perceptrón multicapa** organiza estas unidades en capas sucesivas, de modo que la salida de una capa es la entrada de la siguiente. Para la capa l , la propagación hacia adelante se expresa de forma matricial como

$$\mathbf{a}^{(l)} = f^{(l)}(\mathbf{W}^{(l)} \mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}), \quad (2.5)$$

con $\mathbf{a}^{(0)} = \mathbf{x}$.

2.3.3. Funciones de activación

La activación más utilizada en redes profundas modernas es la unidad lineal rectificadora o **ReLU** [Nair and Hinton, 2010]:

$$\text{ReLU}(z) = \max(0, z). \quad (2.6)$$

Su ventaja principal es que su derivada es constante e igual a 1 para $z > 0$, lo que evita la atenuación del gradiente que sufren funciones saturantes como la sigmoide y permite entrenar redes de muchas capas. Entre sus variantes destacan Leaky ReLU,

que asigna una pendiente pequeña para $z < 0$, y las funciones suaves empleadas en arquitecturas móviles recientes, como *h-swish* en MobileNetV3 [Howard et al., 2019]. En la capa de salida de un clasificador multiclase se emplea la función **softmax**, que convierte el vector de puntuaciones o *logits* $\mathbf{z} \in \mathbb{R}^K$ en una distribución de probabilidad sobre las K clases:

$$p_k = \text{softmax}(\mathbf{z})_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad p_k \in (0, 1), \quad \sum_{k=1}^K p_k = 1. \quad (2.7)$$

El valor $\max_k p_k$ se interpreta como la confianza del modelo en su predicción y es la cantidad sobre la que se construye el mecanismo de rechazo descrito en la sección 2.5.5.

2.3.4. Función de pérdida y optimización

Para un problema de clasificación multiclase la función de pérdida estándar es la **entropía cruzada categórica**, que para un ejemplo con etiqueta verdadera codificada en *one-hot* y se define como

$$\mathcal{L}(\mathbf{y}, \mathbf{p}) = - \sum_{k=1}^K y_k \log p_k = - \log p_c, \quad (2.8)$$

donde c es el índice de la clase correcta. La pérdida crece sin límite conforme la probabilidad asignada a la clase correcta se acerca a cero, lo que penaliza fuertemente los errores cometidos con alta confianza.

El ajuste de los parámetros se realiza mediante **descenso de gradiente estocástico**, actualizando iterativamente

$$\theta \leftarrow \theta - \eta \nabla_{\theta} \mathcal{L}, \quad (2.9)$$

donde η es la **tasa de aprendizaje**. Los gradientes $\nabla_{\theta} \mathcal{L}$ se calculan mediante **retropropagación**, que aplica la regla de la cadena desde la salida hacia las capas anteriores [Rumelhart et al., 1986]. En la práctica se emplean optimizadores adaptativos como **Adam** [Kingma and Ba, 2015], que ajustan la tasa de aprendizaje de cada parámetro a partir de estimaciones del primer y segundo momento del gradiente y convergen más rápido que el descenso de gradiente simple.

Un pase completo sobre el conjunto de entrenamiento se denomina **época**, y los ejemplos se procesan en **lotes** de tamaño fijo, lo que reduce el consumo de memoria y aporta ruido estocástico que ayuda a escapar de mínimos locales pobres.

2.3.5. Aspectos prácticos del entrenamiento

Varios elementos ajenos a la arquitectura determinan si el entrenamiento converge y a qué solución lo hace.

La **inicialización de los pesos** debe preservar la escala de las activaciones y de los gradientes a lo largo de la red. Las estrategias estándar ajustan la varianza inicial en función del número de conexiones de entrada y de salida de cada capa: la inicialización de Glorot [Glorot and Bengio, 2010] para activaciones simétricas y la

de He [He et al., 2015] para redes basadas en ReLU. En transferencia de aprendizaje este problema desaparece parcialmente, porque la base convolucional parte de pesos ya entrenados y solo el clasificador nuevo requiere inicialización.

La **tasa de aprendizaje** es el hiperparámetro más influyente. Un valor excesivo provoca oscilaciones o divergencia; uno demasiado pequeño hace el entrenamiento lento y propenso a estancarse. Es práctica habitual emplear una **programación** que la reduce conforme avanza el entrenamiento, ya sea por escalones, de forma exponencial o siguiendo un descenso cosenoidal con reinicios [Loshchilov and Hutter, 2017]. En el ajuste fino se utiliza además una tasa diferenciada: muy baja para las capas preentrenadas que se descongelan y mayor para el clasificador nuevo.

El **tamaño de lote** determina cuántos ejemplos contribuyen a cada estimación del gradiente. Lotes grandes producen estimaciones más estables y aprovechan mejor el hardware, pero requieren más memoria y el ruido estocástico que aportan los lotes pequeños suele mejorar la generalización. En presencia de normalización por lotes, un tamaño demasiado reducido degrada las estadísticas de normalización.

El **desbalance de clases** es frecuente en conjuntos de hojas compilados a partir de fuentes heterogéneas, donde algunas variedades están representadas por muchas más imágenes que otras. Sin corrección, el modelo tiende a favorecer las clases mayoritarias. Las estrategias habituales son el remuestreo de las particiones, la ponderación de la pérdida por clase —asignando a cada clase un peso inversamente proporcional a su frecuencia— y funciones de pérdida que reducen la contribución de los ejemplos ya bien clasificados, como la pérdida focal [Lin et al., 2017]. La elección de métricas insensibles al desbalance, como el F1-score macro, es complementaria y no sustituye a estas correcciones.

2.3.6. Sobreajuste y regularización

Un modelo con capacidad suficiente puede memorizar el conjunto de entrenamiento y perder capacidad de generalización; este fenómeno es el **sobreajuste**, y se manifiesta cuando el error de entrenamiento sigue disminuyendo mientras el error de validación se estanca o aumenta. Las técnicas más utilizadas para mitigarlo son:

- **Dropout** [Srivastava et al., 2014]: durante el entrenamiento desactiva aleatoriamente una fracción p de las unidades de una capa, lo que impide que la red dependa de coadaptaciones específicas entre neuronas y equivale de forma aproximada a promediar un conjunto de subredes.
- **Normalización por lotes** [Ioffe and Szegedy, 2015]: normaliza las activaciones de cada capa usando la media y la varianza del lote, lo que estabiliza y acelera el entrenamiento y aporta un efecto regularizador.
- **Regularización L_2** : añade a la pérdida un término proporcional a $\|\theta\|^2$ que penaliza los pesos de magnitud elevada.
- **Detención temprana**: interrumpe el entrenamiento cuando la métrica de validación deja de mejorar durante un número determinado de épocas.
- **Aumento de datos**, descrito en la sección 2.2.6.

2.4. Redes neuronales convolucionales

2.4.1. La operación de convolución

Aplicar un perceptrón multicapa directamente sobre una imagen es inviable: una entrada de $224 \times 224 \times 3$ tiene más de 150 000 valores, y una sola capa densa de 1 000 unidades requeriría más de 150 millones de parámetros. Además, esa representación ignora la estructura espacial de la imagen: los píxeles vecinos guardan una relación que el modelo tendría que aprender desde cero.

Las **redes neuronales convolucionales** [LeCun et al., 1998] resuelven ambos problemas mediante la operación de convolución, en la que un **filtro** o **núcleo** de tamaño reducido se desplaza sobre la imagen calculando productos punto locales. Para una entrada I y un filtro W de dimensiones $k \times k \times C$, el elemento (i, j) del mapa de características de salida es

$$O(i, j) = \sum_{c=1}^C \sum_{u=1}^k \sum_{v=1}^k I(i+u-1, j+v-1, c) W(u, v, c) + b. \quad (2.10)$$

Esta formulación introduce dos propiedades decisivas. La **conectividad local** hace que cada unidad de salida dependa solo de una región reducida de la entrada, su *campo receptivo*. El **compartimiento de pesos** implica que el mismo filtro se aplica en todas las posiciones, de modo que un patrón aprendido en una zona de la imagen se detecta en cualquier otra, lo que otorga invariancia a la traslación y reduce drásticamente el número de parámetros.

Las dimensiones del mapa de salida dependen del tamaño del filtro, del relleno o *padding* P y del paso o *stride* S :

$$H_{\text{sal}} = \left\lfloor \frac{H_{\text{ent}} - k + 2P}{S} \right\rfloor + 1. \quad (2.11)$$

Una capa convolucional con C_{ent} canales de entrada y C_{sal} filtros tiene

$$n_{\text{par}} = k^2 \cdot C_{\text{ent}} \cdot C_{\text{sal}} + C_{\text{sal}} \quad (2.12)$$

parámetros entrenables, cantidad independiente del tamaño de la imagen de entrada.

2.4.2. Submuestreo y arquitectura general

Entre bloques convolucionales se intercalan capas de **submuestreo** o *pooling*, que reducen la resolución espacial conservando la información más relevante. El *max pooling* toma el valor máximo de cada ventana y el *average pooling* su promedio. Esta reducción disminuye el costo computacional, amplía el campo receptivo efectivo de las capas posteriores y aporta cierta invariancia a pequeñas traslaciones.

La Figura 2.2 resume la estructura general de una red convolucional aplicada al problema de este proyecto. Las primeras capas aprenden detectores de bordes y texturas; las intermedias combinan esos elementos en motivos más complejos —en el caso de una hoja, la curvatura de un seno o el patrón de los dientes del borde—; y las últimas capas producen representaciones asociadas a la identidad de la clase.

Finalmente, una capa de agrupamiento global promedia cada mapa de características para obtener un vector, sobre el que actúa un clasificador denso y la función softmax.




Figura 2.2: Estructura general de una red neuronal convolucional para clasificación de imágenes de hoja. La profundidad de los bloques aumenta mientras la resolución espacial disminuye.

2.4.3. Campo receptivo, convoluciones 1×1 y agrupamiento global

Tres elementos de diseño merecen atención por su papel en las arquitecturas ligeras. El **campo receptivo** de una unidad es la región de la imagen de entrada que influye en su valor. Se amplía al apilar capas: con filtros de $k \times k$ y paso unitario, el campo receptivo crece en $k - 1$ píxeles por capa. Esta acumulación explica por qué apilar filtros pequeños es preferible a usar uno grande: dos capas de 3×3 alcanzan el mismo campo receptivo que una de 5×5 con menos parámetros y con una no linealidad adicional intercalada [Simonyan and Zisserman, 2015]. Para clasificar una hoja, el campo receptivo de las últimas capas debe abarcar una fracción sustancial del limbo, ya que los caracteres discriminantes —la proporción entre nervaduras o la apertura del seno peciolar— son relaciones globales y no detalles locales.

Las **convoluciones 1×1** no capturan estructura espacial, pero combinan linealmente los canales en cada posición. Permiten reducir o aumentar la profundidad del tensor a un costo muy bajo, y por ello son la base de los cuellos de botella de ResNet, de los módulos Inception y de la etapa puntual de la convolución separable descrita en la sección 2.4.5.

El **agrupamiento promedio global** sustituye al aplanado seguido de capas densas que usaban las arquitecturas clásicas. Promedia cada mapa de características completo para producir un único valor por canal, de modo que el vector resultante tiene tantas componentes como canales y no depende de la resolución de entrada. Esto elimina la mayor parte de los parámetros del clasificador —en VGG-16 las capas densas concentran la mayoría de los 138 millones de parámetros del modelo— y reduce el sobreajuste, razón por la cual todas las arquitecturas ligeras lo adoptan. Una medida del costo computacional complementaria al número de parámetros es el conteo de **operaciones de multiplicación y acumulación**. Para una capa convolucional que produce un mapa de $H_{\text{sal}} \times W_{\text{sal}}$ con C_{sal} canales, este costo es

$$\text{MAC} = H_{\text{sal}} \cdot W_{\text{sal}} \cdot C_{\text{sal}} \cdot k^2 \cdot C_{\text{ent}}. \quad (2.13)$$

A diferencia del número de parámetros, esta cantidad sí depende de la resolución de entrada, y es la que predice de forma más directa la latencia de inferencia en una plataforma embebida.

2.4.4. Arquitecturas de referencia

El desarrollo de las redes convolucionales modernas está marcado por un conjunto de arquitecturas que introdujeron ideas todavía vigentes, y que son las que aparecen de forma recurrente en la literatura de identificación varietal revisada en el capítulo anterior.

AlexNet [Krizhevsky et al., 2012] demostró en el concurso ImageNet [Deng et al., 2009] que una red convolucional profunda entrenada sobre GPU superaba ampliamente a los métodos basados en características diseñadas manualmente. **VGG** [Simonyan and Zisserman, 2015] mostró que apilar filtros pequeños de 3×3 en muchas capas es preferible a usar pocos filtros grandes. **GoogLeNet** [Szegedy et al., 2015] introdujo el módulo *Inception*, que procesa la entrada en paralelo con filtros de distintos tamaños y concatena los resultados, capturando información a varias escalas. **ResNet** [He et al., 2016] incorporó las conexiones residuales, que suman la entrada de un bloque a su salida,

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}, \quad (2.14)$$

permitiendo entrenar redes de cientos de capas al ofrecer al gradiente un camino directo hacia las capas iniciales. **DenseNet** [Huang et al., 2017] llevó la idea más lejos conectando cada capa con todas las posteriores del bloque, lo que favorece la reutilización de características. **Xception** [Chollet, 2017] reemplazó los módulos Inception por convoluciones separables en profundidad, concepto central de la siguiente subsección.

La Tabla 2.3 compara estas arquitecturas con las ligeras que se describen a continuación, empleando las cifras que sus propios autores reportan sobre ImageNet. El contraste es ilustrativo: MobileNetV3-Small utiliza aproximadamente una décima parte de los parámetros de ResNet-50 y sacrifica poco menos de nueve puntos de exactitud, un compromiso razonable cuando la restricción de memoria es determinante.

Tabla 2.3: Comparación de arquitecturas sobre ImageNet según las cifras reportadas por sus autores.

Arquitectura	Parámetros	Exactitud top-1	Costo
ResNet-50 [Tan and Le, 2019]	26 M	76.0 %	4.1 GFLOPs
DenseNet-169 [Tan and Le, 2019]	14 M	76.2 %	3.5 GFLOPs
Xception [Tan and Le, 2019]	23 M	79.0 %	8.4 GFLOPs

Arquitectura	Parámetros	Exactitud top-1	Costo
EfficientNet-B0 [Tan and Le, 2019]	5.3 M	77.1 %	0.39 GFLOPs
MobileNetV2 1.0 [Howard et al., 2019]	3.4 M	72.0 %	300 M MAdds
MobileNetV3-Large 1.0 [Howard et al., 2019]	5.4 M	75.2 %	219 M MAdds
MobileNetV3-Small 1.0 [Howard et al., 2019]	2.5 M	67.4 %	56 M MAdds

Conviene subrayar que estas cifras corresponden a una tarea de 1 000 clases con más de un millón de imágenes de entrenamiento. En un problema con pocas decenas de variedades y algunos miles de imágenes, la diferencia de exactitud entre arquitecturas suele reducirse, mientras que la diferencia de costo computacional se mantiene; es precisamente esta asimetría la que justifica priorizar modelos ligeros en el presente proyecto.

2.4.5. Arquitecturas ligeras

Las arquitecturas anteriores fueron diseñadas priorizando la exactitud sobre el costo computacional. Para ejecutarse en dispositivos con recursos limitados se desarrollaron familias de modelos que buscan explícitamente el equilibrio entre ambos.

La idea fundacional es la **convolución separable en profundidad**, introducida en MobileNet [Howard et al., 2017], que descompone una convolución estándar en dos operaciones sucesivas, ilustradas en la Figura 2.3. La *convolución en profundidad* aplica un único filtro espacial $k \times k$ a cada canal de entrada por separado, sin combinarlos. La *convolución puntual* aplica después filtros 1×1 que sí combinan la información entre canales para producir los C_{sal} mapas de salida.

El ahorro es cuantificable. Una convolución estándar requiere $k^2 \cdot C_{\text{ent}} \cdot C_{\text{sal}}$ parámetros (ecuación 2.12), mientras que la versión separable requiere $k^2 \cdot C_{\text{ent}}$ para la etapa en profundidad más $C_{\text{ent}} \cdot C_{\text{sal}}$ para la puntual. La razón entre ambos costos es

$$R = \frac{k^2 \cdot C_{\text{ent}} + C_{\text{ent}} \cdot C_{\text{sal}}}{k^2 \cdot C_{\text{ent}} \cdot C_{\text{sal}}} = \frac{1}{C_{\text{sal}}} + \frac{1}{k^2}. \quad (2.15)$$

Para un filtro de 3×3 y un número de canales de salida grande, el segundo término domina y la reducción se aproxima a un factor de ocho o nueve, con una pérdida de exactitud pequeña. Este resultado explica por qué MobileNet y sus derivados aparecen de forma recurrente en los estudios de identificación varietal orientados a campo, como el de Deng et al. [2025].

Sobre esta base, **MobileNetV2** [Sandler et al., 2018] añadió los *bloques residuales invertidos* con cuello de botella lineal, que expanden el número de canales antes de la convolución en profundidad y lo contraen después, evitando la pérdida de información que provocaría una activación no lineal en un espacio de baja dimensión. **MobileNetV3** [Howard et al., 2019] incorporó búsqueda automática




Figura 2.3: Comparación entre la convolución estándar y la convolución separable en profundidad empleada por las arquitecturas ligeras.

de arquitecturas, bloques de excitación y compresión, y la activación *h-swish*. **EfficientNet** [Tan and Le, 2019] propuso el *escalado compuesto*, que aumenta de forma coordinada la profundidad, la anchura y la resolución de entrada de la red mediante un único coeficiente, en lugar de escalar una sola de esas dimensiones.

Más recientemente, los **transformadores de visión** [Dosovitskiy et al., 2021] han mostrado resultados competitivos al dividir la imagen en parches y procesarlos con mecanismos de autoatención. Requieren conjuntos de datos considerablemente mayores o estrategias de preentrenamiento autosupervisado para igualar a las redes convolucionales, condición que en el dominio de las hojas de vid solo cumplen los trabajos de mayor escala [Carneiro et al., 2024].

2.4.6. Mecanismos de atención

Un problema de las arquitecturas convolucionales puras es que tratan por igual todas las regiones y todos los canales del mapa de características. Los **mecanismos de atención** añaden la capacidad de ponderar esa información, y lo hacen con un costo de parámetros reducido, lo que los vuelve especialmente atractivos en modelos ligeros.

Los bloques de **excitación y compresión** [Hu et al., 2018] operan sobre la dimensión de canales: comprimen cada mapa de características a un único valor mediante agrupamiento global, aprenden con una pequeña red densa un peso por canal, y reescalan los mapas con esos pesos. El modelo aprende así qué tipos de característica son relevantes para cada entrada. MobileNetV3 los incorpora en varios de sus bloques [Howard et al., 2019].

La **atención de coordenadas** [Hou et al., 2021] extiende la idea incorporando información de posición: en lugar de comprimir cada mapa a un escalar, aplica agrupamiento a lo largo de cada eje por separado, lo que conserva la localización de los rasgos relevantes al tiempo que captura dependencias de largo alcance. Este mecanismo es el que emplea Deng et al. [2025] sobre MobileNetV3-Small para clasificar hojas de vid fotografiadas en viñedos reales, donde permite suprimir la contribución del fondo —suelo, hierba, troncos— sin necesidad de una etapa previa de segmentación. Dada la similitud entre ese escenario y el del presente proyecto, se trata de un componente arquitectónico de interés directo.

2.4.7. Transferencia de aprendizaje

Entrenar una red profunda desde cero exige cientos de miles de imágenes etiquetadas, una cantidad muy superior a la disponible en los conjuntos de hojas de vid. La **transferencia de aprendizaje** resuelve esta limitación aprovechando un modelo previamente entrenado sobre un conjunto grande y general, típicamente ImageNet [Deng et al., 2009]. Las primeras capas de ese modelo aprenden detectores de bordes, texturas y formas que resultan útiles en prácticamente cualquier tarea visual, de modo que solo las capas finales necesitan reaprenderse [Yosinski et al., 2014].

En la práctica se emplean dos modalidades. En la **extracción de características** se congela la base convolucional y se entrena únicamente un clasificador nuevo sobre las representaciones que produce; es el enfoque de Koklu et al. [2022a], que alimenta con ellas una máquina de soporte vectorial. En el **ajuste fino** se descongelan además las capas superiores de la base y se reentrenan con una tasa de aprendizaje reducida, para adaptar las representaciones de alto nivel al dominio específico sin destruir lo aprendido. Lo habitual es combinar ambas en dos fases sucesivas, estrategia que adopta la metodología de este proyecto.

2.5. Evaluación de modelos de clasificación

2.5.1. Particiones del conjunto de datos

Para estimar el desempeño de un modelo sobre datos no vistos, el conjunto disponible se divide en tres particiones disjuntas. La partición de **entrenamiento** se usa para ajustar los parámetros; la de **validación** se usa para tomar decisiones sobre el modelo —selección de arquitectura, hiperparámetros, criterio de detención temprana y, en este proyecto, calibración del umbral de rechazo—; y la de **prueba** se reserva para una única evaluación final. La partición debe ser **estratificada**, es decir, conservar la proporción de cada clase en las tres particiones, lo que resulta especialmente importante cuando el número de imágenes por variedad es desigual.

Cuando el conjunto es pequeño, la **validación cruzada de k pliegues** aprovecha mejor los datos: el conjunto se divide en k subconjuntos, se entrena k veces usando cada subconjunto como validación una sola vez, y se promedian los resultados. Su costo es entrenar el modelo k veces.

Cualquier contaminación entre particiones —la **fuga de datos**— invalida la estimación. Además del caso del aumento de datos descrito en la sección 2.2.6, una fuente frecuente en este dominio es la duplicación entre fuentes: los conjuntos públicos de hojas de vid se compilan con frecuencia a partir de otros conjuntos, de modo que la misma imagen puede aparecer en dos recursos distintos y, al unirlos, quedar repartida entre entrenamiento y prueba. También constituye fuga que varias fotografías de la misma hoja física, tomadas desde ángulos distintos, queden separadas entre particiones.

2.5.2. Matriz de confusión y métricas

Los resultados de un clasificador se resumen en la **matriz de confusión**, una tabla de $K \times K$ en la que la celda (i, j) indica cuántas muestras de la clase real i fueron predichas como clase j . La diagonal contiene los aciertos y los elementos fuera de ella revelan qué pares de clases se confunden, información particularmente valiosa en este problema, donde ciertas variedades comparten morfología foliar.

Para una clase k , y denotando por VP_k los verdaderos positivos, FP_k los falsos positivos y FN_k los falsos negativos, se definen la precisión y la exhaustividad:

$$\text{Precision}_k = \frac{VP_k}{VP_k + FP_k}, \quad \text{Recall}_k = \frac{VP_k}{VP_k + FN_k}. \quad (2.16)$$

El **F1-score** de la clase k es su media armónica, que penaliza el desequilibrio entre ambas:

$$F1_k = 2 \cdot \frac{\text{Precision}_k \cdot \text{Recall}_k}{\text{Precision}_k + \text{Recall}_k}. \quad (2.17)$$

La **exactitud** global es la proporción de predicciones correctas sobre el total de muestras N :

$$\text{Exactitud} = \frac{1}{N} \sum_{k=1}^K VP_k. \quad (2.18)$$

Esta métrica es engañosa cuando las clases están desbalanceadas, ya que un modelo puede alcanzar un valor alto acertando solo en las clases más numerosas. Por ello se reporta además el **F1-score macro**, que promedia el F1 de cada clase asignándoles el mismo peso con independencia de su frecuencia:

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k. \quad (2.19)$$

Cuando el sistema entrega una lista ordenada de predicciones, la **exactitud top- n** considera acierto que la clase correcta figure entre las n primeras. Es una métrica pertinente en identificación varietal, porque un sistema que reduce las posibilidades a tres candidatas sigue siendo útil para el técnico que hará la verificación final; el trabajo de De Nart et al. [2024] la emplea precisamente para mostrar que la caída de desempeño en datos externos se atenúa al pasar de top-1 a top-3.

2.5.3. Incertidumbre de las métricas

Una métrica calculada sobre un conjunto de prueba pequeño es una estimación con incertidumbre considerable, y reportarla como un número único puede inducir a error. Para una proporción $\hat{p}$ observada sobre n muestras, el **intervalo de confianza de Wilson** [Wilson, 1927] ofrece una cobertura adecuada incluso con n pequeño o $\hat{p}$ cercano a los extremos, situaciones en las que el intervalo normal clásico falla:

$$IC = \frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}}, \quad (2.20)$$

donde z es el cuantil de la distribución normal estándar correspondiente al nivel de confianza deseado ($z \approx 1,96$ para el 95 %). Dado que el conjunto local de validación externa de este proyecto es de tamaño reducido, todas las métricas externas se reportan acompañadas de este intervalo.

2.5.4. Comparación entre modelos

Seleccionar la mejor arquitectura comparando una sola cifra de exactitud es poco fiable, porque esa cifra depende de la inicialización aleatoria, del orden de los lotes y del comportamiento estocástico de técnicas como dropout. Dos procedimientos mitigan este problema.

El primero consiste en repetir el entrenamiento con varias **semillas aleatorias** distintas y reportar la media y la desviación estándar de la métrica. Si los intervalos de dos arquitecturas se solapan ampliamente, la diferencia observada no sostiene una conclusión.

El segundo aplica una **prueba estadística** sobre las predicciones. La prueba de McNemar [McNemar, 1947] es apropiada cuando dos modelos se evalúan sobre el mismo conjunto de prueba, situación en la que sus errores están correlacionados y las pruebas para muestras independientes no son válidas. La prueba se construye sobre los casos en que los modelos discrepan: sea n_{01} el número de muestras que el primer modelo clasifica mal y el segundo bien, y n_{10} el caso contrario; el estadístico, con corrección de continuidad, es

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}}, \quad (2.21)$$

y se compara contra una distribución χ^2 con un grado de libertad. Dietterich [1998] analiza las propiedades de esta y otras pruebas en el contexto de la comparación de algoritmos de clasificación y advierte sobre el error de tipo I que introducen los procedimientos basados en particiones repetidas.

Cuando la selección se realiza además atendiendo al costo computacional, como ocurre en este proyecto, la comparación deja de ser unidimensional: se trata de elegir sobre una frontera de compromiso entre exactitud y costo, en la que resulta preferible el modelo más económico entre los que satisfacen el umbral de desempeño establecido.

2.5.5. Generalización, cambio de dominio y conjunto abierto

El supuesto sobre el que descansa la evaluación anterior es que los datos de prueba provienen de la misma distribución que los de entrenamiento. Cuando ese supuesto se rompe se produce un **cambio de dominio** o *domain shift* [Quiñonero-Candela

et al., 2009], y el desempeño medido en la partición interna deja de predecir el desempeño real.

En el problema de identificación varietal, el cambio de dominio tiene causas concretas y acumulativas: el dispositivo de captura, con su resolución, óptica y procesamiento de color propios; las condiciones de iluminación, entre luz natural y controlada; el fondo, entre superficie neutra y vegetación; el estado fenológico y sanitario de la hoja; y las condiciones agroclimáticas del viñedo, que modifican la expresión morfológica de la misma variedad. Esta última causa es la traducción, en términos computacionales, de la limitación ampelográfica señalada al inicio del capítulo. La evidencia empírica de este fenómeno en el dominio de las hojas de vid está documentada por De Nart et al. [2024], cuyos modelos perdieron exactitud de forma drástica al evaluarse contra un conjunto adquirido por terceros, y por Carneiro et al. [2024], que obtuvo un F1-score muy inferior al separar las temporadas de adquisición entre entrenamiento y evaluación.

Un segundo supuesto implícito es el de **conjunto cerrado**: que toda muestra presentada al modelo pertenece a alguna de las K clases entrenadas. En condiciones reales este supuesto también se rompe, porque el usuario puede fotografiar una variedad que el modelo nunca vio. Como la función softmax de la ecuación 2.7 fuerza que las probabilidades sumen uno, la red asignará necesariamente la muestra a alguna clase conocida, con frecuencia con confianza alta. El **reconocimiento en conjunto abierto** aborda este problema incorporando la opción de rechazar la predicción. La estrategia de referencia, por su simplicidad y eficacia, utiliza la probabilidad máxima de la salida como puntuación de confianza [Hendrycks and Gimpel, 2017]: dado un umbral τ , el sistema decide

$$\hat{y} = \begin{cases} \arg \max_k p_k, & \text{si } \max_k p_k \geq \tau, \\ \text{“no reconocida”,} & \text{en otro caso.} \end{cases} \quad (2.22)$$

El umbral τ regula el compromiso entre cobertura y seguridad: un valor alto reduce los errores silenciosos pero rechaza también muestras válidas. Debe calibrarse sobre la partición de validación del dominio de entrenamiento y fijarse antes de evaluar el conjunto externo, pues ajustarlo observando los datos de prueba invalidaría la medición.

Una advertencia necesaria es que las redes profundas modernas tienden a estar **mal calibradas**: sus probabilidades son sistemáticamente más altas que la frecuencia real de acierto, de modo que un valor de softmax de 0.99 no equivale a un 99 % de probabilidad de acierto [Guo et al., 2017]. Por ello el umbral debe determinarse empíricamente y no fijarse en un valor arbitrario.

El grado de descalibración se cuantifica con el **error de calibración esperado**, que agrupa las predicciones en M intervalos de confianza B_m y compara, dentro de cada uno, la exactitud observada con la confianza promedio:

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{N} \left| \text{exactitud}(B_m) - \text{confianza}(B_m) \right|. \quad (2.23)$$

Un modelo perfectamente calibrado tendría ECE igual a cero, es decir, entre las predicciones emitidas con confianza cercana a 0.8 acertaría aproximadamente el

80 %. Entre las técnicas de recalibración, el *escalado de temperatura* es la más simple y efectiva: divide los *logits* por un escalar $T > 0$ ajustado sobre la partición de validación antes de aplicar la función softmax de la ecuación 2.7, lo que suaviza la distribución sin alterar el orden de las clases y, por tanto, sin modificar la predicción [Guo et al., 2017]. Esta propiedad es conveniente para el mecanismo de rechazo, pues permite mejorar la interpretabilidad del umbral τ sin afectar la exactitud del clasificador.

2.6. Sistemas embebidos e inferencia en el borde

2.6.1. Conceptos y plataformas

Un **sistema embebido** es un sistema de cómputo diseñado para cumplir una función específica dentro de un dispositivo, con restricciones de memoria, capacidad de procesamiento, consumo energético y, con frecuencia, tiempo de respuesta. Cuando además ejecuta modelos de aprendizaje automático de forma local, sin enviar los datos a un servidor, se habla de **inferencia en el borde** o *edge computing*. Este esquema ofrece cuatro ventajas relevantes para una aplicación de campo: opera sin conexión a internet, algo determinante en viñedos con cobertura limitada; elimina la latencia de la comunicación; mantiene los datos en el dispositivo; y reduce el costo recurrente de infraestructura.

Las plataformas disponibles se agrupan en tres categorías, resumidas en la Tabla 2.4. Los **microcontroladores** ofrecen el menor consumo y costo, pero su memoria se mide en cientos de kilobytes, lo que obliga a modelos muy reducidos. Las **computadoras de placa única** ejecutan un sistema operativo completo y disponen de varios gigabytes de memoria, a cambio de un consumo mayor. Los **módulos con acelerador** incorporan una GPU o una unidad de procesamiento neuronal que reduce sustancialmente la latencia de inferencia, con el mayor costo y consumo de los tres.

Tabla 2.4: Categorías de plataformas para inferencia en el borde. Los valores son órdenes de magnitud orientativos; las cifras exactas del hardware candidato se medirán durante la etapa de selección.

Categoría	Ejemplo	Memoria y cómputo	Consumo aproximado
Microcontrolador	ESP32-S3 con cámara	Cientos de kB de RAM; CPU sin unidad de punto flotante dedicada a tensores	Por debajo de 1 W
Computadora de placa única	Raspberry Pi 5	Varios GB de RAM; CPU multinúcleo de propósito general	Unidades de watts

Categoría	Ejemplo	Memoria y cómputo	Consumo aproximado
Módulo con acelerador	NVIDIA Jetson Orin Nano	Varios GB compartidos; GPU integrada	Modos configurables de 7 W y 15 W

2.6.2. Entornos de ejecución

Un modelo entrenado en un entorno de escritorio no se ejecuta directamente en una plataforma embebida: debe convertirse a un formato de inferencia optimizado. **TensorFlow Lite** —actualmente denominado LiteRT— es el entorno más extendido para dispositivos móviles y de placa única, y cuenta con la variante **TensorFlow Lite Micro** [David et al., 2021], diseñada para microcontroladores sin sistema operativo ni asignación dinámica de memoria. **ONNX Runtime** ofrece un formato intermedio independiente del marco de entrenamiento, lo que facilita mover un modelo entre herramientas. **TensorRT** es el entorno de NVIDIA, que compila el modelo específicamente para la GPU de destino y aplica fusión de capas y selección de núcleos optimizados.

La conversión de un modelo hacia el formato de destino sigue un flujo con puntos de fallo conocidos. El modelo entrenado se exporta a un formato intermedio, se convierte al formato del entorno de ejecución aplicando las optimizaciones elegidas, y finalmente se integra en la aplicación. El obstáculo más frecuente es la **cobertura de operadores**: los entornos embebidos implementan un subconjunto del catálogo de operaciones disponible en el marco de entrenamiento, de modo que una capa poco común o una operación personalizada puede impedir la conversión o forzar su ejecución en un modo de compatibilidad mucho más lento. Por esta razón es recomendable verificar la convertibilidad de la arquitectura candidata antes de invertir tiempo en entrenarla, y no al final del proceso.

Algunas plataformas incorporan además **aceleradores de inferencia** —unidades de procesamiento neuronal o tensorial— que ejecutan operaciones de convolución en hardware dedicado. Estos aceleradores suelen imponer condiciones adicionales: con frecuencia requieren que el modelo esté cuantizado por completo a enteros y que todos sus operadores estén soportados, pues cualquier operación no admitida provoca que el cómputo regrese al procesador principal, lo que anula buena parte de la ganancia esperada.

2.6.3. Técnicas de optimización de modelos

Cuantización. Es la técnica de mayor impacto. Consiste en representar pesos y activaciones con enteros de baja precisión —típicamente 8 bits— en lugar de números de punto flotante de 32 bits. La correspondencia entre el valor real r y su representación entera q es afín [Jacob et al., 2018]:

$$r = S(q - Z), \quad (2.24)$$

donde S es un factor de escala en punto flotante y Z es el entero que representa al cero. Para un intervalo de valores $[r_{\min}, r_{\max}]$ y una representación de b bits, la escala es

$$S = \frac{r_{\max} - r_{\min}}{2^b - 1}. \quad (2.25)$$

La cuantización a 8 bits reduce el tamaño del modelo en un factor cercano a cuatro y permite emplear aritmética entera, considerablemente más rápida y eficiente en energía que la de punto flotante en la mayoría de los procesadores embebidos. Existen dos modalidades: la **cuantización posterior al entrenamiento**, que convierte un modelo ya entrenado usando un pequeño conjunto de calibración para estimar los rangos de activación, y el **entrenamiento consciente de la cuantización**, que simula el efecto del redondeo durante el entrenamiento y recupera buena parte de la exactitud perdida, al costo de reentrenar el modelo.

Poda. Elimina pesos o canales cuya contribución a la salida es despreciable. La poda estructurada, que retira canales o filtros completos, es la que realmente reduce el tiempo de inferencia en hardware convencional, mientras que la poda no estructurada produce matrices dispersas que requieren soporte específico para traducirse en una mejora real de velocidad.

Destilación del conocimiento. Entrena un modelo pequeño —el estudiante— para reproducir las distribuciones de salida de un modelo grande y preciso —el maestro— en lugar de las etiquetas duras [Hinton et al., 2015]. Las probabilidades del maestro contienen información sobre la similitud entre clases que las etiquetas no transmiten, y esa señal adicional permite al estudiante superar el desempeño que alcanzaría entrenado por su cuenta.

2.6.4. Métricas de desempeño embebido

La evaluación de un sistema embebido no se agota en la exactitud. Las métricas complementarias son las siguientes.

La **latencia de inferencia** es el tiempo transcurrido entre la entrada de la imagen y la disponibilidad de la predicción. Debe reportarse descartando las primeras ejecuciones, en las que el entorno reserva memoria y carga el modelo, y acompañada de una medida de dispersión, ya que la distribución suele presentar valores atípicos; por ello se reporta la media junto con un percentil alto, habitualmente el percentil 95. El **rendimiento** o *throughput*, su inverso, expresa cuántas imágenes por segundo procesa el sistema.

El **uso de memoria** comprende tanto el espacio que ocupa el modelo en almacenamiento como la memoria de trabajo requerida durante la inferencia, que incluye los tensores intermedios. En microcontroladores esta última es con frecuencia la restricción determinante.

El **consumo energético** se obtiene a partir de la potencia medida en la alimentación del dispositivo durante la inferencia. La energía por inferencia se calcula como

$$E = \bar{P} \cdot t_{\text{inf}}, \quad (2.26)$$

donde $\bar{P}$ es la potencia media y t_{inf} la latencia. Esta magnitud determina la autonomía en un despliegue alimentado por batería.

2.6.5. Condiciones de medición

Las métricas anteriores solo son comparables si se miden bajo condiciones controladas y documentadas. Tres factores merecen atención particular.

El **estrangulamiento térmico** reduce la frecuencia del procesador cuando la temperatura supera un umbral, con la consiguiente pérdida de rendimiento. Una medición de latencia realizada sobre unas pocas inferencias, con el dispositivo frío, puede resultar considerablemente optimista frente al comportamiento en operación sostenida bajo el sol de un viñedo. Por ello la caracterización debe incluir una prueba de carga prolongada además de la medición puntual.

El **modo de energía** de la plataforma condiciona directamente los resultados: los módulos con acelerador ofrecen perfiles configurables que limitan la potencia disponible, y la latencia medida carece de sentido si no se reporta junto con el perfil activo.

Finalmente, la **frontera de medición** debe definirse con precisión. La latencia de la inferencia aislada no coincide con la latencia extremo a extremo percibida por el usuario, que incluye la captura de la imagen, el preprocesamiento, la copia de datos hacia el acelerador y la presentación del resultado. Reportar solo la primera sobrestima el desempeño del sistema completo, por lo que conviene medir y desglosar ambas.

2.6.6. Captura de imagen

El subsistema de adquisición condiciona todo lo demás. Los módulos de cámara para plataformas embebidas emplean sensores CMOS y se conectan mediante interfaces como MIPI CSI-2, en las placas que la ofrecen, o mediante USB. Los parámetros que más influyen en la calidad de la imagen para esta aplicación son la resolución, que debe superar con margen la entrada del modelo para no perder detalle en el borde dentado de la hoja; el enfoque, dado que la captura se realiza a corta distancia; y el control de exposición y balance de blancos, cuyo comportamiento automático puede introducir variaciones de color entre capturas que el modelo no vio durante el entrenamiento. Una práctica recomendable es documentar y, en lo posible, fijar estos parámetros, de modo que las condiciones de captura en producción se aproximen a las del conjunto de entrenamiento y se reduzca el cambio de dominio descrito en la sección 2.5.5.

2.7. Síntesis del marco teórico

Los elementos presentados en este capítulo se articulan de la siguiente manera en el sistema propuesto. La ampelografía establece que la hoja adulta concentra caracteres suficientes para distinguir variedades, y que esos caracteres son geométricos: proporciones entre nervaduras, ángulos, forma de los senos y del borde. Las redes convolucionales son adecuadas precisamente porque aprenden ese tipo de patrones

espaciales directamente de los píxeles, sin necesidad de medirlos manualmente. La transferencia de aprendizaje hace viable entrenarlas con los pocos miles de imágenes disponibles en los conjuntos públicos, y las arquitecturas ligeras basadas en convolución separable en profundidad reducen el costo computacional lo suficiente para que el modelo quepa en una plataforma embebida.

Ahora bien, la misma ampelografía advierte que la expresión morfológica depende del ambiente, y la teoría del cambio de dominio explica por qué eso degrada el desempeño de un modelo entrenado con imágenes de otro origen; de ahí la necesidad de una evaluación externa con hojas locales y de reportar sus métricas con intervalos de confianza. Y dado que el sistema operará en un entorno donde pueden aparecer variedades ausentes del entrenamiento, el reconocimiento en conjunto abierto justifica incorporar un umbral de rechazo. Finalmente, la cuantización y las métricas de desempeño embebido proporcionan las herramientas para llevar el modelo a la plataforma de destino y caracterizar su comportamiento en ella. Estos son los fundamentos sobre los que se construyen los métodos del capítulo siguiente.

Bibliografia

- T. Adão, S. Shahrabadi, J. Mendes, R. Bastardo, L. Magalhães, R. Morais, and E. Peres. Advancing digital ampelography: Automated classification of grapevine varieties. *Computers and Electronics in Agriculture*, 229:109675, 2025. doi: 10.1016/j.compag.2024.109675.
- F. Ates, H. Coban, Z. Kara, and A. Sabir. Ampelographic characterization of some grape cultivars (*Vitis vinifera* L.) grown in south-western region of Turkey. *Bulgarian Journal of Agricultural Science*, 17(3):314–324, 2011.
- G. Carneiro. UTAD grapevine varieties dataset 2023, 2024.
- G. A. Carneiro, T. J. Aubry, A. Cunha, P. Radeva, and J. J. Sousa. Advancing image-based grapevine variety classification with a new benchmark and evaluation of masked autoencoders. *arXiv preprint arXiv:2506.13335*, 2024. doi: 10.48550/arXiv.2506.13335.
- G. Chen, Z. Xia, X. Ma, Y. Jiang, and Z. He. MobileNet-GDR: a lightweight algorithm for grape leaf disease identification based on improved MobileNetV4-small. *Frontiers in Plant Science*, 16:1702071, 2025. doi: 10.3389/fpls.2025.1702071.
- D. H. Chitwood. The shapes of wine and table grape leaves: An ampelometric study inspired by the methods of Pierre Galet. *Plants, People, Planet*, 3(2):155–170, 2021. doi: 10.1002/ppp3.10157.
- D. H. Chitwood, A. Ranjan, C. C. Martinez, L. R. Headland, T. Thiem, R. Kumar, M. F. Covington, T. Hatcher, D. T. Naylor, S. Zimmerman, N. Downs, N. Raymundo, E. S. Buckler, J. N. Maloof, M. Aradhya, B. Prins, L. Li, S. Myles, and N. R. Sinha. A modern ampelography: A genetic basis for leaf shape and venation patterning in grape. *Plant Physiology*, 164(1):259–272, 2014. doi: 10.1104/pp.113.229708.
- F. Chollet. Xception: Deep learning with depthwise separable convolutions. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017. doi: 10.1109/CVPR.2017.195.
- L. C. Colibaba, D. Rîndunică, I. Bodale, R. Butnaru, M. Mustea, L. M. Irimia, C. E. Luchian, M. T. Andrieș, A. Scutarașu, V. V. Cotea, and L. Rotaru. AI-based recognition tool for Romanian indigenous grapevine cultivars using Xception and convolutional neural networks. In *AI and Engineering*, volume 1925 of *Lecture*

- Notes in Networks and Systems*. Springer, 2026. doi: 10.1007/978-3-032-22615-0_10.
- R. David, J. Duke, A. Jain, V. Janapa Reddi, N. Jeffries, J. Li, et al. TensorFlow Lite Micro: Embedded machine learning for TinyML systems. In *Proceedings of Machine Learning and Systems (MLSys)*, volume 3, 2021.
- D. De Nart, M. Gardiman, V. Alba, L. Tarricone, P. Storchi, S. Roccotelli, M. Ammoniaci, V. Tosi, R. Perria, and R. Carraro. Vine variety identification through leaf image classification: a large-scale study on the robustness of five deep learning models. *The Journal of Agricultural Science*, 162(1):19–32, 2024. doi: 10.1017/S0021859624000145.
- J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei. ImageNet: A large-scale hierarchical image database. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2009. doi: 10.1109/CVPR.2009.5206848.
- L. Deng, Z. Du, X. Liu, Z. Wu, X. Lin, and B. Wen. Grape leaf cultivar identification in complex backgrounds with an improved MobileNetV3-Small model. *Plants*, 14(23):3581, 2025. doi: 10.3390/plants14233581.
- T. G. Dietterich. Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, 10(7):1895–1923, 1998. doi: 10.1162/089976698300017197.
- A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, et al. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- S. Fuentes, E. Hernández-Montes, J. M. Escalona, J. Bota, C. Gonzalez Viejo, C. Poblete-Echeverría, E. Tongson, and H. Medrano. Automated grapevine cultivar classification based on machine learning using leaf morpho-colorimetry, fractal dimension and near-infrared spectroscopy parameters. *Computers and Electronics in Agriculture*, 151:311–318, 2018. doi: 10.1016/j.compag.2018.06.035.
- X. Glorot and Y. Bengio. Understanding the difficulty of training deep feedforward neural networks. In *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2010.
- R. C. Gonzalez and R. E. Woods. *Digital Image Processing*. Pearson, 4th edition, 2018.
- I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016.
- C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger. On calibration of modern neural networks. In *International Conference on Machine Learning (ICML)*, 2017.
- D. Hall, C. McCool, F. Dayoub, N. Sunderhauf, and B. Upcroft. Evaluation of features for leaf classification in challenging conditions. In *IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 797–804, 2015. doi: 10.1109/WACV.2015.111.

- K. He, X. Zhang, S. Ren, and J. Sun. Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. In *IEEE International Conference on Computer Vision (ICCV)*, 2015.
- K. He, X. Zhang, S. Ren, and J. Sun. Deep residual learning for image recognition. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016. doi: 10.1109/CVPR.2016.90.
- D. Hendrycks and K. Gimpel. A baseline for detecting misclassified and out-of-distribution examples in neural networks. In *International Conference on Learning Representations (ICLR)*, 2017.
- G. Hinton, O. Vinyals, and J. Dean. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.
- Q. Hou, D. Zhou, and J. Feng. Coordinate attention for efficient mobile network design. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2021.
- A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le, and H. Adam. Searching for MobileNetV3. In *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019.
- A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam. MobileNets: Efficient convolutional neural networks for mobile vision applications. *arXiv preprint arXiv:1704.04861*, 2017.
- J. Hu, L. Shen, and G. Sun. Squeeze-and-excitation networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018. doi: 10.1109/CVPR.2018.00745.
- G. Huang, Z. Liu, L. van der Maaten, and K. Q. Weinberger. Densely connected convolutional networks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2017. doi: 10.1109/CVPR.2017.243.
- J. Huang. Research on grape leaf classification based on optimized DenseNet201 model. *PLOS ONE*, 20(10):e0334877, 2025. doi: 10.1371/journal.pone.0334877.
- J. Ibáñez, G. Muñoz-Organero, L. H. Zinelabidine, M. T. de Andrés, F. Cabello, and J. M. Martínez-Zapater. Genetic origin of the grapevine cultivar Tempranillo. *American Journal of Enology and Viticulture*, 63(4):549–553, 2012. doi: 10.5344/ajev.2012.12012.
- Institut für Rebenzüchtung Geilweilerhof. Vitis International Variety Catalogue (VIVC). Base de datos en línea, 2026. URL <https://www.vivc.de>.
- S. Ioffe and C. Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International Conference on Machine Learning (ICML)*, 2015.
- B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam, and D. Kalenichenko. Quantization and training of neural networks for efficient

- integer-arithmetic-only inference. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018. doi: 10.1109/CVPR.2018.00286.
- M. J. Karim, M. O. F. Goni, M. Nahiduzzaman, M. Ahsan, J. Haider, and M. Kowalski. Enhancing agriculture through real-time grape leaf disease classification via an edge device with a lightweight CNN architecture and Grad-CAM. *Scientific Reports*, 14:16022, 2024. doi: 10.1038/s41598-024-66989-9.
- D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. In *International Conference on Learning Representations (ICLR)*, 2015.
- B. Kitchenham and S. Charters. Guidelines for performing systematic literature reviews in software engineering. *EBSE Technical Report EBSE-2007-01*, 2007.
- M. Koklu, M. F. Unlersen, I. A. Ozkan, M. F. Aslan, and K. Sabanci. A CNN-SVM study based on selected deep features for grapevine leaves classification. *Measurement*, 188:110425, 2022a. doi: 10.1016/j.measurement.2021.110425.
- M. Koklu, M. F. Unlersen, I. A. Ozkan, M. F. Aslan, and K. Sabanci. Grapevine leaves image dataset. Kaggle Dataset, 2022b. 500 imágenes de hojas de 5 variedades: Ak, Ala Idris, Buzgulu, Dimnit y Nazli.
- A. Krizhevsky, I. Sutskever, and G. E. Hinton. ImageNet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 25, 2012.
- I. Kunduracioglu and I. Pacal. Advancements in deep learning for accurate classification of grape leaves and diagnosis of grape diseases. *Journal of Plant Diseases and Protection*, 131:1061–1080, 2024. doi: 10.1007/s41348-024-00896-z.
- C. Lazcano-García, K. G. García-Resendiz, J. Carrillo-Tripp, E. Inzunza-Gonzalez, E. E. García-Guerrero, D. Cervantes-Vasquez, J. Galarza-Falfan, C. A. Lopez-Mercado, and O. A. Aguirre-Castro. Deep learning-based system for early symptoms recognition of grapevine red blotch and leafroll diseases and its implementation on edge computing devices. *AgriEngineering*, 7(3):63, 2025. doi: 10.3390/agriengineering7030063.
- Y. LeCun, L. Bottou, Y. Bengio, and P. Haffner. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11):2278–2324, 1998. doi: 10.1109/5.726791.
- T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár. Focal loss for dense object detection. In *IEEE International Conference on Computer Vision (ICCV)*, 2017.
- Y. Liu, J. Su, L. Shen, N. Lu, Y. Fang, F. Liu, Y. Song, and B. Su. Development of a mobile application for identification of grapevine (*Vitis vinifera* L.) cultivars via deep learning. *International Journal of Agricultural and Biological Engineering*, 14(5):172–179, 2021. doi: 10.25165/j.ijabe.20211405.6593.
- S. J. López García. Proyecto de adquisición de datos de hoja de vid. Technical report, Universidad Autónoma de Baja California, Programa de Vinculación con

- Valor en Créditos (PVVC), en colaboración con Viñas Pasini S.A. de C.V., 2025. Reporte de proyecto de vinculación con valor en créditos.
- I. Loshchilov and F. Hutter. SGDR: Stochastic gradient descent with warm restarts. In *International Conference on Learning Representations (ICLR)*, 2017.
- S. Magalhães, L. Castro, L. Rodrigues, T. Padilha, et al. Dataset INCAFO – grapevine variety identification using leaves, 2023a. 37 variedades; acceso restringido.
- S. C. Magalhães, L. Castro, L. Rodrigues, T. C. Padilha, F. De Carvalho, F. N. Dos Santos, T. Pinho, G. Moreira, J. Cunha, M. Cunha, P. Silva, and A. P. Moreira. Toward grapevine digital ampelometry through vision deep learning models. *IEEE Sensors Journal*, 2023b. doi: 10.1109/JSEN.2023.3261544.
- S. Mancuso. The fractal dimension of grapevine leaves as a tool for ampelographic research. *HarFA – Harmonic and Fractal Image Analysis*, pages 6–8, 2001.
- Q. McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947. doi: 10.1007/BF02295996.
- V. Nair and G. E. Hinton. Rectified linear units improve restricted Boltzmann machines. In *International Conference on Machine Learning (ICML)*, 2010.
- Organisation Internationale de la Vigne et du Vin. OIV descriptor list for grape varieties and *Vitis* species, 2009.
- Organisation Internationale de la Vigne et du Vin. OIV descriptor list of grapevine varieties and *Vitis* species. Resolución OIV-VITI 702-2023, 2023.
- M. J. Page, J. E. McKenzie, P. M. Bossuyt, I. Boutron, T. C. Hoffmann, C. D. Mulrow, et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372:n71, 2021. doi: 10.1136/bmj.n71.
- C. S. Pereira, R. Morais, and M. J. C. S. Reis. Deep learning techniques for grape plant species identification in natural images. *Sensors*, 19(22), 2019. doi: 10.3390/s19224850.
- J. Quiñonero-Candela, M. Sugiyama, A. Schwaighofer, and N. D. Lawrence. *Dataset Shift in Machine Learning*. MIT Press, 2009.
- A. K. Reyes, J. C. Caicedo, and J. E. Camargo. Fine-tuning deep convolutional networks for plant recognition. *CLEF (Working Notes)*, 1391, 2015.
- D. E. Rumelhart, G. E. Hinton, and R. J. Williams. Learning representations by back-propagating errors. *Nature*, 323:533–536, 1986. doi: 10.1038/323533a0.
- M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen. MobileNetV2: Inverted residuals and linear bottlenecks. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018. doi: 10.1109/CVPR.2018.00474.
- S. T. H. Shah, S. A. H. Shah, S. Godio, K. Kassem, S. A. Qureshi, S. B. Hussain, and M. A. Deriu. Grapevine leaf variety & disease dataset (GLVD), 2026.

- C. Shorten and T. M. Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, 6:60, 2019. doi: 10.1186/s40537-019-0197-0.
- K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.
- N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15:1929–1958, 2014.
- C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015. doi: 10.1109/CVPR.2015.7298594.
- M. Tan and Q. V. Le. EfficientNet: Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, 2019.
- A. M. Tapia, J. A. Cabezas, F. Cabello, et al. Determining the Spanish origin of representative ancient American grapevine varieties. *American Journal of Enology and Viticulture*, 58(2):242–251, 2007.
- I. Terzi, M. M. Ozguven, and A. Yagci. Automatic detection of grape varieties with the newly proposed ampelographic characteristics. *Scientia Horticulturae*, 334: 113340, 2024. doi: 10.1016/j.scienta.2024.113340.
- M. Torres. Produce BC el 85 % del vino de México. Industrial News Baja California, Mar. 2024. URL <https://www.industrialnewsbc.com/2024/03/05/produce-bc-el-85-del-vino-de-mexico/>. Cifras presentadas en el webinar “Vinos Mexicanos”; consultado el 21 de septiembre de 2026.
- S. Vélez, J. A. Rubio, R. Vacas, and E. Barajas. Digital ampelography: deep learning (CNN) using Keras to identify grapevine cultivars. *Acta Horticulturae*, 1390:311–320, 2024. doi: 10.17660/ActaHortic.2024.1390.38.
- M. Vlah. Grapevine leaves. Kaggle Dataset, 2021. Dataset containing 1009 images of leaves from 11 grapevine varieties.
- J. F. Vouillamoz and M. S. Grando. Genealogy of wine grape cultivars: ‘Pinot’ is related to ‘Syrah’. *Heredity*, 97(2):102–110, 2006. doi: 10.1038/sj.hdy.6800842.
- E. B. Wilson. Probable inference, the law of succession, and statistical inference. *Journal of the American Statistical Association*, 22(158):209–212, 1927. doi: 10.1080/01621459.1927.10502953.
- Wine Australia. Vine identification – knowing what you have. Fact sheet, Aug. 2010. URL <https://www.wineaustralia.com/getmedia/21669eff-05de-41d9-9ef8-283b1e01edcb/201008-Vine-identification.pdf>.
- J. Yosinski, J. Clune, Y. Bengio, and H. Lipson. How transferable are features

in deep neural networks? *Advances in Neural Information Processing Systems (NeurIPS)*, 27, 2014.

A

Appendix 1

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.