

Universidad Autónoma de Baja California

FACULTAD DE INGENIERÍA

INGENIERÍA EN COMPUTACIÓN



**Desarrollo e implementación de un sistema embebido
basado en redes neuronales para la identificación automática
de variedades de vid mediante el análisis de hojas**

Asignatura

Proyecto de Carrera

Presentan:

**Jesús Ramón Ruiz Soto
Sergio Josué López García**

Profesor:

Dr. Adolfo Heriberto Ruelas Puente

Mexicali, B.C. México

Septiembre de 2026

1

Introducción

En este capítulo se presenta el estado del arte relacionado con la identificación de variedades de vid mediante características foliares, así como la problemática que motiva el desarrollo del proyecto, su justificación, objetivos, hipótesis y metodología propuesta. La revisión comprende desde los métodos ampelográficos tradicionales hasta las técnicas actuales basadas en aprendizaje profundo y su implementación en dispositivos con recursos computacionales limitados.

1.1. Estado del Arte

Esta sección presenta el estado del arte mediante una revisión sistemática de la literatura. La ejecución de la revisión sigue los lineamientos de Kitchenham y Charters [Kitchenham and Charters, 2007], mientras que la documentación del proceso de búsqueda y selección se apega al protocolo PRISMA 2020 [Page et al., 2021].

1.1.1. Metodología de la revisión sistemática

1.1.1.1. Justificación de la revisión

La identificación de variedades de vid (*Vitis vinifera* L.) mediante el análisis de hojas ha evolucionado desde la ampelografía tradicional hasta el uso de redes neuronales convolucionales, pasando por descriptores morfométricos y clasificadores de aprendizaje automático. Sin embargo, los estudios reportados emplean conjuntos de datos, arquitecturas, métricas y condiciones de evaluación heterogéneas, lo que dificulta determinar qué enfoques ofrecen un mejor equilibrio entre exactitud de clasificación y viabilidad de implementación en plataformas embebidas. Por esta razón se plantea una revisión sistemática que permita identificar, organizar y comparar la evidencia disponible sobre algoritmos, conjuntos de datos y estrategias de generalización e implementación embebida aplicadas a la identificación varietal de vid mediante hojas.

1.1.1.2. Preguntas de investigación

- **PI1.** ¿Qué algoritmos y arquitecturas se han utilizado para clasificar variedades de vid a partir de imágenes de hojas?
- **PI2.** ¿Qué conjuntos de datos (públicos o propios) se han empleado, y qué variedades y cantidad de imágenes cubren?

- **PI3.** ¿Qué métricas y niveles de desempeño se han reportado para estos clasificadores?
- **PI4.** ¿Cómo se ha evaluado la capacidad de generalización de los modelos frente a datos externos al entrenamiento?
- **PI5.** ¿Qué estrategias se han utilizado para implementar estos modelos en dispositivos con recursos computacionales limitados?

1.1.1.3. Estrategia de búsqueda

La estrategia de búsqueda se diseñó en dos fases. La **Fase 1**, cuyos resultados se reportan en esta revisión, consistió en la ejecución de las cadenas de búsqueda sobre fuentes de acceso abierto y motores académicos de cobertura amplia, complementada con el rastreo de referencias (*snowballing*) de los estudios recuperados. La **Fase 2**, que se ejecutará mediante el acceso institucional de la Universidad Autónoma de Baja California, replicará las mismas cadenas en Scopus, Web of Science e IEEE Xplore para incorporar los registros no accesibles públicamente. Esta separación se documenta de manera explícita para que el proceso sea reproducible y para distinguir con claridad el alcance de la evidencia aquí sintetizada.

1.1.1.3.1. Fuentes de información La búsqueda de la Fase 1 se realizó en las fuentes listadas en la Tabla 1.1, seleccionadas por su cobertura en agricultura de precisión, visión por computadora, aprendizaje profundo e ingeniería electrónica, así como por la disponibilidad de texto completo. Se consideraron publicaciones en inglés y español desde el año 2001 —fecha del primer antecedente morfométrico cuantitativo identificado— hasta septiembre de 2026. La última búsqueda se ejecutó el **17 de septiembre de 2026**. Los registros se consolidaron en una hoja de extracción única, en la que se eliminaron los duplicados comparando título, autores y DOI.

Tabla 1.1: Fuentes de información consultadas en la Fase 1 de la búsqueda.

Fuente	Fecha de búsqueda	Periodo	Registros recuperados
Motor académico general (Google Scholar y buscador web indexado)	17/09/2026	2001–2026	32
ScienceDirect (Elsevier)	17/09/2026	2001–2026	8
MDPI (<i>Plants</i> , <i>Agriculture</i> , <i>Sensors</i> , <i>AgriEngineering</i>)	17/09/2026	2018–2026	6
SpringerLink	17/09/2026	2015–2026	6
IEEE Xplore (acceso público)	17/09/2026	2015–2026	3

Fuente	Fecha de búsqueda	Periodo	Registros recuperados
Otras fuentes revisadas por pares (Cambridge Core, PLOS ONE, Frontiers, Nature Portfolio, Acta Horticulturae)	17/09/2026	2019–2026	7
Repositorios de datos y preimpresiones (Zenodo, Kaggle, arXiv)	17/09/2026	2021–2026	3
Total			65

1.1.1.3.2. Palabras clave Los conceptos principales derivados de las preguntas de investigación y sus sinónimos se presentan en la Tabla 1.2. Se incluyeron términos en inglés por ser el idioma predominante de la literatura especializada.

Tabla 1.2: Conceptos y palabras clave utilizadas en las cadenas de búsqueda.

Concepto	Palabras clave y sinónimos
Vid / uva	“grapevine”, “grape”, “Vitis vinifera”, “cultivar”
Hoja	“leaf”, “leaves”, “foliar”
Identificación de variedad	“variety identification”, “variety classification”, “cultivar classification”, “cultivar identification”, “ampelography”
Aprendizaje profundo	“deep learning”, “convolutional neural network”, “CNN”, “transfer learning”, “vision transformer”
Conjunto de datos	“dataset”, “image dataset”, “benchmark”
Generalización	“generalization”, “robustness”, “domain shift”, “external validation”
Sistema embebido	“embedded system”, “edge computing”, “edge device”, “lightweight model”, “mobile deployment”

1.1.1.3.3. Cadenas de búsqueda Se ejecutaron siete cadenas de búsqueda derivadas de la combinación de los conceptos anteriores. Las tres cadenas principales se muestran a continuación.

Cadena general:

("grapevine" OR "grape" OR "Vitis vinifera" OR cultivar)

AND

(leaf OR leaves OR foliar)

AND

("variety identification" OR "variety classification" OR "cultivar classification" OR ampelography)

AND

("deep learning" OR "convolutional neural network" OR CNN

OR "machine learning")

Cadena enfocada en implementación embebida:

("grapevine" OR "Vitis vinifera") AND (leaf OR foliar)

AND ("embedded system" OR "edge computing" OR
"lightweight model" OR "mobile application"
OR "edge device")

Cadena enfocada en generalización y conjuntos de datos:

("grapevine" OR "grape") AND (leaf OR leaves)

AND (dataset OR benchmark)

AND (generalization OR robustness OR "domain shift"
OR "external validation")

Durante la ejecución fue necesario adaptar las cadenas a la sintaxis de cada fuente. En los motores académicos generales se eliminaron los paréntesis anidados, que no son soportados, y cada bloque conceptual se ejecutó como una consulta independiente cuyos resultados se unieron manualmente. En MDPI y SpringerLink las comillas dobles se conservaron pero el operador AND se sustituyó por la búsqueda por campos de título y resumen. En ScienceDirect se aplicó además el filtro de tipo de documento "research article" para descartar editoriales y capítulos introductorios.

1.1.1.4. Criterios de inclusión y exclusión

Criterios de inclusión

- Estudios sobre identificación o clasificación de variedades de vid (*Vitis vinifera*) mediante hojas.
- Investigaciones que describan un método ampelográfico, morfométrico, de aprendizaje automático o aprendizaje profundo.
- Estudios que utilicen conjuntos de datos de imágenes foliares, públicos o propios.
- Conjuntos de datos públicos de imágenes de hoja de vid etiquetados por variedad, incorporados como recursos de datos.
- Artículos publicados en revistas o congresos con revisión por pares.
- Publicaciones en inglés o español dentro del periodo establecido.
- Documentos con texto completo disponible.

Criterios de exclusión

- Registros duplicados.
- Estudios sobre otras especies vegetales sin relación directa con vid, o sobre órganos distintos de la hoja (semilla, baya, sarmiento).
- Estudios enfocados exclusivamente en detección de enfermedades sin relación con identificación varietal. Estos se documentan como antecedente narrativo cuando aportan evidencia sobre arquitecturas ligeras o implementación embebida, pero no se integran a la extracción formal.
- Revisiones, editoriales, resúmenes y presentaciones sin datos originales.
- Propuestas teóricas sin implementación ni evaluación experimental.
- Documentación técnica, tutoriales y repositorios de código sin revisión por pares.
- Documentos no recuperados a texto completo o publicados fuera del periodo establecido.

1.1.1.5. Proceso de selección

Los registros recuperados de las siete cadenas se integraron en una hoja de extracción única. Primero se eliminaron los duplicados comparando título, autores y DOI; posteriormente se cribaron títulos y resúmenes aplicando los criterios de elegibilidad, y finalmente los documentos potencialmente relevantes se recuperaron y evaluaron a texto completo. Las cifras del proceso se presentan en la Tabla 1.3 y el flujo completo en la Figura 1.1.

Tabla 1.3: Resultados del proceso de selección de estudios (Fase 1).

Etapas	Cantidad
Registros identificados	65
Duplicados eliminados	18
Registros cribados (título/resumen)	47
Registros excluidos en el cribado	27
Informes buscados a texto completo	20
Informes no recuperados (acceso restringido)	2
Informes evaluados a texto completo	18
Informes excluidos a texto completo	6
Registros retenidos en la Fase 1	12
Coincidentes con la revisión narrativa previa	5
Nuevos registros incorporados	7
Total de registros incluidos en la revisión	26

El corpus final está formado por los 19 registros documentados en la revisión narrativa previa del proyecto más los 7 registros nuevos aportados por la Fase 1, para un total de 26 registros incluidos (22 estudios y 4 recursos de datos).




Figura 1.1: Diagrama de flujo del proceso de selección de estudios según PRISMA 2020, correspondiente a la Fase 1 de la búsqueda (17 de septiembre de 2026).

1.1.1.6. Evaluación de calidad

La calidad metodológica de los estudios se evaluó mediante la rúbrica de siete criterios presentada en la Tabla 1.4. Se establece de antemano que **la puntuación de calidad no se utiliza como criterio de exclusión**, sino únicamente para ponderar la interpretación de la evidencia: los hallazgos procedentes de estudios de calidad baja se reportan señalando explícitamente esa condición.

Tabla 1.4: Rúbrica de evaluación de calidad metodológica.

Código	Criterio de calidad
C1	¿Se define claramente el objetivo de clasificación varietal?
C2	¿Se describe el conjunto de datos (variedades, tamaño, procedencia)?
C3	¿Se explica suficientemente la arquitectura o método utilizado?
C4	¿Se reportan métricas de desempeño (exactitud, F1, matriz de confusión)?
C5	¿Se evalúa la generalización mediante datos externos o independientes?
C6	¿Se abordan requerimientos computacionales o viabilidad embebida?
C7	¿Se discuten limitaciones o amenazas a la validez?

Cada criterio se califica con 1 punto (sí), 0.5 (parcialmente) o 0 (no), para un máximo de 7 puntos. Los niveles resultantes son: calidad alta, de 6 a 7 puntos; calidad media, de 4 a 5.5 puntos; y calidad baja, menos de 4 puntos. Los cuatro recursos de datos (E14, E15, E16 y E26) no se puntúan, ya que la rúbrica está diseñada para estudios experimentales.

1.1.1.7. Extracción de datos

La Tabla 1.5 contiene la hoja de extracción completa de los 26 registros incluidos. La columna de calidad reporta la puntuación obtenida con la rúbrica C1–C7; se indica “RD” para los recursos de datos y “NI” (no informado) cuando el estudio no proporciona el dato correspondiente.

Tabla 1.5: Hoja de extracción de datos de los registros incluidos.

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E01	Ates et al. [2011]	Descriptores ampelográficos + análisis de conglomerados	10 cultivares (Turquía)	Diferenciación morfológica por conglo- merados	4.0

continúa en la página siguiente

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E02	Mancuso [2001]	Dimensión fractal (<i>box-counting</i>)	Ecotipos de Sangiovese	Menor error que descriptores tradicionales	3.0
E03	Chitwood et al. [2014]	Morfometría geométrica (Fourier elíptico, Procrustes)	>1200 accesiones	Componentes genéticos de forma y venación	4.5
E04	Chitwood [2021]	Integración de ampelografía clásica y morfometría	NI	Marco conceptual, sin clasificador automático	2.0
E05	Fuentes et al. [2018]	Morfo-colorimetría + fractal + NIR + ANN	16 cultivares	Exactitud 94.2 %	5.5
E06	Koklu et al. [2022a]	MobileNetV2 (extracción de características) + SVM	5 variedades, 500 imágenes	Exactitud >97 %	5.0
E07	Reyes et al. [2015]	Ajuste fino de CNN preentrenadas	Reconocimiento de plantas (general)	Antecedente metodológico de transferencia	3.5
E08	Hall et al. [2015]	Evaluación de características para clasificación de hojas	Condiciones visuales complejas (general)	Antecedente metodológico, no específico de vid	4.5
E09	Pereira et al. [2019]	Transferencia de aprendizaje (AlexNet)	6 variedades de uva tinta	Exactitud 77.3 %	5.5
E10	Liu et al. [2021]	Comparación de CNN + aplicación Android	21 cultivares	Hasta 99.91 % (GoogLeNet); app funcional	6.5
E11	Magalhães et al. [2023b]	MobileNetV2 / ResNet-34 / VGG-11-BN	26 variedades	F1-score 94.75 % (MobileNetV2)	6.0

continúa en la página siguiente

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E12	Terzi et al. [2024]	CNN con nuevas características ampelográficas	NI	Exactitud ≈94.1 %	4.0
E13	Adão et al. [2025]	Xception + Mask R-CNN (segmentación previa)	6 var. (GIG6wb, 480 img.) y 12 var. (GIG12nb, 888 img.), Portugal	98.33 % (6 var.) / 95 % (12 var.)	6.0
E14	Vlah [2021]	Conjunto de datos público <i>Grapevine Leaves</i> (Kaggle)	11 variedades, ≈1000 imágenes	Recurso de datos; usado como conjunto externo por E17	RD
E15	Carneiro [2024]	Conjunto de datos público UTAD Grapevine Varieties 2023	Varios dispositivos y condiciones	Recurso de datos con mayor variabilidad	RD
E16	Shah et al. [2026]	Conjunto de datos estandarizado GLVD (multi-fuente)	1469 imágenes, 16 cultivares	Particiones definidas de entrenamien- to/validación/ prueba	RD
E17	De Nart et al. [2024]	Comparación de 5 modelos de visión + validación externa	26 382 imágenes, 27 variedades, 3 sitios (Italia)	Alta exactitud interna; caída marcada en conjunto externo	6.5
E18	Lazcano- García et al. [2025]	CNN para enfermedades virales + <i>edge computing</i> (Jetson Nano)	Contexto vitivinícola de Baja California	Viabilidad de <i>edge computing</i> demostrada (no varietal)	6.0
E19	López García [2025]	Mediciones ampelográficas manuales (ImageJ)	Misión, Syrah y Tempranillo (Baja California)	Conjunto local de referencia para evaluación externa	2.5

continúa en la página siguiente

ID	Referencia	Enfoque / Método	Variedades / Datos	Resultado principal	Cal.
E20	Vélez et al. [2024]	CNN con Keras/-TensorFlow (ampelografía digital)	2 cultivares (Verdejo, Tempranillo), 1011 imágenes	95.8 % (Verdejo) y 100 % (Tempranillo)	4.0
E21	Kunduracioglu and Pacal [2024]	Comparación de 14 CNN y 17 transformadores de visión	5 variedades, 500 imágenes	100 % con Swinv2-Base sobre un conjunto reducido	5.0
E22	Carneiro et al. [2024]	Transformadores de visión (ViT) + autocodificadores enmascarados	43 variedades; 13 479 y 6 776 img. etiquetadas; 54 571 sin etiquetar	F1-score 0.796 (ViT-B preentrenado)	6.5
E23	Huang [2025]	DenseNet201 optimizado (normalización, agrupamiento global y regularización)	5 variedades, 500 img. aumentadas a 2500	F1-score 0.756 en prueba, pese a 99.5 % en entrenamiento	4.5
E24	Deng et al. [2025]	ICS-MobileNetV3-Small (atención de coordenadas + pérdida conjunta)	11 cultivares (incl. Syrah y Tempranillo), 6051 img. en viñedo real	96.53 % con 1.17 M de parámetros (−23.5 %)	6.5
E25	Colibaba et al. [2026]	Xception con ajuste fino en dos fases	10 cultivares autóctonos rumanos	Herramienta de reconocimiento; exactitud NI	2.0
E26	Koklu et al. [2022b]	Conjunto de datos público Grapevine Leaves Image Dataset	500 imágenes, 5 variedades	Recurso de datos base de E06, E21 y E23	RD

1.1.1.8. Método de síntesis

Los estudios se agruparon en las categorías: ampelografía tradicional, morfometría cuantitativa sin aprendizaje automático, aprendizaje automático clásico con características diseñadas manualmente, aprendizaje profundo y transferencia de aprendizaje, arquitecturas basadas en transformadores, implementación embebida y recursos de datos públicos. Para cada categoría se compararon resultados, arquitecturas y limitaciones mediante tablas, gráficas generadas a partir de la hoja de

extracción y una síntesis narrativa. No se realizó un metaanálisis estadístico debido a la heterogeneidad de conjuntos de datos, número de variedades consideradas, particiones de evaluación y métricas reportadas entre los estudios.

1.1.2. Resultados de la revisión

1.1.2.1. Resultados de la búsqueda y selección

La Fase 1 de la búsqueda produjo 65 registros. Tras eliminar 18 duplicados se cribaron 47 títulos y resúmenes, de los cuales 27 fueron excluidos principalmente por tratarse de documentación técnica sin revisión por pares, de estudios sobre enfermedades sin relación varietal o de trabajos sobre otras especies vegetales. Se buscaron 20 informes a texto completo; 2 no pudieron recuperarse por acceso restringido —ambos artículos de congreso alojados en IEEE Xplore, uno sobre modelos de conjunto y otro sobre una aproximación basada en MobileNetV3Large—, por lo que se evaluaron 18 informes completos. De estos, 6 fueron excluidos y 12 retenidos; 5 de los 12 coincidían con estudios ya documentados en la revisión narrativa previa del proyecto y 7 constituyen aportaciones nuevas. Sumados a los 19 registros previos, el corpus final de la revisión asciende a 26 registros: 22 estudios y 4 recursos de datos públicos. La Figura 1.1 presenta el flujo completo.

Es pertinente señalar que la coincidencia de 5 de los 12 registros retenidos con el conjunto documentado previamente funciona como una prueba piloto implícita: indica que las cadenas de búsqueda recuperan de manera efectiva los estudios relevantes ya conocidos, lo cual respalda su validez antes de ejecutar la Fase 2 en las bases de datos de suscripción.

1.1.2.2. Características de los estudios incluidos

La Tabla 1.6 resume la distribución de los 26 registros incluidos por enfoque metodológico principal. La categoría más numerosa es la del aprendizaje profundo basado en redes convolucionales, con 10 estudios, y las dos categorías más recientes —transformadores de visión e implementación embebida— concentran los trabajos publicados a partir de 2024.

Tabla 1.6: Distribución de los registros incluidos por enfoque metodológico.

Categoría	n	Identificadores
Ampelografía tradicional	1	E01
Morfometría cuantitativa sin aprendizaje automático	4	E02, E03, E04, E19
Aprendizaje automático clásico con características diseñadas manualmente	3	E05, E06, E08
Aprendizaje profundo con redes convolucionales	10	E07, E09, E10, E11, E12, E13, E17, E20, E23, E25

Categoría	n	Identificadores
Transformadores de visión y aprendizaje autosupervisado	2	E21, E22
Implementación embebida o <i>edge computing</i>	2	E18, E24
Recursos de datos públicos	4	E14, E15, E16, E26
Total	26	

En cuanto a la distribución temporal, 19 de los 26 registros (73 %) se publicaron a partir de 2021 y 13 (50 %) a partir de 2024, lo que confirma que se trata de una línea de investigación en expansión activa. Geográficamente predominan los trabajos europeos —Portugal (E11, E13, E22), Italia (E02, E17), España (E20) y Rumania (E25)—, seguidos de Turquía (E01, E06, E12, E21, E26) y China (E10, E23, E24). Los únicos antecedentes mexicanos identificados corresponden al propio contexto de Baja California (E18 y E19).

1.1.2.3. Resultados de la extracción de datos

Las exactitudes reportadas por los estudios de clasificación varietal mediante aprendizaje automático y profundo oscilan entre 75.6 % de F1-score (E23, DenseNet201 sobre 5 variedades) y 100 % (E21, Swinv2-Base sobre las mismas 5 variedades y el mismo conjunto de 500 imágenes). Este contraste es el hallazgo más informativo de la extracción: dos estudios que emplean el mismo recurso de datos (E26) reportan desempeños separados por casi 25 puntos porcentuales, lo que evidencia que el protocolo de evaluación —particiones, aumento de datos y selección del conjunto de prueba— influye tanto o más que la arquitectura elegida.

Las arquitecturas ligeras de la familia MobileNet aparecen de forma recurrente (E06, E11, E17, E21, E24), y el estudio más reciente de la serie (E24) es también el que reporta de manera más completa el costo computacional: 1.17 millones de parámetros, una reducción del 23.5 % respecto a la línea base, con 96.53 % de exactitud sobre 11 cultivos fotografiados en un viñedo real. Los tamaños de los conjuntos de datos varían en tres órdenes de magnitud, desde 500 imágenes (E06, E21, E23, E26) hasta 26 382 imágenes (E17) y 54 571 imágenes sin etiquetar empleadas para preentrenamiento autosupervisado (E22).

El número de variedades consideradas oscila entre 2 (E20) y 43 (E22). Las métricas reportadas con mayor frecuencia son la exactitud (*accuracy*), el F1-score y el F1-score macro; solo E11, E22, E23 y E24 reportan además matrices de confusión o métricas por clase, y únicamente E17 y E22 reportan resultados sobre conjuntos externos al entrenamiento.

1.1.2.4. Resultados de la evaluación de calidad

La rúbrica C1–C7 se aplicó a los 22 estudios experimentales; los 4 recursos de datos quedaron fuera de la evaluación. Las puntuaciones individuales se presentan en la Tabla 1.7. La evaluación se basó en la información disponible en los textos completos recuperados y en los resúmenes estructurados de los estudios no accesibles en su totalidad, condición que se reconoce en la sección de amenazas a la validez.

Tabla 1.7: Puntuaciones de calidad metodológica por estudio.

ID	C1	C2	C3	C4	C5	C6	C7	Total	Nivel
E01	1	1	1	0.5	0	0	0.5	4.0	Media
E02	0.5	0.5	1	0.5	0	0	0.5	3.0	Baja
E03	0.5	1	1	1	0	0	1	4.5	Media
E04	0.5	0.5	0.5	0	0	0	0.5	2.0	Baja
E05	1	1	1	1	0	0.5	1	5.5	Media
E06	1	1	1	1	0	0.5	0.5	5.0	Media
E07	0	1	1	1	0	0	0.5	3.5	Baja
E08	0	1	1	1	0.5	0.5	0.5	4.5	Media
E09	1	1	1	1	0	0.5	1	5.5	Media
E10	1	1	1	1	0.5	1	1	6.5	Alta
E11	1	1	1	1	0	1	1	6.0	Alta
E12	1	0.5	1	1	0	0	0.5	4.0	Media
E13	1	1	1	1	0.5	0.5	1	6.0	Alta
E17	1	1	1	1	1	0.5	1	6.5	Alta
E18	0.5	1	1	1	0.5	1	1	6.0	Alta
E19	1	0.5	0.5	0	0	0	0.5	2.5	Baja
E20	1	1	0.5	1	0	0	0.5	4.0	Media
E21	1	1	1	1	0	0.5	0.5	5.0	Media
E22	1	1	1	1	1	0.5	1	6.5	Alta
E23	1	1	1	1	0	0	0.5	4.5	Media
E24	1	1	1	1	0.5	1	1	6.5	Alta
E25	1	0.5	0.5	0	0	0	0	2.0	Baja

De los 22 estudios evaluados, 7 alcanzaron calidad alta (E10, E11, E13, E17, E18, E22 y E24), 10 calidad media y 5 calidad baja. La distribución se muestra en la Figura 1.5.

El análisis por criterio revela un patrón muy marcado. Los criterios C3 (descripción del método) y C4 (reporte de métricas) se satisfacen de forma prácticamente generalizada: 18 y 17 de los 22 estudios los cumplen por completo. En cambio, el criterio **C5 (generalización con datos externos)** es el más débil de todo el corpus: solo 2 estudios de 22 (E17 y E22) lo satisfacen plenamente y 5 más lo hacen de manera parcial, lo que significa que 15 de 22 estudios no evalúan en absoluto el comportamiento de su modelo fuera del conjunto con el que fue entrenado. El criterio C6 (requerimientos computacionales o viabilidad embebida) es el segundo más débil, con solo 4 estudios que lo satisfacen por completo (E10, E11, E18 y E24).

Estas dos debilidades coinciden exactamente con los dos ejes que el presente proyecto se propone abordar.

1.1.2.5. Resultados por pregunta de investigación

PI1 (Algoritmos y arquitecturas). Se identificó una progresión clara en cuatro etapas. Primero, descriptores ampelográficos y morfométricos (E01–E04, E19). Segundo, clasificadores de aprendizaje automático sobre características diseñadas manualmente, como redes neuronales artificiales alimentadas con parámetros morfocolorimétricos, fractales y de espectroscopía NIR (E05), o máquinas de soporte vectorial sobre características extraídas por una red convolucional (E06). Tercero, redes neuronales convolucionales mediante transferencia de aprendizaje, incluyendo AlexNet (E09), GoogLeNet (E10), MobileNetV2, ResNet-34 y VGG-11-BN (E11), Xception con segmentación previa por Mask R-CNN (E13), Xception con ajuste fino en dos fases (E25), EfficientNet e Inception-ResNet (E17) y DenseNet201 optimizado (E23). Cuarto, y como desarrollo más reciente, arquitecturas basadas en transformadores de visión: comparaciones exhaustivas de 14 CNN frente a 17 transformadores (E21) y preentrenamiento autosupervisado con autocodificadores enmascarados sobre ViT (E22). En paralelo a esta progresión, una línea específica optimiza arquitecturas ligeras para su despliegue en campo, cuyo exponente más avanzado es ICS-MobileNetV3-Small (E24). La Figura 1.3 presenta la frecuencia de cada categoría.

PI2 (Conjuntos de datos). Existen cuatro recursos públicos identificados: *Grapevine Leaves* en Kaggle, con 11 variedades y alrededor de 1000 imágenes (E14); el Grapevine Leaves Image Dataset, con 500 imágenes de 5 variedades, que es el más utilizado por su facilidad de acceso (E26, empleado por E06, E21 y E23); UTAD Grapevine Varieties 2023, adquirido con múltiples dispositivos y condiciones (E15); y GLVD, con 1469 imágenes de 16 cultivares y particiones predefinidas de entrenamiento, validación y prueba (E16). Los conjuntos propios de mayor escala pertenecen a E17 (26 382 imágenes, 27 variedades, 3 sitios en Italia) y E22 (13 479 y 6 776 imágenes etiquetadas de 43 variedades, más 54 571 imágenes sin etiquetar para preentrenamiento). En el extremo opuesto, E20 trabaja con solo 2 cultivares y E06, E21, E23 y E26 con 5.

PI3 (Métricas y desempeño). Las métricas predominantes son la exactitud, el F1-score y el F1-score macro. Los valores reportados abarcan un rango muy amplio, de 75.6 % (E23) a 100 % (E21), sin una relación monótona con el número de variedades, como se aprecia en la Figura 1.4. El caso de E10 (99.91 % sobre 21 cultivares) y el de E22 (F1 de 0.796 sobre 43 variedades) ilustran que la dificultad real depende más de las condiciones de adquisición —fondo controlado frente a viñedo real— que del número de clases. Solo cuatro estudios (E11, E22, E23 y E24) reportan métricas desagregadas por clase o matrices de confusión, lo que limita la posibilidad de identificar qué variedades resultan sistemáticamente más difíciles de distinguir.

PI4 (Generalización). Esta es la dimensión con mayor déficit de evidencia. E17 constituye el caso más directo y mejor documentado: cinco modelos entrenados sobre 26 382 imágenes de 27 variedades alcanzaron exactitudes internas muy altas, pero al evaluarse contra un conjunto externo —precisamente el recurso público E14,

restringido a las 8 variedades compartidas— la exactitud en la primera predicción cayó de manera drástica, recuperándose de forma solo parcial (aproximadamente 0.75 a 0.83) al admitir las tres o cinco predicciones más probables. E22 confirma el mismo fenómeno desde otro ángulo: al construir un banco de pruebas con temporadas de adquisición distintas para entrenamiento y evaluación, el mejor F1-score obtenido fue de 0.796, muy por debajo de las cifras superiores al 95 % que se reportan en escenarios de partición aleatoria. E24 aporta evidencia complementaria al trabajar directamente con fondos complejos de viñedo real y cuantificar el nivel de oclusión de las hojas (65 % sin obstrucción, 25 % ligeramente ocluidas, 10 % moderadamente ocluidas). En conjunto, estos tres estudios establecen que la exactitud obtenida sobre particiones aleatorias de un conjunto homogéneo sobrestima de manera sistemática el desempeño esperable en campo.

PI5 (Implementación embebida). Se identificaron dos estrategias diferenciadas. La primera es el despliegue en dispositivos móviles: E10 desarrolló y validó una aplicación Android funcional para 21 cultivos, y E11 seleccionó MobileNetV2 explícitamente por su relación entre desempeño y costo computacional. La segunda es el diseño de arquitecturas ligeras específicas: E24 reduce MobileNetV3-Small a 1.17 millones de parámetros mediante atención de coordenadas y una función de pérdida conjunta, conservando 96.53 % de exactitud. Como antecedentes narrativos —excluidos de la extracción formal por tratarse de detección de enfermedades y no de identificación varietal— destacan tres trabajos que documentan con precisión el costo de inferencia en hardware real: E18, que ejecuta modelos de visión sobre NVIDIA Jetson Nano en el contexto vitivinícola de Baja California; Karim et al. [2024], que reporta 90 ms por imagen y un consumo aproximado de 3.4 W sobre Jetson Nano B01; y Chen et al. [2025], que alcanza 1.75 millones de parámetros y 0.18 GFLOPs con una variante de MobileNetV4-small. Ninguno de los estudios de identificación varietal recuperados reporta simultáneamente latencia, consumo energético y exactitud medidos sobre la plataforma embebida de destino.

1.1.2.6. Representación gráfica

Las figuras de esta subsección se generaron a partir de la hoja de extracción de datos (Tabla 1.5) y de las puntuaciones de calidad (Tabla 1.7).

La Figura 1.2 muestra una concentración pronunciada en el periodo 2024–2026, que reúne 13 de los 26 registros. Los antecedentes previos a 2015 corresponden en su totalidad a métodos ampelográficos y morfométricos, sin componentes de aprendizaje automático.

La Figura 1.4 confirma la ausencia de una relación simple entre el número de variedades y el desempeño alcanzado. Los dos valores más bajos del corpus corresponden, por un lado, al estudio con mayor número de clases y condiciones de adquisición más exigentes (E22, 43 variedades) y, por otro, a un estudio con solo 5 variedades sobre un conjunto reducido (E23), mientras que otro estudio sobre ese mismo conjunto alcanza el 100 % (E21). Esta dispersión vertical dentro de una misma abscisa es la evidencia más directa de que las métricas publicadas no son comparables entre sí sin considerar el protocolo de evaluación.




Figura 1.2: Distribución de los 26 registros incluidos por año de publicación.




Figura 1.3: Frecuencia de los enfoques metodológicos identificados en la revisión.




Figura 1.4: Desempeño reportado frente al número de variedades clasificadas. Para E20 se grafica el promedio de los dos cultivares evaluados; para E22 y E23 se grafica el F1-score, por ser la métrica principal reportada.




Figura 1.5: Distribución de los 22 estudios experimentales por nivel de calidad metodológica según la rúbrica C1–C7.

1.1.3. Discusión de los hallazgos

1.1.3.1. Interpretación de los resultados

Los hallazgos revelan una tensión de tres vértices —exactitud, costo computacional y generalización— que la literatura ha resuelto hasta ahora sacrificando alguno de ellos. Los métodos ampelográficos y morfométricos clásicos (E01–E04, E19) exigen recursos computacionales mínimos y ofrecen interpretabilidad botánica directa, pero dependen de mediciones manuales que impiden la automatización. Las redes convolucionales profundas alcanzan exactitudes superiores al 99 % (E10) a costa de modelos de decenas de millones de parámetros. Las arquitecturas ligeras constituyen el punto intermedio más prometedor, y su evolución dentro del corpus es medible: de MobileNetV2 usada como extractor de características (E06) y como clasificador completo (E11, F1 de 94.75 % sobre 26 variedades), a una variante de MobileNetV3-Small rediseñada específicamente para el problema, con 1.17 millones de parámetros y 96.53 % de exactitud sobre imágenes de viñedo real (E24).

La interpretación más relevante para el presente proyecto, sin embargo, no proviene de los valores máximos de exactitud sino de su varianza. Que E21 y E23 reporten 100 % y 75.6 % respectivamente sobre el mismo recurso de 500 imágenes y las mismas 5 variedades indica que una parte sustancial de las cifras publicadas mide la facilidad del conjunto de datos y no la capacidad del modelo. Los conjuntos pequeños de fondo controlado, con particiones aleatorias y aumento de datos aplicado antes de la partición, favorecen la memorización de artefactos de adquisición. Esta lectura es coherente con la caída documentada por E17 al cambiar de fuente de datos y con el F1-score de 0.796 que E22 obtiene al separar las temporadas de adquisición entre entrenamiento y evaluación.

En cuanto a la viabilidad embebida, los estudios de identificación varietal tratan el costo computacional como una justificación cualitativa para elegir una arquitectura, no como una variable medida. Solo E10 valida una implementación funcional —una aplicación Android— y solo E24 reporta el conteo de parámetros del modelo final. Ninguno reporta latencia de inferencia, consumo energético ni uso de memoria sobre la plataforma de destino. Los datos más precisos sobre este eje provienen de trabajos

de detección de enfermedades: 90 ms por imagen y 3.4 W en Jetson Nano [Karim et al., 2024] y 0.18 GFLOPs con 1.75 millones de parámetros [Chen et al., 2025]. Esto significa que el proyecto debe importar la metodología de medición de la literatura de enfermedades y aplicarla al problema varietal.

1.1.3.2. Comparación con otras investigaciones

Los resultados de esta revisión coinciden con la conclusión central de las revisiones previas sobre ampelografía digital, que identifican la transferencia de aprendizaje sobre redes convolucionales preentrenadas como el enfoque dominante. La aportación diferencial de la presente revisión es la incorporación de los trabajos de 2024–2026, que modifican ese panorama en dos sentidos: introducen los transformadores de visión y el preentrenamiento autosupervisado como alternativa competitiva (E21, E22) y, sobre todo, desplazan el criterio de evaluación desde la exactitud sobre conjuntos controlados hacia la robustez en condiciones de campo (E17, E22, E24). El antecedente local del PVVC-UABC (E19) resulta directamente consistente con la necesidad señalada por E17 y E22 de evaluar los modelos con muestras independientes del entrenamiento: las hojas de Misión, Syrah y Tempranillo cultivadas en Baja California constituyen precisamente un dominio distinto al de los conjuntos públicos europeos y turcos. Este punto adquiere mayor peso al observar que E24 clasifica 11 cultivares que incluyen Syrah y Tempranillo, lo que abre la posibilidad de una comparación directa entre el desempeño publicado sobre ese conjunto chino y el desempeño obtenido sobre material vegetal de Baja California. Se trata, en los términos de E17, de un escenario de validación externa con variedades compartidas.

De manera complementaria, Lazcano-García et al. [2025] (E18) —aunque enfocado en enfermedades virales y no en identificación varietal— constituye el antecedente regional más directo de que es viable procesar imágenes de hojas de vid sobre plataformas de *edge computing* dentro del contexto vitivinícola de Baja California, y por tanto valida la factibilidad técnica de la plataforma sobre la que se desplegará el sistema propuesto.

1.1.3.3. Limitaciones y amenazas a la validez

Se reconocen cinco amenazas a la validez de esta revisión.

Cobertura incompleta de las fuentes. La Fase 1 se ejecutó sobre fuentes de acceso abierto y motores académicos de cobertura amplia; los conteos exportables de Scopus, Web of Science e IEEE Xplore quedan pendientes de la Fase 2. Es posible que existan estudios indexados exclusivamente en esas bases que no hayan sido recuperados. La coincidencia de 5 de los 12 registros retenidos con el conjunto documentado previamente mitiga parcialmente esta amenaza, pero no la elimina.

Sesgo de recuperación por acceso. Dos informes de congreso no pudieron evaluarse a texto completo por acceso restringido, y ambos tratan precisamente temas centrales para las preguntas PI1 y PI5 (modelos de conjunto y una aproximación basada en MobileNetV3Large). Su exclusión podría subestimar la evidencia disponible sobre arquitecturas ligeras.

Evaluación de calidad basada en información parcial. La rúbrica C1–C7 se aplicó a partir de los textos completos recuperados y, en los casos en que el texto completo no estaba disponible, de resúmenes estructurados. Las puntuaciones de E12 y E25 son las más susceptibles a esta limitación, al haberse asignado con información reducida.

Heterogeneidad que impide la comparación cuantitativa. Las diferencias en número de variedades, tamaño y procedencia de los conjuntos de datos, estrategias de aumento, particiones y métricas hacen que las cifras de desempeño no sean directamente comparables, motivo por el cual se descartó el metaanálisis. Las comparaciones presentadas en la Figura 1.4 deben leerse como una caracterización de la dispersión existente, no como un ordenamiento de arquitecturas.

Extracción realizada por un número reducido de revisores. La selección y extracción no se realizaron por duplicado de forma independiente, por lo que no fue posible calcular un índice de concordancia entre revisores. Esta condición introduce un riesgo de sesgo de selección que se mitigó mediante la aplicación explícita y documentada de los criterios de elegibilidad, pero que no queda descartado.

1.1.4. Conclusiones del estado del arte

La revisión de 26 registros confirma que la identificación automática de variedades de vid mediante imágenes de hojas es técnicamente viable, con exactitudes reportadas de hasta 99.91 % sobre 21 cultivares (E10), y que existen antecedentes de implementación tanto en dispositivos móviles (E10) como en plataformas de *edge computing* en el propio contexto vitivinícola de Baja California (E18). La evolución metodológica documentada —de la ampelografía manual a las arquitecturas ligeras optimizadas para campo— indica además que el problema se considera resuelto en el plano algorítmico y que el interés de la comunidad se ha desplazado hacia las condiciones de despliegue.

Ese desplazamiento es precisamente donde la evidencia resulta más escasa. La evaluación de calidad muestra que 15 de los 22 estudios experimentales no evalúan en absoluto la generalización hacia datos externos, y que solo 4 documentan los requerimientos computacionales de su modelo final. Los tres estudios que sí abordan la generalización (E17, E22 y E24) coinciden en que la exactitud obtenida sobre particiones aleatorias de un conjunto homogéneo sobrestima de manera sistemática el desempeño en campo, con caídas que en el caso de E17 resultan drásticas al cambiar de fuente de datos. A esto se suma que ningún estudio de identificación varietal reporta latencia de inferencia, consumo energético y exactitud medidos de forma conjunta sobre la plataforma embebida de destino; los únicos datos precisos en ese sentido provienen de la literatura de detección de enfermedades.

En consecuencia, ningún trabajo identificado combina simultáneamente los tres elementos que define el presente proyecto: clasificación varietal de vid a partir de hojas, evaluación de generalización con un conjunto local independiente del entrenamiento, e implementación completa y caracterizada en una plataforma embebida. Esta combinación constituye la brecha que aborda el proyecto, y el conjunto local de Misión, Syrah y Tempranillo documentado por el PVVC-UABC (E19) —con dos de esas tres variedades presentes también en el conjunto de E24—

ofrece la base para llevar a cabo esa evaluación externa.

1.2. Problemática

Baja California concentra la mayor parte de la producción vitivinícola del país: de acuerdo con cifras difundidas en 2024, alrededor del 85 % del vino que se produce en México proviene de este estado, que reúne más de 150 vinícolas y cerca de 4600 hectáreas de viñedo [Torres, 2024]. En una industria de este peso regional, conocer con certeza qué variedad se tiene plantada no es un detalle técnico: determina el manejo agronómico del viñedo, la etiqueta del vino, el valor comercial de la uva y el cumplimiento de los contratos entre productores y vinícolas.

A pesar de ello, la identificación varietal sigue dependiendo de dos caminos, ambos con limitaciones importantes. El primero es la ampelografía: la descripción morfológica de hojas, brotes y racimos por parte de un especialista. Este método requiere personal altamente capacitado y escaso, solo puede aplicarse en ventanas específicas del ciclo vegetativo, y su resultado se ve afectado por la variación ambiental, las infecciones virales que deforman la hoja, la variabilidad clonal de las variedades antiguas y la interpretación del propio observador [Wine Australia, 2010]. El segundo camino es el análisis molecular mediante marcadores de ADN, que ofrece una identificación objetiva pero exige enviar muestras a un laboratorio especializado, con el costo y el tiempo de espera que ello implica, lo que lo hace poco práctico como herramienta de consulta cotidiana en campo.

Las consecuencias de una identificación errónea están documentadas. En la industria australiana se han reportado plantaciones registradas con un nombre que en realidad contenían otra variedad, mezclas de varias variedades bajo una sola denominación y, en el caso más conocido, un material importado como Albariño que años después resultó ser Savagnin Blanc, lo que obligó a reetiquetar vinos, modificar planes de comercialización y suspender contratos con productores [Wine Australia, 2010].

En el plano tecnológico, la revisión sistemática presentada en la sección anterior muestra que la identificación automática de variedades a partir de imágenes de hojas es técnicamente viable, con exactitudes reportadas superiores al 95 % en múltiples estudios. Sin embargo, la misma revisión evidencia dos carencias que impiden trasladar esos resultados al campo. La primera es la falta de evaluación de la generalización: 15 de los 22 estudios experimentales no evalúan su modelo con datos externos al conjunto de entrenamiento, y los pocos que lo hacen documentan caídas drásticas de desempeño al cambiar la fuente de las imágenes [De Nart et al., 2024, Carneiro et al., 2024]. La segunda es la falta de caracterización embebida: ningún estudio de identificación varietal reporta de manera conjunta la exactitud, la latencia y el consumo energético del modelo sobre la plataforma de hardware en la que operaría.

A estas dos carencias se suma una tercera, propia del contexto regional. Los conjuntos de datos públicos disponibles fueron adquiridos en viñedos de Europa, Turquía y China, bajo condiciones de clima, suelo, iluminación y equipo de captura distintas a las de Baja California. Además, la variedad Misión —la vid histórica introducida en las misiones de la península y genéticamente identificada con la española Listán Prieto [Tapia et al., 2007]— no aparece en ninguno de los conjuntos

públicos identificados. En consecuencia, un clasificador entrenado exclusivamente con datos públicos no solo podría perder exactitud al enfrentarse a hojas locales de variedades conocidas, sino que tendería a asignar con falsa seguridad una etiqueta equivocada a cualquier variedad que nunca vio durante el entrenamiento.

Con base en lo anterior, el problema que aborda este proyecto se formula de la siguiente manera: **no se dispone de un sistema de identificación varietal de vid a partir de hojas que opere de forma autónoma sobre hardware de bajo costo y cuyo desempeño haya sido verificado con hojas cultivadas en Baja California, independientes de los datos con los que fue entrenado.**

1.3. Justificación

El desarrollo del sistema propuesto se justifica desde cuatro perspectivas.

Relevancia regional y económica. Dado que Baja California concentra la mayor parte de la producción nacional de vino [Torres, 2024], una herramienta que facilite la verificación varietal atiende una necesidad concreta de la industria local: la validación del material vegetal adquirido en viveros, la auditoría de plantaciones existentes y la documentación de variedades en viñedos antiguos. Un sistema embebido de bajo costo permitiría realizar una primera verificación directamente en el viñedo, reservando el análisis molecular —más costoso y lento— para los casos en que el sistema reporte baja confianza o una posible discrepancia.

Aportación técnica. El proyecto se dirige exactamente a las dos debilidades más marcadas que identificó la evaluación de calidad del estado del arte: la evaluación de la generalización con datos externos (criterio C5) y la caracterización de la viabilidad embebida (criterio C6). A diferencia de los trabajos revisados, el sistema no se evaluará únicamente sobre una partición del mismo conjunto con el que se entrenó, sino sobre un conjunto local adquirido de forma independiente, y su desempeño se medirá directamente sobre la plataforma de destino. Incorpora además un mecanismo de rechazo por confianza, de modo que el sistema pueda reportar “variedad no reconocida” en lugar de forzar una etiqueta incorrecta, una capacidad que ninguno de los estudios revisados evalúa de forma explícita.

Vinculación académica. El proyecto da continuidad al trabajo del Programa de Vinculación con Valor en Créditos de la UABC realizado en colaboración con Viñas Pasini [López García, 2025], que documentó hojas de Misión, Syrah y Tempranillo cultivadas en Baja California. Ese material, que por sí solo es insuficiente para entrenar una red neuronal profunda, adquiere un valor científico particular al emplearse como conjunto de prueba independiente, ya que permite medir de forma directa el efecto del cambio de dominio entre los datos públicos y las condiciones locales.

Viabilidad. El proyecto es realizable con los recursos disponibles: existen conjuntos de datos públicos con licencia abierta que incluyen dos de las tres variedades locales, las arquitecturas ligeras de redes convolucionales cuentan con modelos preentrenados de libre acceso, y las plataformas embebidas candidatas son de bajo costo y cuentan con soporte maduro para la ejecución de modelos cuantizados.

Los beneficiarios directos del proyecto son los productores y viveristas de la región, que contarían con una herramienta de verificación de primer nivel; los técnicos y

enólogos, como apoyo a la labor ampelográfica; y la comunidad académica, que dispondría de una evaluación documentada del comportamiento de estos modelos fuera de su dominio de entrenamiento.

1.4. Objetivos

1.4.1. Objetivo general

Desarrollar e implementar un sistema embebido basado en redes neuronales convolucionales que identifique automáticamente variedades de vid a partir de imágenes de hojas, entrenado con conjuntos de datos públicos y validado con un conjunto independiente de hojas cultivadas en Baja California.

1.4.2. Objetivos específicos

- OE1.** Integrar un conjunto de datos de entrenamiento a partir de conjuntos públicos de imágenes de hojas de vid, homologando los sinónimos varietales y eliminando imágenes duplicadas entre fuentes.
- OE2.** Entrenar y comparar al menos cuatro arquitecturas de redes neuronales convolucionales mediante transferencia de aprendizaje, priorizando arquitecturas ligeras, y seleccionar la de mejor equilibrio entre desempeño y costo computacional.
- OE3.** Optimizar el modelo seleccionado para su ejecución en dispositivos con recursos limitados mediante cuantización a enteros de 8 bits, cuantificando la pérdida de desempeño asociada.
- OE4.** Seleccionar la plataforma embebida de implementación mediante una comparación de alternativas con criterios ponderados de latencia, consumo energético, memoria disponible y costo.
- OE5.** Implementar el sistema completo de captura, preprocesamiento, inferencia y presentación de resultados en la plataforma seleccionada, incluyendo un mecanismo de rechazo para variedades no reconocidas.
- OE6.** Evaluar la capacidad de generalización del sistema con el conjunto local de hojas de Misión, Syrah y Tempranillo de la UABC, sin emplearlo en ninguna etapa de entrenamiento o ajuste.
- OE7.** Caracterizar el desempeño del sistema sobre la plataforma embebida en términos de latencia de inferencia, consumo energético y uso de memoria.

1.5. Hipótesis

Hipótesis de investigación (H1). Un modelo de red neuronal convolucional ligera, entrenado exclusivamente con conjuntos de datos públicos y cuantizado a enteros de 8 bits, puede implementarse en una plataforma embebida de bajo costo e identificar variedades de vid a partir de imágenes de hojas con un desempeño adecuado para su uso como herramienta de verificación en campo, aun cuando

se evalúa con hojas cultivadas en Baja California que no formaron parte del entrenamiento.

Para que la hipótesis pueda aceptarse o rechazarse de forma objetiva, se descompone en cuatro hipótesis específicas con umbrales verificables, resumidas en la Tabla 1.8. Los umbrales se fijaron a partir de la evidencia del estado del arte: los modelos ligeros reportan entre 94.75 % y 96.53 % de exactitud en validación interna [Magalhães et al., 2023b, Deng et al., 2025], por lo que un umbral de 90 % resulta conservador considerando un conjunto de entrenamiento más reducido; en cambio, los estudios que evaluaron datos externos documentan caídas drásticas [De Nart et al., 2024] y un F1-score de 0.796 incluso con preentrenamiento a gran escala [Carneiro et al., 2024], por lo que el umbral externo se estableció en 70 %.

Tabla 1.8: Hipótesis específicas y criterios de aceptación.

Código	Hipótesis específica	Criterio de aceptación
H1a	El modelo alcanza un desempeño alto dentro del dominio de los conjuntos públicos.	Exactitud top-1 ≥ 90 % y F1-score macro ≥ 0.88 en la partición de prueba interna.
H1b	El modelo generaliza a hojas locales de las variedades que conoce.	Exactitud top-1 ≥ 70 % sobre las imágenes locales de Syrah y Tempranillo.
H1c	El mecanismo de rechazo evita asignar etiquetas falsas a una variedad no incluida en el entrenamiento.	Tasa de rechazo ≥ 70 % sobre las imágenes locales de Misión.
H1d	El modelo optimizado es viable en la plataforma embebida sin pérdida significativa de desempeño.	Latencia de inferencia ≤ 500 ms por imagen y pérdida por cuantización ≤ 2 puntos porcentuales de exactitud.

Hipótesis nula (H0). Al menos uno de los criterios de la Tabla 1.8 no se cumple; es decir, el modelo no alcanza el desempeño interno requerido, no generaliza a las hojas locales, no es capaz de rechazar una variedad desconocida o no es viable sobre la plataforma embebida seleccionada. Cada hipótesis específica se evaluará y reportará de manera independiente, de modo que el rechazo de una de ellas documente con precisión en qué dimensión falla el enfoque.

Las variables del estudio son las siguientes. Las **variables independientes** son la arquitectura de la red, el esquema de optimización (precisión completa frente a cuantización int8) y la plataforma de ejecución. Las **variables dependientes** son la exactitud top-1, el F1-score macro, la tasa de rechazo, la latencia de inferencia, el consumo energético y el uso de memoria. Como **variables controladas** se mantienen fijas la resolución de entrada, las particiones de datos y las semillas aleatorias de entrenamiento.

1.6. Metodología

La metodología se organiza en siete etapas secuenciales, cada una con actividades, entregables y un criterio de salida que debe cumplirse antes de avanzar a la siguiente. La Figura 1.6 presenta el flujo general y la Tabla 1.9 resume la correspondencia entre etapas, objetivos específicos e hipótesis.




Figura 1.6: Flujo general de la metodología. El conjunto local de la UABC ingresa únicamente en la etapa de validación.

Tabla 1.9: Correspondencia entre etapas, objetivos específicos, entregables e hipótesis.

Etapa	Objetivo específico	Entregable	Hipótesis
1. Integración y curaduría de datos	OE1	Conjunto integrado con particiones fijas	–
2. Entrenamiento y selección	OE2	Modelo seleccionado y tabla comparativa	H1a
3. Optimización	OE3	Modelo cuantizado int8	H1d
4. Selección de plataforma	OE4	Matriz de decisión	H1d
5. Implementación embebida	OE5	Prototipo funcional	–
6. Validación y caracterización	OE6, OE7	Métricas internas, externas y de hardware	H1a–H1d

Etap	Objetivo específico	Entregable	Hipótesis
7. Análisis de resultados	–	Contraste de hipótesis	H1, H0

1.6.1. Etapa 1: Integración y curaduría de datos públicos

El conjunto de entrenamiento se construirá a partir de conjuntos públicos con licencia abierta. La base principal será GLVD [Shah et al., 2026], que compila 1 469 imágenes de 16 cultivos con particiones predefinidas e integra los recursos de Koklu et al. [2022b] y Vlah [2021]; se complementará con el UTAD Grapevine Varieties Dataset 2023 [Carneiro, 2024], que aporta imágenes adquiridas con nueve dispositivos distintos y mayor variabilidad de condiciones. El conjunto INCAFO [Magalhães et al., 2023a], con 37 variedades, se solicitará a sus autores dado que su acceso es restringido; su incorporación se considerará opcional.

La Tabla 1.10 muestra la cobertura de las tres variedades locales en los conjuntos públicos identificados. Syrah y Tempranillo están disponibles en al menos un conjunto abierto; Misión no aparece en ninguno. Esta condición define el diseño experimental de la validación: Syrah y Tempranillo funcionarán como clases conocidas para medir la generalización (H1b), mientras que Misión funcionará como variedad desconocida para medir la capacidad de rechazo del sistema (H1c).

Tabla 1.10: Cobertura de las variedades locales en los conjuntos públicos.

Variedad local	Sinónimos	GLVD / Kaggle	UTAD 2023	INCAFO
Syrah	Shiraz	Sí	No	Sí
Tempranillo	Tinta Roriz, Aragonez	Sí	Sí (Tinta Roriz)	Sí (Aragonez)
Misión	Listán Prieto, País, Criolla Chica	No	No	No
Licencia		CC BY 4.0	CC BY 4.0	Restringida

Las actividades de esta etapa son: (a) homologar las etiquetas de las distintas fuentes, unificando sinónimos varietales bajo un solo nombre; (b) eliminar imágenes duplicadas o casi duplicadas mediante comparación por *hash* perceptual, paso indispensable porque GLVD integra imágenes de otros conjuntos públicos y un duplicado presente en entrenamiento y en prueba inflaría artificialmente las métricas; (c) excluir las clases con un número insuficiente de imágenes; y (d) generar particiones estratificadas de entrenamiento, validación y prueba, que quedarán fijas para todo el proyecto. El criterio de salida es disponer del conjunto integrado, con sus particiones congeladas y un reporte del número de imágenes por clase.

1.6.2. Etapa 2: Entrenamiento y selección de arquitectura

Se entrenarán al menos cuatro arquitecturas mediante transferencia de aprendizaje a partir de pesos preentrenados en ImageNet: MobileNetV2, MobileNetV3-Small y EfficientNet-B0 como candidatas ligeras, y ResNet-50 como referencia de mayor capacidad. El entrenamiento se realizará en dos fases: primero con la base convolucional congelada para ajustar el clasificador, y después con descongelamiento parcial de las capas superiores y una tasa de aprendizaje reducida.

Las imágenes se redimensionarán a 224×224 píxeles y se normalizarán según los parámetros de ImageNet. El aumento de datos —rotaciones, reflejos, variaciones de brillo, contraste y tono, y recortes aleatorios— se aplicará exclusivamente sobre la partición de entrenamiento y después de generar las particiones. Esta precaución responde directamente a la evidencia del estado del arte, donde dos estudios sobre el mismo conjunto reportan desempeños separados por casi 25 puntos porcentuales [Kunduracioglu and Pacal, 2024, Huang, 2025].

Cada arquitectura se entrenará con tres semillas aleatorias distintas y se reportará la media y la desviación estándar de la exactitud top-1 y del F1-score macro sobre la partición de prueba interna, junto con la matriz de confusión. La arquitectura se seleccionará con un criterio de equilibrio: entre los modelos que cumplan el umbral de H1a, se elegirá el de menor número de parámetros y operaciones de punto flotante.

1.6.3. Etapa 3: Optimización para recursos limitados

El modelo seleccionado se convertirá a un formato de inferencia embebida (TensorFlow Lite u ONNX, según la plataforma) y se aplicará cuantización posterior al entrenamiento a enteros de 8 bits, utilizando un subconjunto representativo de la partición de entrenamiento para la calibración. Se medirá el tamaño del modelo y la exactitud antes y después de la cuantización sobre la misma partición de prueba. Si la pérdida supera el umbral de H1d, se aplicará entrenamiento consciente de la cuantización como alternativa.

En esta etapa se fijará también el umbral del mecanismo de rechazo. Se utilizará la probabilidad máxima de la salida *softmax* como medida de confianza, y el umbral se calibrará sobre la partición de validación de los conjuntos públicos, de manera que acepte al menos el 95 % de las predicciones correctas. El umbral quedará fijo antes de cualquier contacto con el conjunto local, para que la evaluación de H1c no esté sesgada.

1.6.4. Etapa 4: Selección de la plataforma embebida

La plataforma de implementación se seleccionará mediante una matriz de decisión ponderada entre tres alternativas representativas de distintos niveles de capacidad y costo: una computadora de placa única basada en CPU (Raspberry Pi 5), un módulo con aceleración por GPU (NVIDIA Jetson Orin Nano) y un microcontrolador con cámara integrada (ESP32-S3). Los criterios de evaluación serán la latencia de inferencia del modelo cuantizado, el consumo energético, la memoria disponible frente a la requerida por el modelo, el costo de adquisición y la madurez del soporte de software y de cámara. Como filtro previo se descartará cualquier plataforma en

la que el modelo no quepa en memoria o no alcance el umbral de latencia de H1d. El entregable de la etapa es la matriz de decisión con la justificación de la plataforma elegida.

1.6.5. Etapa 5: Implementación del sistema embebido

Sobre la plataforma seleccionada se implementará el flujo completo del sistema: captura de la imagen de la hoja mediante la cámara, preprocesamiento con los mismos parámetros empleados en el entrenamiento, inferencia con el modelo cuantizado, aplicación del umbral de rechazo y presentación del resultado al usuario, incluyendo la variedad identificada —o la indicación de “variedad no reconocida”— y el nivel de confianza asociado. El criterio de salida es un prototipo que ejecute el flujo completo de forma autónoma, sin depender de una computadora externa ni de conexión a internet.

1.6.6. Etapa 6: Validación y caracterización

La validación se realizará en tres niveles. El **nivel interno** evaluará el modelo sobre la partición de prueba de los conjuntos públicos para contrastar H1a. El **nivel externo** evaluará el sistema sobre el conjunto local de la UABC: las imágenes de Syrah y Tempranillo se usarán para medir la exactitud top-1 (H1b) y las de Misión para medir la tasa de rechazo (H1c). El conjunto local no se utilizará en ninguna etapa de entrenamiento, selección de arquitectura, calibración del umbral ni ajuste de hiperparámetros. Dado que el conjunto local es de tamaño reducido, las métricas externas se reportarán acompañadas de intervalos de confianza al 95 % calculados con el método de Wilson, para que la aceptación o rechazo de la hipótesis considere la incertidumbre asociada al tamaño de muestra.

El **nivel de hardware** caracterizará el sistema sobre la plataforma embebida: latencia de inferencia (media y percentil 95 sobre al menos 100 ejecuciones, excluyendo las ejecuciones iniciales de calentamiento), consumo energético durante la inferencia medido con un medidor de potencia en la alimentación, y uso máximo de memoria. Estas mediciones permitirán contrastar H1d.

1.6.7. Etapa 7: Análisis de resultados y contraste de hipótesis

Cada hipótesis específica se contrastará contra su criterio de aceptación y se reportará de manera independiente. Se analizarán además las matrices de confusión internas y externas para identificar qué variedades se confunden con mayor frecuencia, y se compararán los resultados con los reportados en el estado del arte, con especial atención a la magnitud de la caída entre la evaluación interna y la externa. En caso de que alguna hipótesis se rechace, el análisis documentará la causa probable —insuficiencia de datos, cambio de dominio o limitación del hardware— como base para trabajos futuros.

1.6.8. Alcance y limitaciones

El sistema se limita a la identificación de variedades a partir de hojas maduras fotografiadas individualmente; no contempla racimos, sarmientos ni la detección de enfermedades. El número de variedades que el sistema podrá reconocer está determinado por la cobertura de los conjuntos públicos, por lo que Misión no podrá identificarse positivamente sino únicamente rechazarse como variedad desconocida. Los resultados de la validación externa corresponden a las condiciones de captura del conjunto local de la UABC y no deben extrapolarse sin evaluación adicional a otros viñedos, temporadas o dispositivos de captura. Finalmente, el sistema se plantea como una herramienta de verificación de primer nivel y no sustituye al análisis molecular en los casos que requieran certeza legal o comercial.

Bibliografia

- T. Adão, S. Shahrabadi, J. Mendes, R. Bastardo, L. Magalhães, R. Morais, and E. Peres. Advancing digital ampelography: Automated classification of grapevine varieties. *Computers and Electronics in Agriculture*, 229:109675, 2025. doi: 10.1016/j.compag.2024.109675.
- F. Ates, H. Coban, Z. Kara, and A. Sabir. Ampelographic characterization of some grape cultivars (*Vitis vinifera* L.) grown in south-western region of Turkey. *Bulgarian Journal of Agricultural Science*, 17(3):314–324, 2011.
- G. Carneiro. UTAD grapevine varieties dataset 2023, 2024.
- G. A. Carneiro, T. J. Aubry, A. Cunha, P. Radeva, and J. J. Sousa. Advancing image-based grapevine variety classification with a new benchmark and evaluation of masked autoencoders. *arXiv preprint arXiv:2506.13335*, 2024. doi: 10.48550/arXiv.2506.13335.
- G. Chen, Z. Xia, X. Ma, Y. Jiang, and Z. He. MobileNet-GDR: a lightweight algorithm for grape leaf disease identification based on improved MobileNetV4-small. *Frontiers in Plant Science*, 16:1702071, 2025. doi: 10.3389/fpls.2025.1702071.
- D. H. Chitwood. The shapes of wine and table grape leaves: An ampelometric study inspired by the methods of Pierre Galet. *Plants, People, Planet*, 3(2):155–170, 2021. doi: 10.1002/ppp3.10157.
- D. H. Chitwood, A. Ranjan, C. C. Martinez, L. R. Headland, T. Thiem, R. Kumar, M. F. Covington, T. Hatcher, D. T. Naylor, S. Zimmerman, N. Downs, N. Raymundo, E. S. Buckler, J. N. Maloof, M. Aradhya, B. Prins, L. Li, S. Myles, and N. R. Sinha. A modern ampelography: A genetic basis for leaf shape and venation patterning in grape. *Plant Physiology*, 164(1):259–272, 2014. doi: 10.1104/pp.113.229708.
- L. C. Colibaba, D. Rîndunică, I. Bodale, R. Butnaru, M. Mustea, L. M. Irimia, C. E. Luchian, M. T. Andrieș, A. Scutarașu, V. V. Cotea, and L. Rotaru. AI-based recognition tool for Romanian indigenous grapevine cultivars using Xception and convolutional neural networks. In *AI and Engineering*, volume 1925 of *Lecture Notes in Networks and Systems*. Springer, 2026. doi: 10.1007/978-3-032-22615-0_10.
- D. De Nart, M. Gardiman, V. Alba, L. Tarricone, P. Storchi, S. Roccotelli, M. Ammoniaci, V. Tosi, R. Perria, and R. Carraro. Vine variety identification

- through leaf image classification: a large-scale study on the robustness of five deep learning models. *The Journal of Agricultural Science*, 162(1):19–32, 2024. doi: 10.1017/S0021859624000145.
- L. Deng, Z. Du, X. Liu, Z. Wu, X. Lin, and B. Wen. Grape leaf cultivar identification in complex backgrounds with an improved MobileNetV3-Small model. *Plants*, 14(23):3581, 2025. doi: 10.3390/plants14233581.
- S. Fuentes, E. Hernández-Montes, J. M. Escalona, J. Bota, C. Gonzalez Viejo, C. Poblete-Echeverría, E. Tongson, and H. Medrano. Automated grapevine cultivar classification based on machine learning using leaf morpho-colorimetry, fractal dimension and near-infrared spectroscopy parameters. *Computers and Electronics in Agriculture*, 151:311–318, 2018. doi: 10.1016/j.compag.2018.06.035.
- D. Hall, C. McCool, F. Dayoub, N. Sunderhauf, and B. Upcroft. Evaluation of features for leaf classification in challenging conditions. In *IEEE Winter Conference on Applications of Computer Vision (WACV)*, pages 797–804, 2015. doi: 10.1109/WACV.2015.111.
- J. Huang. Research on grape leaf classification based on optimized DenseNet201 model. *PLOS ONE*, 20(10):e0334877, 2025. doi: 10.1371/journal.pone.0334877.
- M. J. Karim, M. O. F. Goni, M. Nahiduzzaman, M. Ahsan, J. Haider, and M. Kowalski. Enhancing agriculture through real-time grape leaf disease classification via an edge device with a lightweight CNN architecture and Grad-CAM. *Scientific Reports*, 14:16022, 2024. doi: 10.1038/s41598-024-66989-9.
- B. Kitchenham and S. Charters. Guidelines for performing systematic literature reviews in software engineering. *EBSE Technical Report EBSE-2007-01*, 2007.
- M. Koklu, M. F. Unlersen, I. A. Ozkan, M. F. Aslan, and K. Sabanci. A CNN-SVM study based on selected deep features for grapevine leaves classification. *Measurement*, 188:110425, 2022a. doi: 10.1016/j.measurement.2021.110425.
- M. Koklu, M. F. Unlersen, I. A. Ozkan, M. F. Aslan, and K. Sabanci. Grapevine leaves image dataset. Kaggle Dataset, 2022b. 500 imágenes de hojas de 5 variedades: Ak, Ala Idris, Buzgulu, Dimnit y Nazli.
- I. Kunduracioglu and I. Pacal. Advancements in deep learning for accurate classification of grape leaves and diagnosis of grape diseases. *Journal of Plant Diseases and Protection*, 131:1061–1080, 2024. doi: 10.1007/s41348-024-00896-z.
- C. Lazcano-García, K. G. García-Resendiz, J. Carrillo-Tripp, E. Inzunza-Gonzalez, E. E. García-Guerrero, D. Cervantes-Vasquez, J. Galarza-Falfan, C. A. Lopez-Mercado, and O. A. Aguirre-Castro. Deep learning-based system for early symptoms recognition of grapevine red blotch and leafroll diseases and its implementation on edge computing devices. *AgriEngineering*, 7(3):63, 2025. doi: 10.3390/agriengineering7030063.
- Y. Liu, J. Su, L. Shen, N. Lu, Y. Fang, F. Liu, Y. Song, and B. Su. Development of a mobile application for identification of grapevine (*Vitis vinifera* L.) cultivars via

- deep learning. *International Journal of Agricultural and Biological Engineering*, 14(5):172–179, 2021. doi: 10.25165/j.ijabe.20211405.6593.
- S. J. López García. Proyecto de adquisición de datos de hoja de vid. Technical report, Universidad Autónoma de Baja California, Programa de Vinculación con Valor en Créditos (PVVC), en colaboración con Viñas Pasini S.A. de C.V., 2025. Reporte de proyecto de vinculación con valor en créditos.
- S. Magalhães, L. Castro, L. Rodrigues, T. Padilha, et al. Dataset INCAFO – grapevine variety identification using leaves, 2023a. 37 variedades; acceso restringido.
- S. C. Magalhães, L. Castro, L. Rodrigues, T. C. Padilha, F. De Carvalho, F. N. Dos Santos, T. Pinho, G. Moreira, J. Cunha, M. Cunha, P. Silva, and A. P. Moreira. Toward grapevine digital ampelometry through vision deep learning models. *IEEE Sensors Journal*, 2023b. doi: 10.1109/JSEN.2023.3261544.
- S. Mancuso. The fractal dimension of grapevine leaves as a tool for ampelographic research. *HarFA – Harmonic and Fractal Image Analysis*, pages 6–8, 2001.
- M. J. Page, J. E. McKenzie, P. M. Bossuyt, I. Boutron, T. C. Hoffmann, C. D. Mulrow, et al. The PRISMA 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372:n71, 2021. doi: 10.1136/bmj.n71.
- C. S. Pereira, R. Moraes, and M. J. C. S. Reis. Deep learning techniques for grape plant species identification in natural images. *Sensors*, 19(22), 2019. doi: 10.3390/s19224850.
- A. K. Reyes, J. C. Caicedo, and J. E. Camargo. Fine-tuning deep convolutional networks for plant recognition. *CLEF (Working Notes)*, 1391, 2015.
- S. T. H. Shah, S. A. H. Shah, S. Godio, K. Kassem, S. A. Qureshi, S. B. Hussain, and M. A. Deriu. Grapevine leaf variety & disease dataset (GLVD), 2026.
- A. M. Tapia, J. A. Cabezas, F. Cabello, et al. Determining the Spanish origin of representative ancient American grapevine varieties. *American Journal of Enology and Viticulture*, 58(2):242–251, 2007.
- I. Terzi, M. M. Ozguven, and A. Yagci. Automatic detection of grape varieties with the newly proposed ampelographic characteristics. *Scientia Horticulturae*, 334: 113340, 2024. doi: 10.1016/j.scienta.2024.113340.
- M. Torres. Produce BC el 85 % del vino de México. Industrial News Baja California, Mar. 2024. URL <https://www.industrialnewsbc.com/2024/03/05/produce-bc-el-85-del-vino-de-mexico/>. Cifras presentadas en el webinar “Vinos Mexicanos”; consultado el 21 de septiembre de 2026.
- S. Vélez, J. A. Rubio, R. Vacas, and E. Barajas. Digital ampelography: deep learning (CNN) using Keras to identify grapevine cultivars. *Acta Horticulturae*, 1390:311–320, 2024. doi: 10.17660/ActaHortic.2024.1390.38.
- M. Vlah. Grapevine leaves. Kaggle Dataset, 2021. Dataset containing 1009 images of leaves from 11 grapevine varieties.

Wine Australia. Vine identification – knowing what you have. Fact sheet, Aug. 2010. URL <https://www.wineaustralia.com/getmedia/21669eff-05de-41d9-9ef8-283b1e01edcb/201008-Vine-identification.pdf>.

A

Appendix 1

Lorem ipsum dolor sit amet, consectetur adipisicing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.